UNIVERSIDAD TÉCNICA DE AMBATO

Facultad de Ingeniería en Sistemas, Electrónica e Industrial

Carrera de Software

Machine Learning aplicado al Data Warehouse Wide World Importers

Clasificación binaria de ventas mediante perceptrón simple y regresión logística

Informe académico incremental

Primera aplicación desarrollada y evaluada: Data Mart de Ventas

Asignatura:	Inteligencia de Negocios
Autores:	Josue Guevara
	Jonathan López
Docente:	Ing. Rubén Nogales Portero, Ph.D.
Nivel y paralelo:	Sexto «A»
Unidad curricular:	Profesional

Autores, nivel y unidad curricular verificados en los informes académicos previos.

Ciclo y fecha de entrega de esta versión: pendientes de confirmación.

Las referencias previas indican enero–julio de 2026 y una carta de diseño fechada el 18/08/2026.

Resumen

Se estudia la clasificación binaria de ventas unitarias mensuales de Wide World Importers (WWI), a partir de una extracción de su Data Mart de Ventas. La respuesta indica si las unidades observadas de un producto superan la mediana de sus tres meses previos. Se auditaron 228 265 líneas de factura y se construyeron observaciones producto-mes con información disponible antes del horizonte objetivo. El perceptrón simple y la regresión logística se implementaron mediante NumPy sobre las mismas 20 características transformadas, con particiones temporales de 4 599 observaciones de entrenamiento, 2 628 de validación y 1 111 de prueba.

La selección utilizó únicamente validación; las predicciones finales se conservaron y su consistencia se comprobó sin reentrenar. En prueba, la regresión logística alcanzó balanced accuracy de 62,42 %, frente a 54,10 % del perceptrón, 50,00 % del baseline mayoritario y 51,31 % de la regla histórica. La logística registró 370 falsos positivos y 49 falsos negativos, lo que limita su utilidad para alertas automáticas. El perceptrón mantuvo actualizaciones hasta la última época; la logística mostró descenso estable de entropía cruzada, sin demostración de convergencia completa al agotar 200 épocas. PCA se empleó solo para visualización y conservó 49,62 % de la varianza en dos componentes.

Las conclusiones son descriptivas de cinco meses de prueba con observaciones dependientes. La cobertura al cierre y la identidad por nombre son supuestos o limitaciones pendientes de validación operacional. Este documento recoge la primera aplicación efectivamente implementada en Ventas; la extensión a los demás Data Marts es una obligación académica pendiente, no una actividad opcional ni un resultado ya obtenido.

Palabras clave: Inteligencia de Negocios; Data Warehouse; clasificación temporal; perceptrón; regresión logística; PCA; trazabilidad.

Índice

Resumen I

1. Introducción 1

1.1. Alcance académico incremental 1

2. Problema empresarial y objetivos 1

2.1. Pregunta de negocio y respuesta operativa 1

2.2. Objetivo general 1

2.3. Objetivos específicos 1

3. Fundamentos matemáticos 2

3.1. Neurona artificial y perceptrón simple 2

3.2. Regresión logística binaria 2

3.2.1. Verificación de gradientes y condiciones de descenso 3

3.3. PCA mediante descomposición SVD 3

3.4. Métricas y magnitudes de error 4

4. Data Warehouse WWI y evidencia de origen 5

5. Metodología y preparación causal de datos 5

5.1. Grano producto-mes, etiqueta e instante de predicción 5
5.2. Completitud y disponibilidad asumidas 5
5.3. Características permitidas y exclusiones 6
5.4. Particiones temporales y control de fuga 6
5.5. Baselines comunes 7

6. Implementación del perceptrón simple **8**

7. Implementación de la regresión logística binaria **11**

8. Verificación de convergencia y comportamiento del error **15**
8.1. Evidencia y definición de los diagnósticos 15
8.2. Perceptrón: fluctuaciones sin cese de actualizaciones 15
8.3. Logística: descenso estable, límite de épocas 15

9. Reducción dimensional para visualización **18**

10. Resultados experimentales **21**
10.1. Comparación común de entrenamiento, validación y prueba 21
10.2. Matrices de confusión, sensibilidad y exceso de positivos 22
10.3. Generalización temporal y error por partición 22
10.3.1. Por qué BA global y promedio mensual difieren 24
10.4. Productos conocidos y nuevos 25
10.5. Concordancias y desacuerdos 25

11. Comparación estadística y cambios de distribución **27**
11.1. Distribuciones observadas frente a hipótesis de cambio 27
11.2. Incertidumbre y dependencia 28

12. Interpretación para Inteligencia de Negocios **28**

13. Limitaciones y decisiones pendientes **28**

14. Conclusiones parciales del Data Mart de Ventas **29**

Referencias bibliográficas **30**

A. Catálogo de características efectivas **31**

B. Trazabilidad y reproducción documental **31**
B.1. Relación entre afirmaciones y evidencia 31
B.2. Comandos sin reentrenamiento 32
B.3. Parámetros y series que no deben confundirse 32

C. Continuidad obligatoria del proyecto académico **32**

Índice de figuras

1. Clases y calendario por partición 6
2. Errores online del perceptrón 9
3. Accuracy por época del perceptrón 9
4. BA de validación del perceptrón 10
5. Entropía cruzada de entrenamiento y validación 12
6. Norma del gradiente logístico 13
7. Accuracy por época de logística 13
8. BA de validación de logística 14
9. Diagnóstico detallado de convergencia logística 16
10. Conteos del perceptrón y pérdida logística en paneles separados 17
11. Dispersión PCA de entrenamiento 19
12. Dispersión PCA de validación 19
13. Varianza individual y acumulada del PCA 20
14. Comparación de métricas globales de test 21
15. Matriz de confusión de test del perceptrón 22
16. Matriz de confusión de test de logística 23
17. Sensibilidad y especificidad por método 23
18. Error de clasificación por partición 24
19. BA de todos los meses de test 25
20. Aciertos compartidos y exclusivos por mes 26
21. Cambios de medias en las entradas existentes 27

Índice de tablas

1. Particiones por mes objetivo y soporte de clases; historia disponible desde enero de 2013. . . . 6
2. Pesos del modelo congelado perceptrón. Valores float64 conservados con representación decimal de ida y vuelta. . . . 8
3. Verificación original por diferencias finitas centrales. Todos los casos cumplen tolerancias. . . . 11
4. Presupuesto logístico previo: 200 épocas por tasa; checkpoint elegido por BA de validación a umbral 0,5. . . . 11
5. Pesos del modelo congelado logístico. Valores float64 conservados con representación decimal de ida y vuelta. . . . 12
6. Recorrido seleccionado del perceptrón: errores online y al cierre son magnitudes diferentes. . . . 15
7. Diagnóstico documental por época. ΔL y r se derivan del historial sin modificar el criterio de parada. . . . 16
8. Cinco mayores coeficientes por magnitud en cada componente. El cuadrado es participación en la norma del vector, no importancia predictiva. . . . 18
9. Métricas finales por partición (%). Estados seleccionados en validación; no corresponden a la última época del perceptrón. . . . 21
10. Conteos de test y tasas de error (%). Filas reales y columnas predichas en orden 0,1. 22
11. Todos los meses de test. Tasas en %; soporte negativo/positivo. . . . 24
12. Comparación de cohortes en test, sin excluir los productos nuevos. . . . 25
13. Entradas efectivas y fórmulas del contrato. $q_j = Q_{p,t-j}$. . . . 31

1. Introducción

El análisis descriptivo de un Data Warehouse permite comparar indicadores por tiempo, producto, cliente y territorio. La clasificación predictiva plantea una pregunta distinta: qué información disponible antes de un mes permite anticipar un comportamiento de sus ventas. Este trabajo enlaza ambas perspectivas mediante un problema reproducible, con reglas temporales explícitas y evaluación común de dos clasificadores lineales.

La carta de diseño plantea necesidades de seguimiento comercial, clientes e inventario; los informes de limpieza y dashboard documentan la preparación y exploración del ámbito de ventas [5, 6, 7]. La extracción disponible respalda esa primera aplicación, pero no acredita la disponibilidad ni implementación de todos los procesos del Data Warehouse. Las dimensiones Producto y Cliente no se consideran Data Marts independientes por el solo hecho de existir como dimensiones.

1.1. Alcance académico incremental

La instrucción proporcionada para esta entrega es: «Perfeccionen todo con un data mart y de ahí háganlo con el resto de Data Marts». En consecuencia, Ventas constituye la primera aplicación desarrollada y evaluada. La continuación obligatoria consiste en trasladar la metodología a los demás Data Marts contemplados en el proyecto, previa comprobación de su modelo, datos y problema predictivo. No se han implementado ni evaluado aquí esas aplicaciones. La estructura modular del informe permite incorporarlas posteriormente sin atribuirles resultados inexistentes.

2. Problema empresarial y objetivos

2.1. Pregunta de negocio y respuesta operativa

Al cierre del mes anterior se busca identificar productos cuyas unidades facturadas observadas en el siguiente mes superarán su mediana reciente. La comparación se realiza contra la historia del propio producto, no contra un umbral absoluto común. Un positivo puede corresponder a una diferencia de una sola unidad; su relevancia comercial necesita validación adicional.

La respuesta no representa rentabilidad, demanda insatisfecha, inventario disponible ni cantidad exacta futura. Una alerta podría orientar la revisión de un analista comercial; no establece por sí sola una orden de compra o reposición. No se dispone de costos de falsos positivos o negativos para cuantificar beneficio económico.

2.2. Objetivo general

Desarrollar y documentar una primera aplicación verificable de clasificación binaria en el Data Mart de Ventas de WWI, comparando un perceptrón simple y una regresión logística implementados matemáticamente, con prevención de fuga temporal y conclusiones sustentadas en resultados congelados.

2.3. Objetivos específicos

1. Auditar el grano, identidad, calidad y disponibilidad temporal de los datos antes de definir las entradas y la etiqueta.

2. Preparar una representación común de dimensión dinámica y particiones cronológicas, con parámetros de transformación ajustados solo en entrenamiento.

3. Implementar las reglas del perceptrón y los gradientes logísticos, comprobar su matemática y analizar sus historiales reales.

4. Comparar ambos modelos con baselines mediante matrices de confusión, métricas por clase y evaluación temporal.

5. Interpretar PCA únicamente como visualización e identificar las limitaciones estadísticas y empresariales de la evidencia.

6. Dejar una estructura documental reproducible para la ampliación obligatoria a los demás Data Marts, sin implementarlos en esta entrega.

3. Fundamentos matemáticos

3.1. Neurona artificial y perceptrón simple

Una observación transformada es un vector $x \in \mathbb{R}^d$, con $d = 20$ en este experimento. Una neurona lineal combina cada entrada con un peso w_j y añade un sesgo b:

$$z = w^\top x + b = \sum_{j=1}^{d} w_j x_j + b, \qquad \widehat{y} = \mathbf{1}[z \geq 0]. \tag{1}$$

El peso controla la contribución algebraica de una entrada y el sesgo desplaza el hiperplano. La función escalón devuelve una clase, no una probabilidad. Con etiquetas canónicas $y \in \{0, 1\}$, la implementación usa

$$e_i = y_i - \widehat{y}_i, \quad w \leftarrow w + \eta e_i x_i, \quad b \leftarrow b + \eta e_i, \tag{2}$$

solo si $e_i \neq 0$. La tasa $\eta > 0$ determina la magnitud del paso. Una época recorre todas las observaciones de entrenamiento; cada error durante ese recorrido produce una actualización. Los errores al finalizar una época se calculan con un único estado de parámetros y pueden diferir del conteo online, que mezcla los estados sucesivos.

La separabilidad lineal supone que existe un hiperplano que clasifica estrictamente todos los ejemplos. Para expresar la condición teórica, se incorporan sesgo y entrada aumentada $\widetilde{x} = (x, 1)$, etiquetas $s = 2y - 1$ y un separador unitario u con margen $s_i u^\top \widetilde{x}_i \geq \gamma > 0$. Si $\|\widetilde{x}_i\| \leq R$, la regla clásica desde cero realiza a lo sumo $(R/\gamma)^2$ errores bajo esas hipótesis. El escalado constante positivo de la actualización no cambia el argumento geométrico. La convención de empate del programa asigna 1; ello no autoriza inferir separabilidad de los datos.

La garantía requiere un margen positivo y presentación reiterada de los ejemplos. No establece que cualquier conjunto real sea separable, ni que 100 épocas basten, ni que un checkpoint con buena validación tenga cero errores. En ausencia de una prueba de separabilidad, las oscilaciones observadas solo describen el comportamiento de esta ejecución. El modelo corresponde al antecedente clásico del perceptrón [1]; su optimización no es descenso de entropía cruzada.

3.2. Regresión logística binaria

Para el mismo $z_i = w^\top x_i + b$, se estima $p_i = \sigma(z_i) = 1/(1 + \exp(-z_i))$. El umbral τ transforma la salida en $\widehat{y}_i = \mathbf{1}[p_i \geq \tau]$. Aquí $\tau = 0,5$ está congelado: la frontera es $z = 0$. La salida está comprendida entre cero y uno, pero su calibración empírica no se deduce de esa propiedad.

La pérdida media para m ejemplos es la entropía cruzada binaria:

$$L(w,b) = -\frac{1}{m}\sum_{i=1}^{m}[y_i \log p_i + (1-y_i)\log(1-p_i)] \tag{3}$$
$$= \frac{1}{m}\sum_{i=1}^{m}[\log(1+\exp(z_i)) - y_i z_i].$$

Derivando con respecto al logit se obtiene $\partial \ell_i/\partial z_i = p_i - y_i$; la regla de la cadena conduce a

$$\nabla_w L = \frac{1}{m}X^\top(p-y), \qquad \partial_b L = \frac{1}{m}\sum_i (p_i - y_i). \tag{4}$$

El descenso por lote completo actualiza $w \leftarrow w - \eta\nabla_w L$ y $b \leftarrow b - \eta\partial_b L$ una vez por época. Utiliza toda la matriz, no únicamente ejemplos mal clasificados. El objetivo suave refleja también cambios de confianza que no cruzan el umbral, por lo que resulta más informativo para estudiar la optimización que el conteo discreto de errores. Las convenciones de clasificación y pérdida siguen el tratamiento de modelos lineales probabilísticos [2].

La estabilidad numérica se favorece evaluando la sigmoidea por ramas: para $z \geq 0$, $1/(1+e^{-z})$; para $z < 0$, $e^z/(1+e^z)$. La pérdida utiliza `np.logaddexp(0,z)-y*z`, sin calcular logaritmos de probabilidades redondeadas a cero ni recortarlas. El programa rechaza estados no finitos.

3.2.1. Verificación de gradientes y condiciones de descenso

Para un parámetro θ_j, las diferencias centrales aproximan

$$g_j^{\text{num}} = \frac{L(\theta + h_j e_j) - L(\theta - h_j e_j)}{2h_j}, \qquad h_j = h\,\text{máx}(1, |\theta_j|), \tag{5}$$

donde e_j es el vector coordenado, incluido el sesgo. Se contrasta $|g_j - g_j^{\text{num}}| \leq \text{atol} + \text{rtol}|g_j^{\text{num}}|$. Un paso demasiado pequeño amplifica cancelación y uno demasiado grande aumenta error de truncamiento. La prueba comprueba derivadas locales en sus casos de control; no demuestra convergencia del entrenamiento WWI.

Con matriz aumentada $A = [X\ \mathbf{1}]$ y $D = \text{diag}(p_i(1-p_i))$, la Hessiana es $A^\top DA/m \succeq 0$. Así, el objetivo es convexo y tiene gradiente Lipschitz con cota $L_g \leq \|A\|_2^2/(4m)$. Un paso adecuadamente pequeño, por ejemplo $0 < \eta < 2/L_g$ cuando se dispone de esa cota, permite justificar descenso. Esta condición no se comprobó retrospectivamente para elegir otra tasa. Sin regularización, separabilidad puede impedir un minimizador finito; redundancia puede impedir unicidad. Menor pérdida, gradiente reducido y estabilización son diagnósticos distintos de certificar un óptimo [3].

3.3. PCA mediante descomposición SVD

Sea $X \in \mathbb{R}^{m\times d}$ la matriz de entrenamiento ya transformada. Se calcula su media μ y $X_c = X - \mathbf{1}\mu^\top$. La SVD real produce

$$X_c = U\Sigma V^\top, \quad W_2 = [v_1, v_2], \quad Z = (X - \mathbf{1}\mu^\top)W_2. \tag{6}$$

Los vectores v_j son ortonormales y los valores singulares σ_j están ordenados de mayor a menor, de acuerdo con la operación SVD de NumPy [4]. Las varianzas y proporciones se definen por

$$\lambda_j = \frac{\sigma_j^2}{m-1}, \qquad \rho_j = \frac{\lambda_j}{\sum_{q=1}^{d}\lambda_q}. \tag{7}$$

El denominador incluye las 20 direcciones, no solo las dos conservadas. La proyección favorece varianza, no separación de etiquetas. El signo de cada vector es convencional; aquí se hace positivo su coeficiente de mayor magnitud. Centrado y componentes se ajustaron solo en entrenamiento y se reutilizaron en validación. Los clasificadores conservaron las 20 entradas originales transformadas.

3.4. Métricas y magnitudes de error

Con matriz de confusión $C = \left[\begin{smallmatrix} TN & FP \\ FN & TP \end{smallmatrix}\right]$, filas reales y columnas predichas, se calculan

$$\text{Accuracy} = (TP + TN)/N, \qquad \text{Precision} = TP/(TP + FP), \tag{8}$$

$$\text{Recall} = TP/(TP + FN), \qquad \text{Specificity} = TN/(TN + FP), \tag{9}$$

$$F_1 = 2TP/(2TP + FP + FN), \qquad BA = \tfrac{1}{2}(\text{Recall} + \text{Specificity}), \tag{10}$$

$$FPR = FP/(TN + FP), \qquad FNR = FN/(TP + FN). \tag{11}$$

La proporción de predicciones positivas es $(TP+FP)/N$. El error de clasificación es $1-\text{Accuracy}$; no equivale a entropía cruzada ni a número de actualizaciones. Si no existen positivos predichos, precision se registra como cero con indicador de denominador nulo; recall y especificidad no son estimables si falta su clase real, y BA requiere ambas clases. Todas las particiones globales de este estudio contienen ambas clases.

4. Data Warehouse WWI y evidencia de origen

La carta de diseño describe un modelo estrella de ventas con `FactVentas` y las dimensiones Tiempo, Producto, Cliente, Ubicación y Vendedor [5]. El grano propuesto y comprobado en la extracción es una línea de factura, identificada por `InvoiceLineID`. `InvoiceID` se repite legítimamente cuando una factura contiene varias líneas; contar facturas exige identificar valores distintos, no sumar filas.

Los dos CSV auditados contienen 228 265 filas y 30 columnas. La extracción cubre del 1 de enero de 2013 al 31 de mayo de 2016, con 41 meses. Se encontraron 70 510 facturas y 227 nombres de producto, sin duplicados completos ni duplicados de la clave de línea. Las medidas monetarias satisfacen las relaciones aritméticas comprobadas. La limpieza conserva las claves y medidas; además del tratamiento de nulos, se observan 268 recortes de espacio en un nombre de cliente. La columna afectada es `NombreCliente`, según la comparación estructurada, aunque un resumen previo lo atribuye a vendedor. No se atribuye ese cambio a una operación específica sin el historial de OpenRefine.

La auditoría detectó ausencias en Marca (209 328), Tamaño (67 315) y GrupoCompra (84 297), que no justifican borrar las observaciones. Se conservaron extremos y beneficios negativos. Estos últimos no son errores demostrados: faltan costos históricos para explicar su origen. La extracción no incluye StockItemID, CustomerID ni CityID, por lo que la identidad por nombre es provisional. Inventario histórico, compras, cobros y demanda no atendida no están disponibles en los CSV usados.

Los documentos previos describen procesos analíticos y un dashboard [6, 7]; no verifican por sí solos todos los cierres, claves, medidas de otras áreas o disponibilidad al instante de predicción. Las cifras anteriores se contrastaron con `resultados/auditoria/perfilado_datos.json`, su comparación entre fuentes y los manifiestos posteriores. La trazabilidad por archivo se conserva en los anexos digitales del informe.

5. Metodología y preparación causal de datos

5.1. Grano producto-mes, etiqueta e instante de predicción

Sea $Q_{p,t}$ la suma de unidades facturadas observadas del producto provisional p en el mes t. La referencia histórica y la etiqueta son

$$R_{p,t} = \text{mediana}(Q_{p,t-1}, Q_{p,t-2}, Q_{p,t-3}), \qquad y_{p,t} = \mathbf{1}[Q_{p,t} > R_{p,t}]. \tag{12}$$

Clase 1 significa ventas unitarias superiores a la mediana reciente del mismo producto; el empate pertenece a clase 0. El horizonte es un mes y el instante de predicción es el cierre de $t-1$. La cantidad objetivo y su etiqueta se mantienen separadas de las entradas. El calendario del mes futuro sí es conocido al corte.

Un producto es elegible cuando se reconoce antes del corte y dispone de los tres meses históricos esenciales, con cobertura válida conforme al contrato. Se construyó el calendario desde su primera aparición; no se asignaron ceros antes de esa fecha. El calendario contiene 9 019 filas y 8 792 corresponden a productos ya reconocidos antes del corte. Se evitaron 288 pares previos a la primera aparición de ocho productos recientes. Las observaciones no elegibles se conservan con su estado, sin fabricar una etiqueta cero.

5.2. Completitud y disponibilidad asumidas

La ejecución aprobada utiliza modo académico: se asume completitud y disponibilidad al cierre de enero de 2013 a mayo de 2016. No es una certificación del sistema fuente. En un modo de

cobertura desconocida, una ausencia no puede convertirse automáticamente en cero ventas. Los cierres e ingestiones reales deben demostrarse para una aplicación operacional. La disponibilidad secuencial permite usar un mes ya cerrado de test como historia de uno posterior, sin reajustar transformaciones o modelos.

5.3. Características permitidas y exclusiones

Se definieron 23 entradas numéricas base. Incluyen tres retardos de unidades, media, mediana y dispersión histórica; cambio absoluto, variación relativa y tendencia; facturas, ingresos y clientes históricos; precio ponderado y unidades por factura; antigüedad observada y calendario conocido. Las 20 columnas efectivas y sus fórmulas completas constan en el anexo A.

Se excluyeron variables del horizonte, medidas monetarias y clientes futuros, identificadores directos, inventario inexistente, atributos estáticos sin historia verificable y categorías no autorizadas. Tampoco se añadieron características después de observar test. Se preservaron redundancias algebraicas: eliminarlas por rendimiento habría cambiado el contrato.

Las razones no esenciales pueden ser nulas si su denominador es cero. Se imputaron con medianas de entrenamiento; la historia esencial ausente bloquea elegibilidad. Tras imputar, se eliminaron únicamente tres columnas constantes en entrenamiento: `base_variacion_cero`, `mes_anterior_sin_ventas` y `facturas_lag_1_cero`. No se suprimieron columnas por correlación con la respuesta o por inspección del rendimiento final.

La estandarización aplica $x_j = (\widetilde{x}_j - \mu_j)/s_j$, donde $\widetilde{x}_j$ es la entrada imputada y μ_j, s_j provienen solo de entrenamiento, con desviación poblacional ($ddof = 0$). Las mismas medianas, medias, desviaciones y orden de columnas se reutilizan en validación y test. Las matrices son float64 y las etiquetas int8 canónicas 0/1. No hay codificación categórica en el contrato aprobado.

5.4. Particiones temporales y control de fuga

Tabla 1: Particiones por mes objetivo y soporte de clases; historia disponible desde enero de 2013.

Conjunto	Mes inicial–final	N	Clase 0	Clase 1	Clase 1 (%)
Entrenamiento	2013-04–2014-12	4599	2217	2382	51.794
Validación	2015-01–2015-12	2628	1299	1329	50.571
Prueba	2016-01–2016-05	1111	558	553	49.775

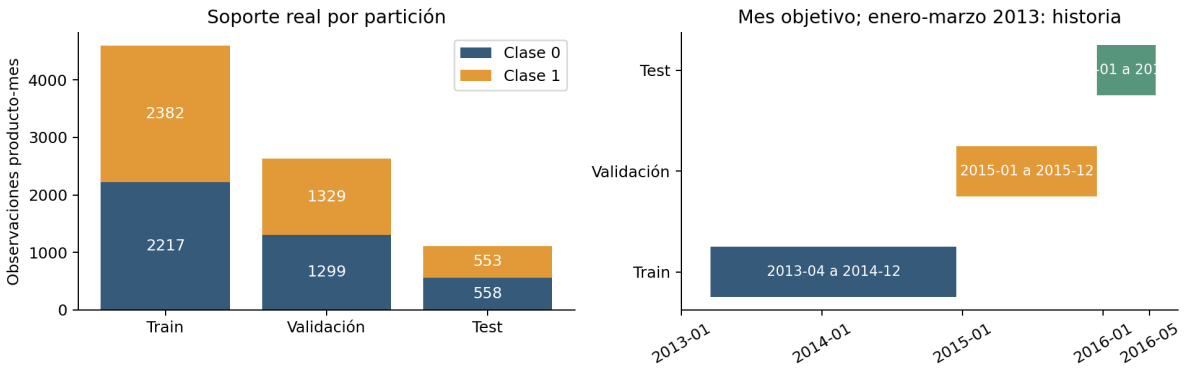


Figura 1: Distribución real de clases y períodos por mes objetivo. Enero–marzo de 2013 aportan la historia inicial, no observaciones objetivo de entrenamiento.

Las observaciones se ordenan por mes objetivo y nombre provisional de producto. Los índices e

identificadores producto-mes se conservaron alineados entre modelos. La validación seleccionó configuraciones y checkpoints; test se utilizó después de congelar las decisiones, sin volver a entrenar con train más validación. No se usó partición aleatoria de líneas de factura.

El protocolo previno fuga mediante desplazamiento por calendario, ajuste exclusivo con train, separación de respuestas y protección de hashes. Las pruebas existentes incluyen perturbaciones del horizonte y de datos futuros, fronteras de partición y persistencia del preprocesador. Ambos modelos reciben exactamente las mismas matrices, filas y etiquetas. Las métricas de validación son de selección, por lo que pueden ser optimistas; no se presentan como una reserva independiente del diseño.

5.5. Baselines comunes

El mayoritario predice la clase más frecuente de train, aquí 1, con empate resuelto hacia 0. El histórico predice $\mathbf{1}[Q_{p,t-1} > R_{p,t}]$, usando cantidades crudas comparables, no columnas estandarizadas en escalas distintas. Ambos se evaluaron sobre los mismos casos que los clasificadores; no se eligió su regla según test.

6. Implementación del perceptrón simple

La implementación propia en `src/models/perceptron.py` valida dimensión, finitud, etiquetas y orden de nombres. El número de entradas es dinámico; en esta aplicación se deduce de las 20 columnas aprobadas. Usa NumPy, la función escalón de la ecuación 1 y la actualización online de la ecuación 2, sin optimizadores externos ni pérdida probabilística.

El presupuesto previo compara orden fijo y orden barajado con tasa 0,01, semilla 42, pesos y sesgo iniciales cero y máximo de 100 épocas por recorrido. La validación selecciona máxima BA, después mayor F1 positivo, menor época y orden del plan. El estado elegido se restaura mediante copia de pesos; no se exporta automáticamente la última época ni se realiza refit.

El orden fijo seleccionó la época 80 y obtuvo BA de validación 61,508 %; el barajado seleccionó la época 70 y alcanzó 61,632 %, por lo que se conservó este último. Con inicialización cero y tasa constante positiva, cambiar solo la tasa escala la trayectoria en aritmética exacta; las operaciones flotantes pueden romper esa equivalencia. Por ello, el presupuesto aprobado no amplió tasas retrospectivamente.

El sesgo seleccionado es $b = 0{,}010000000000000004$. La tabla 2 conserva los 20 pesos extraídos del JSON congelado. Operan sobre entradas transformadas: sus magnitudes no expresan efectos en unidades crudas ni importancia causal independiente. Las métricas train/validación/test y matrices se presentan en la sección 10. El número de actualizaciones coincide exactamente con

Tabla 2: Pesos del modelo congelado perceptrón. Valores float64 conservados con representación decimal de ida y vuelta.

Índice	Característica estandarizada	Peso
1	`unidades_lag_1`	0.08604738881119216
2	`unidades_lag_2`	0.07955933295077251
3	`unidades_lag_3`	0.08643380694807037
4	`unidades_media_3`	0.08682046217511337
5	`unidades_mediana_3`	-0.3720436256352147
6	`unidades_std_3`	-0.0011423824327889114
7	`cambio_unidades_1`	0.016234371544841163
8	`variacion_relativa_1`	0.015503476495048884
9	`tendencia_unidades_3`	0.002266138406936554 8
10	`facturas_lag_1`	-0.01341653202315568
11	`facturas_media_3`	-0.07449527454509768
12	`ingresos_lag_1`	-0.08671342154352552
13	`ingresos_media_3`	0.09642870252787368
14	`precio_unitario_ponderado_lag_1`	0.14385982435183342
15	`clientes_distintos_lag_1`	-0.04867982347072822
16	`unidades_por_factura_lag_1`	0.0246007086039395
17	`antiguedad_observada_meses`	0.0478919237829946
18	`mes_objetivo_sin`	0.05422922302085315
19	`mes_objetivo_cos`	0.030914856096277414
20	`dias_mes_objetivo`	0.034500061409917425

los errores online en cada época. Una segunda figura que dibujara solo actualizaciones duplicaría la misma serie; la identidad se verificó y ambos conteos se presentan en la tabla 6. La figura 10 aporta en cambio el conteo de errores al cierre, que sí es información diferente.

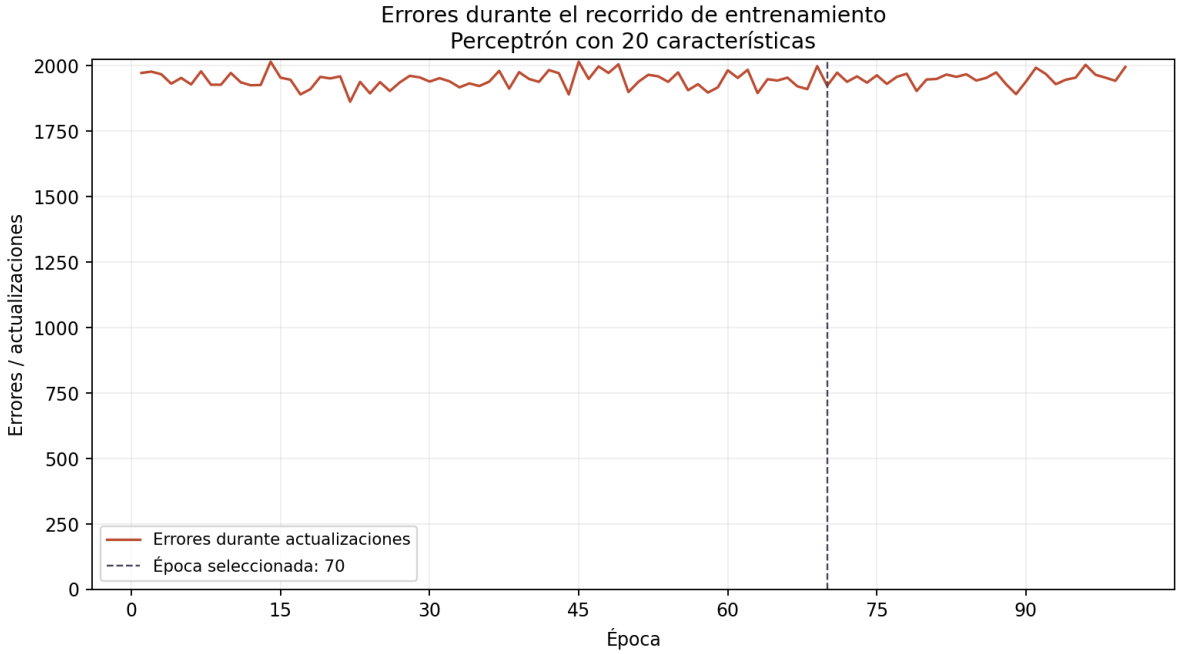


Figura 2: Errores del recorrido de entrenamiento del perceptrón. El análisis distingue conteo online de error al cierre; no es entropía cruzada. El checkpoint seleccionado es la época 70.

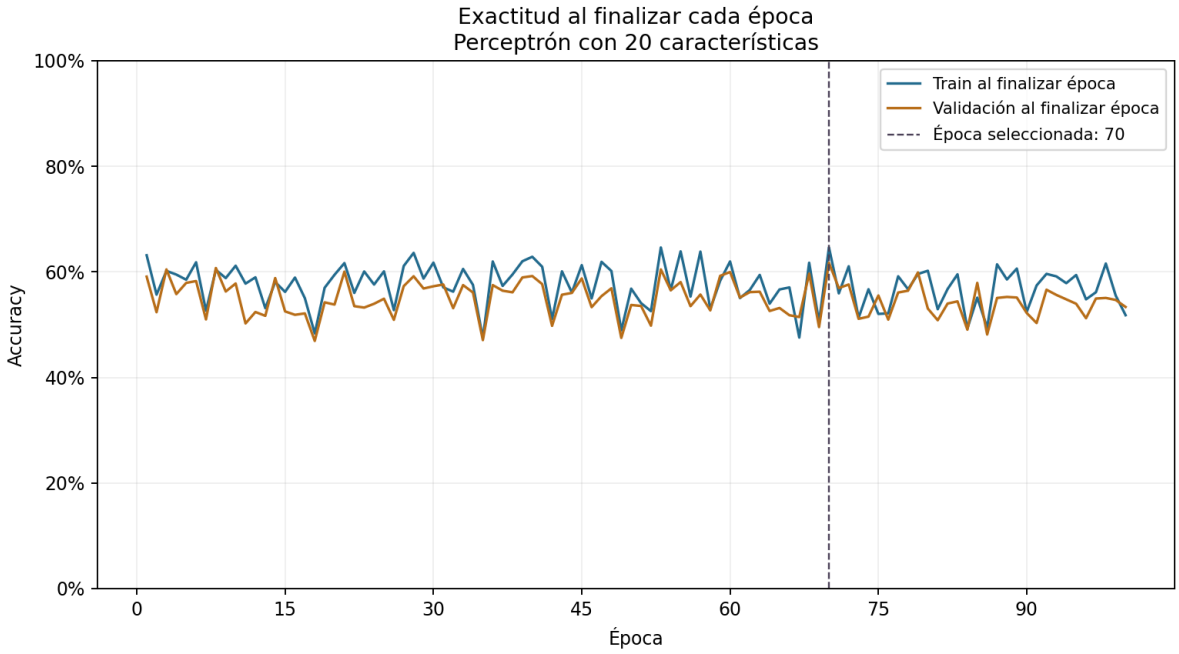


Figura 3: Accuracy de entrenamiento y validación por época del recorrido barajado. Las oscilaciones no se ocultan mediante suavizado.

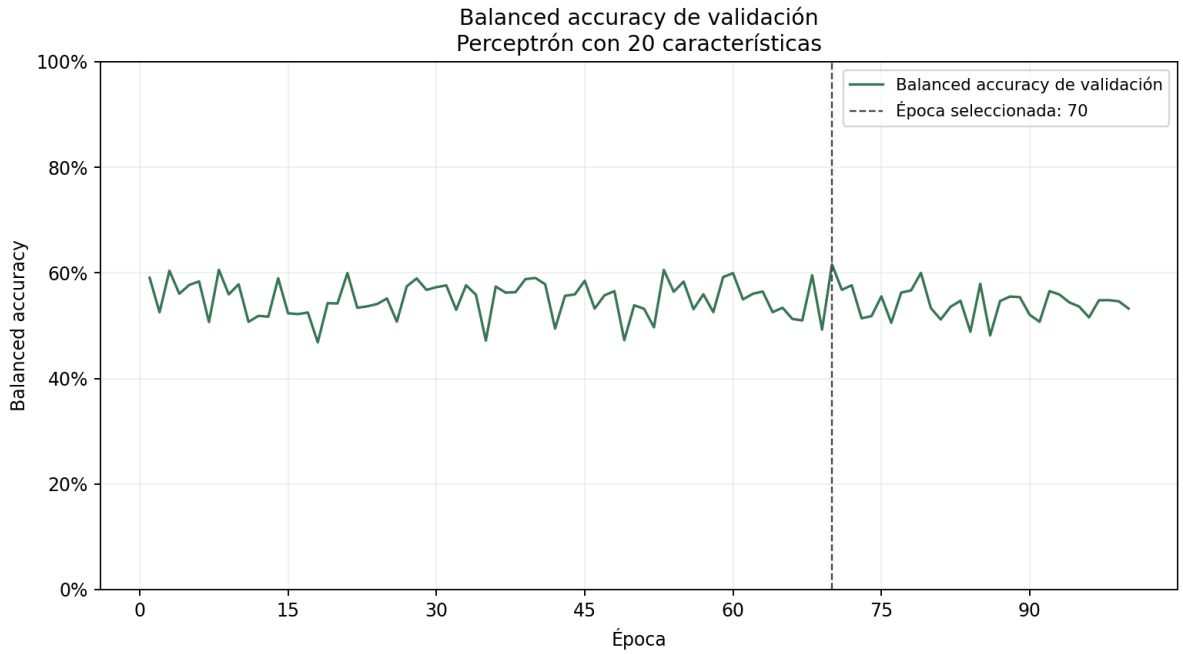


Figura 4: BA de validación por época del perceptrón; la selección responde a la métrica observada en validación, no a cero errores de entrenamiento.

7. Implementación de la regresión logística binaria

El módulo `src/models/logistic_regression.py` implementa sigmoidea estable por ramas, entropía cruzada con `np.logaddexp`, gradientes analíticos y descenso de gradiente por lote completo. La operación matricial $X^\top((p-y)/m)$ evita una suma grande antes de dividir. Se comprueban valores finitos y no se emplean scikit-learn, autodiferenciación ni regularización.

Los gradientes de pesos y sesgo se contrastaron previamente con diferencias centrales en casos moderados y logits extremos, con parámetros no nulos y etiquetas mixtas. La tabla 3 procede del registro original de esas comprobaciones; no se reejecutó el entrenamiento para construirla. La

Tabla 3: Verificación original por diferencias finitas centrales. Todos los casos cumplen tolerancias.

Caso	h	atol	rtol	Error abs. máx.	Error rel. máx.
moderado	1e-06	1e-08	1e-05	6.3527e-11	4.1054e-09
logits_extremos	1e-05	2e-06	1e-05	9.5497e-09	2.0213e-08

prueba utiliza tolerancias absolutas y relativas: cerca de derivadas cero, un error relativo aislado puede ser engañoso. Se verificaron también dimensiones alternativas y estabilidad en las pruebas de implementación. Son comprobaciones del cálculo, no garantías de utilidad predictiva.

Tabla 4: Presupuesto logístico previo: 200 épocas por tasa; checkpoint elegido por BA de validación a umbral 0,5.

Tasa	k elegido	BA val. (%)	Pérdida final train	Gradiente final
0.01	195	58.577	0.648476730	0.094666887
0.05	170	60.605	0.629514103	0.023199269
0.10	200	61.199	0.626953986	0.011097460

Se evaluaron tres tasas, 0,01, 0,05 y 0,1, con 200 épocas cada una, inicialización cero y semilla 42. Al ser lote completo con inicio cero, la semilla no altera la trayectoria de esta ejecución. La tolerancia de parada estuvo desactivada. Se eligieron tasa y checkpoint por BA de validación a umbral 0,5, con desempates por F1, menor época y orden del plan. Después se inspeccionó sobre un único checkpoint la cuadrícula de 19 umbrales entre 0,05 y 0,95; permaneció 0,5. No se buscó el producto cartesiano épocas por umbrales ni se usó test para elegirlos.

El modelo conservado corresponde a tasa 0,1, época 200 y sesgo $b = 0{,}08539078966952132$. La tabla 5 reproduce los pesos con representación decimal suficiente para recuperar el mismo float64. El historial de clasificación usa umbral 0,5, que coincide aquí con el umbral final. La serialización JSON almacena dimensión, nombres, parámetros y checkpoint sin pickle. Compartir fronteras lineales en 20 dimensiones no implica obtener los mismos parámetros: objetivo, recorrido, frecuencia de actualización y selección difieren. El perceptrón corrige errores discretos online, mientras logística optimiza una función suave por lote. Las diferencias finales no se atribuyen a una causa comercial sin evidencia.

Tabla 5: Pesos del modelo congelado logístico. Valores float64 conservados con representación decimal de ida y vuelta.

Índice	Característica estandarizada	Peso
1	`unidades_lag_1`	0.007753842937108124
2	`unidades_lag_2`	0.021919159372678004
3	`unidades_lag_3`	-0.02887438357917642
4	`unidades_media_3`	0.0003849533526338643
5	`unidades_mediana_3`	-0.1550018310751814
6	`unidades_std_3`	0.1603485307302967
7	`cambio_unidades_1`	-0.03239089609332676
8	`variacion_relativa_1`	0.13404048909634628
9	`tendencia_unidades_3`	0.08312368854459541
10	`facturas_lag_1`	-0.11308763440928998
11	`facturas_media_3`	-0.520097786700729
12	`ingresos_lag_1`	-0.037081330837846524
13	`ingresos_media_3`	0.007335190966533872
14	`precio_unitario_ponderado_lag_1`	0.0004866891244691942
15	`clientes_distintos_lag_1`	-0.11718785125889304
16	`unidades_por_factura_lag_1`	0.028211039550568473
17	`antiguedad_observada_meses`	0.16703575165447174
18	`mes_objetivo_sin`	0.24188638442783236
19	`mes_objetivo_cos`	-0.018110885050252778
20	`dias_mes_objetivo`	0.2550458337404401

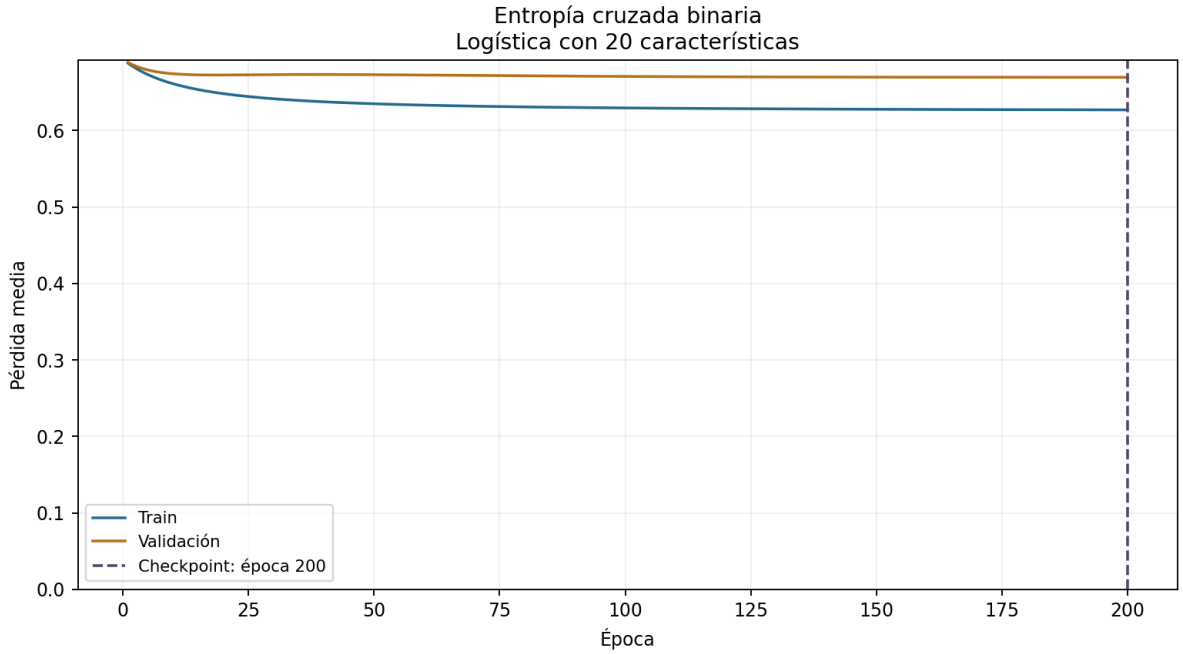


Figura 5: Entropía cruzada de entrenamiento y validación en la ejecución logística seleccionada. La pérdida inicial de ambas particiones es $\log 2$, con parámetros cero.

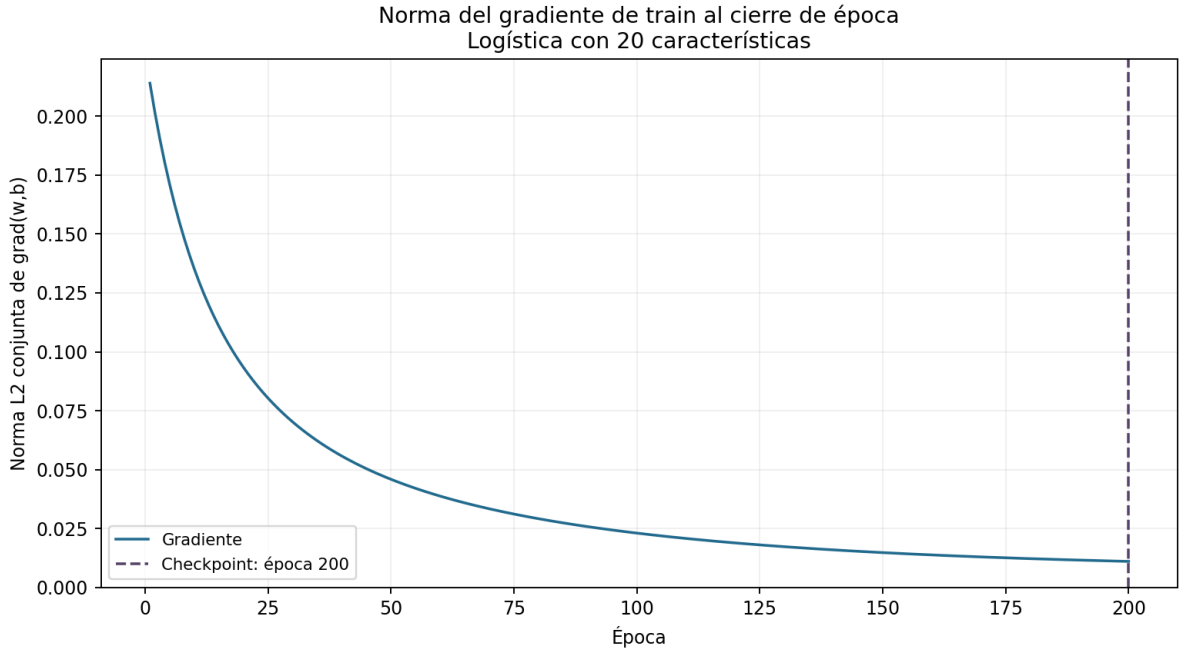


Figura 6: Norma del gradiente logístico registrada después de cada actualización. Incluye derivadas de pesos y sesgo y no se interpreta como error de clasificación.

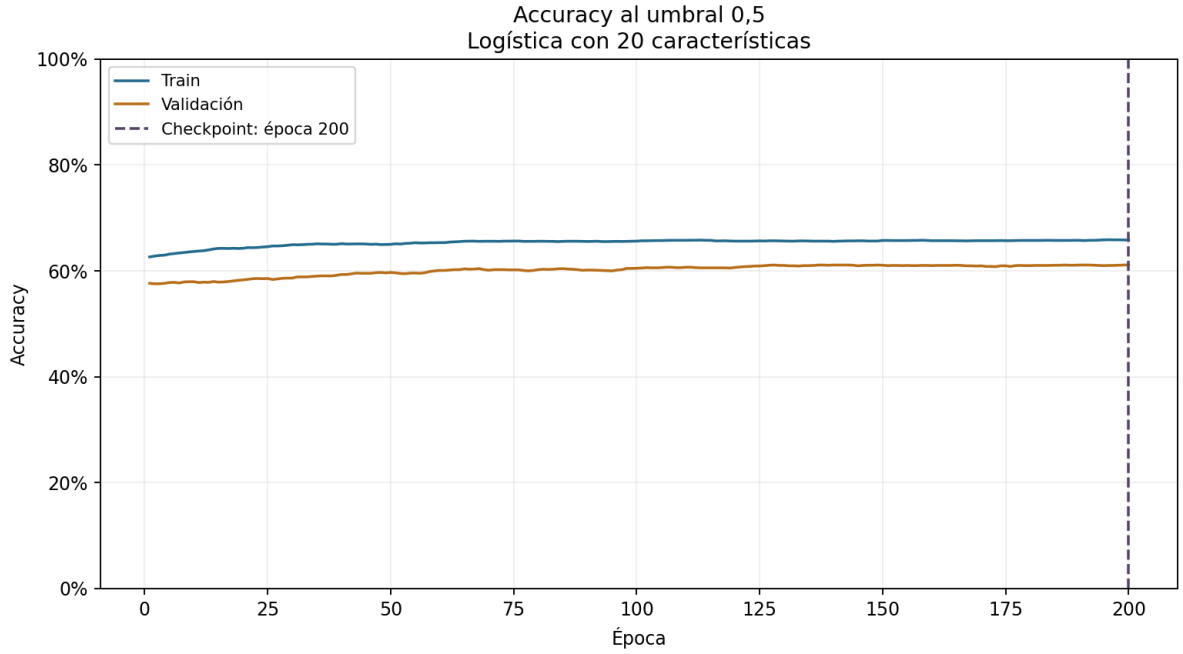


Figura 7: Accuracy train y validación por época a umbral 0,5. La disminución de pérdida no obliga a una mejora monótona de la clasificación discreta.

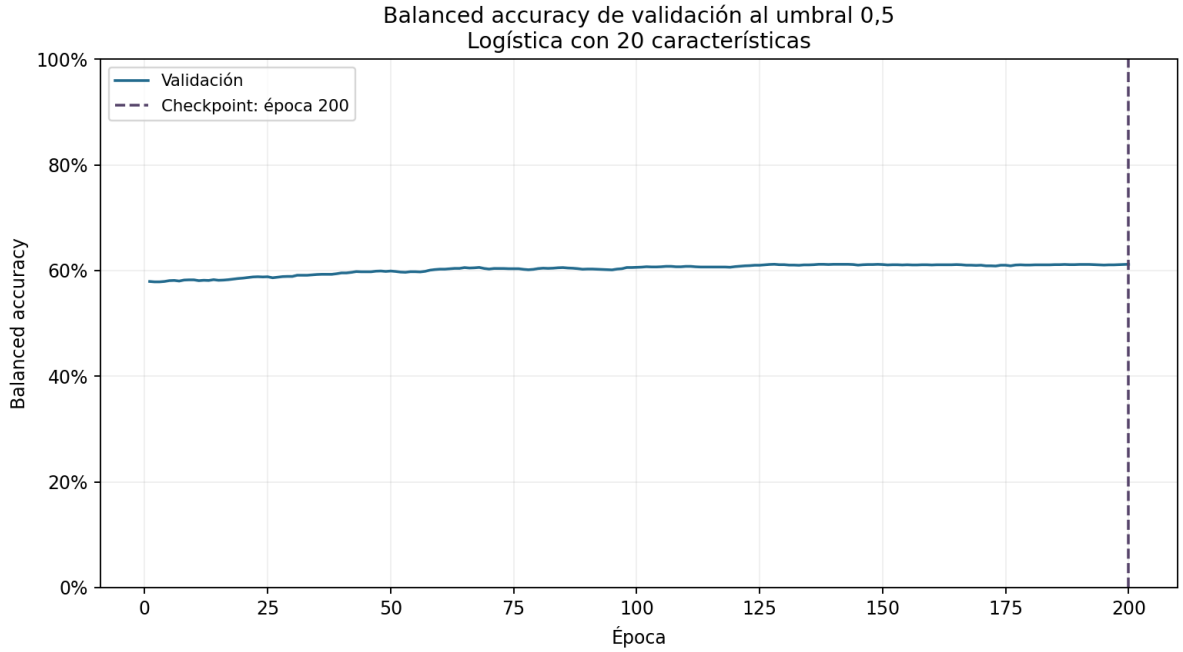


Figura 8: BA de validación por época en la ejecución logística seleccionada. El presupuesto y la selección quedaron fijados antes de la evaluación final.

8. Verificación de convergencia y comportamiento del error

8.1. Evidencia y definición de los diagnósticos

Se analizan exclusivamente los historiales aprobados del recorrido barajado del perceptrón y de la ejecución logística de tasa 0,1. Los CSV por época se conservan íntegros, junto con los cálculos documentales, en `informe/evidencias/`. No se reconstruyen curvas mediante entrenamiento, no se inventan métricas de test por época y no se aplica un criterio de parada nuevo.

Para la logística, con L_0 guardada en el registro del experimento, se calcula para $k = 1, \ldots, 200$:

$$\Delta L_k = L_{k-1} - L_k, \qquad r_k = \frac{|L_k - L_{k-1}|}{\max(1, |L_{k-1}|)}. \tag{13}$$

Como todas las pérdidas previas son menores que 1, $r_k = |\Delta L_k|$ numéricamente en este recorrido. El denominador evita exagerar un cambio relativo cuando la pérdida es pequeña. Estos diagnósticos describen la ejecución; no fueron condiciones efectivas de parada.

8.2. Perceptrón: fluctuaciones sin cese de actualizaciones

Tabla 6: Recorrido seleccionado del perceptrón: errores online y al cierre son magnitudes diferentes.

Época	Online	Actualiz.	Error cierre	Acc. train	Acc. val	BA val	Norma w
1	1973	1973	1695	63.144	59.094	59.067	0.266956
70	1924	1924	1627	64.623	61.720	61.632	0.470391
100	1996	1996	2217	51.794	53.349	53.238	0.439505

Los errores online pasan de 1 973 a 1 996, con mínimo 1 863 y máximo 2 016. En 49 transiciones aumenta su conteo. Ninguna de las 100 épocas presenta cero actualizaciones; la última conserva 1 996. La media de las primeras diez épocas es 1 954,2 errores y la de las últimas diez 1 965,8. No aparece una tendencia de reducción a cero ni un cese de aprendizaje en el presupuesto observado. La norma de pesos es 0,470390802 en el checkpoint y 0,439505108 al finalizar; cambiar de norma no prueba estabilización de la dirección o de las predicciones.

El checkpoint 70 tiene 1 924 errores online, pero 1 627 errores al cierre, porque se evalúan estados diferentes. Su accuracy train es 64,623 % y validación 61,720 %, frente a 51,794 % y 53,349 % en la época 100. La BA de validación cae de 61,632 % en el estado exportado a 53,238 % en el último. Por ello, no deben utilizarse métricas de la última época como si fueran las del modelo final conservado.

El resultado es un recorrido oscilante, sin convergencia a cero errores demostrada. La garantía teórica requiere separabilidad con margen; ni esta se ha demostrado ni su ausencia se deduce únicamente de 100 épocas. Mantener actualizaciones es evidencia de no estabilización de este recorrido, no prueba de un fallo de implementación.

8.3. Logística: descenso estable, límite de épocas

La pérdida inicial train es 0,6931471805599452 y la final es 0,6269539858615067: disminuye 0,06619319469843843, equivalente al 9,549659 % de la inicial. Las 200 diferencias ΔL_k son positivas; no hay aumentos estrictos de pérdida train. El descenso medio por época pasa de 0,003200745231 en las primeras diez a 0,000012942798 en las últimas diez. La pendiente se aplana, pero la pérdida sigue disminuyendo.

En la última época, $\Delta L_{200} = r_{200} = 1,239994026 \times 10^{-5}$. La norma del gradiente pasa de 0,2276084513231957 antes del primer paso a 0,01109745983712376 después del último; no es cero.

Tabla 7: Diagnóstico documental por época. ΔL y r se derivan del historial sin modificar el criterio de parada.

Época	L train	L val	ΔL	r	Norma grad.	BA val (%)
1	0.688123412	0.689090657	0.005024	0.005024	0.2139699	57.943
50	0.634948297	0.672987850	0.0002168	0.0002168	0.0459331	59.918
100	0.629497740	0.670700835	5.422e-05	5.422e-05	0.0230980	60.621
150	0.627772423	0.669767545	2.221e-05	2.221e-05	0.0148239	61.147
200	0.626953986	0.669574543	1.24e-05	1.24e-05	0.0110975	61.199

La norma final de pesos es 0,726685646640. La pérdida de validación pasa de 0,6931471805599452 a 0,6695745428232207, una mejora menor que en entrenamiento. Su diferencia final con train es aproximadamente 0,042620557. El menor valor registrado de validación coincide con la época 200, sin que esto pruebe que épocas posteriores serían mejores.

La tolerancia estaba desactivada (`tolerance=null`); el registro indica `converged_by_tolerance=false`. Se detuvo por máximo de 200 épocas. En este caso, checkpoint y último estado coinciden. La reducción de pérdida y gradiente respalda **descenso estable sin convergencia completa demostrada**; no certifica un óptimo numérico ni un criterio retrospectivo de suficiencia. Las redundancias impiden asumir unicidad del vector de pesos.

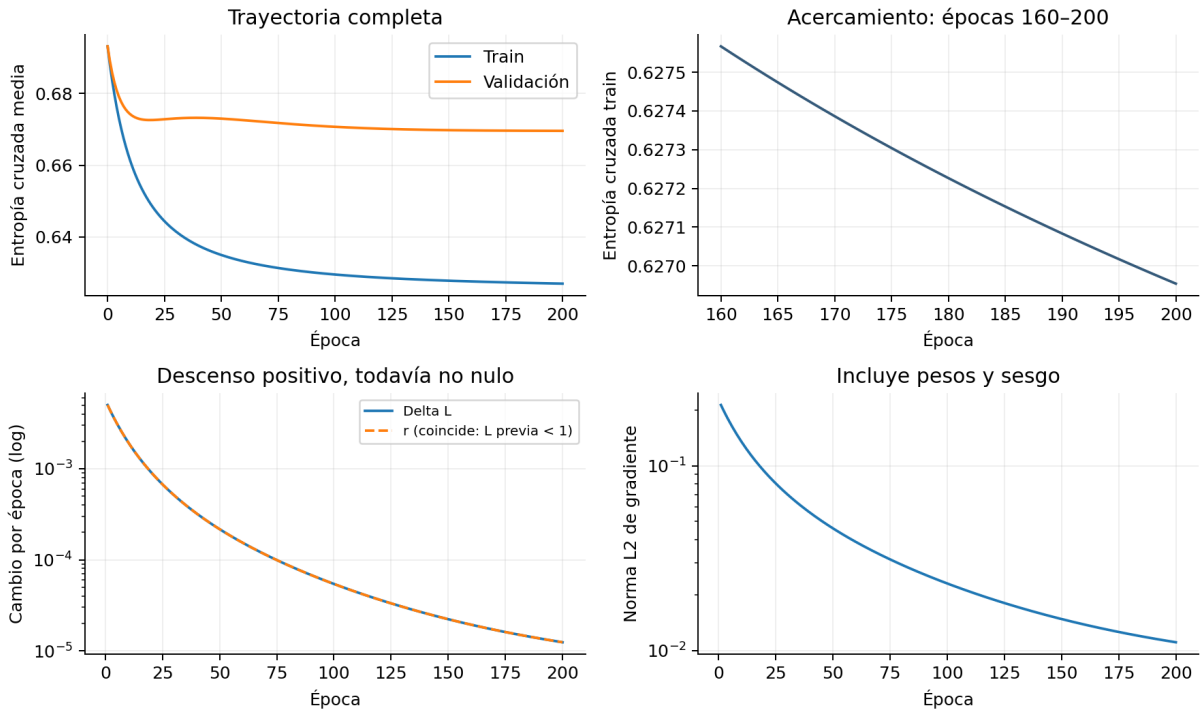


Figura 9: Diagnóstico de la ejecución logística seleccionada: pérdida completa con inicialización real, acercamiento final, cambios por época y norma del gradiente. El eje logarítmico se identifica en los paneles inferiores.

Las curvas permiten distinguir mejora del objetivo continuo y comportamiento de la clasificación. Concluyen sobre las ejecuciones conservadas, sin extender el presupuesto ni modificar tasas o modelos después de observar test.

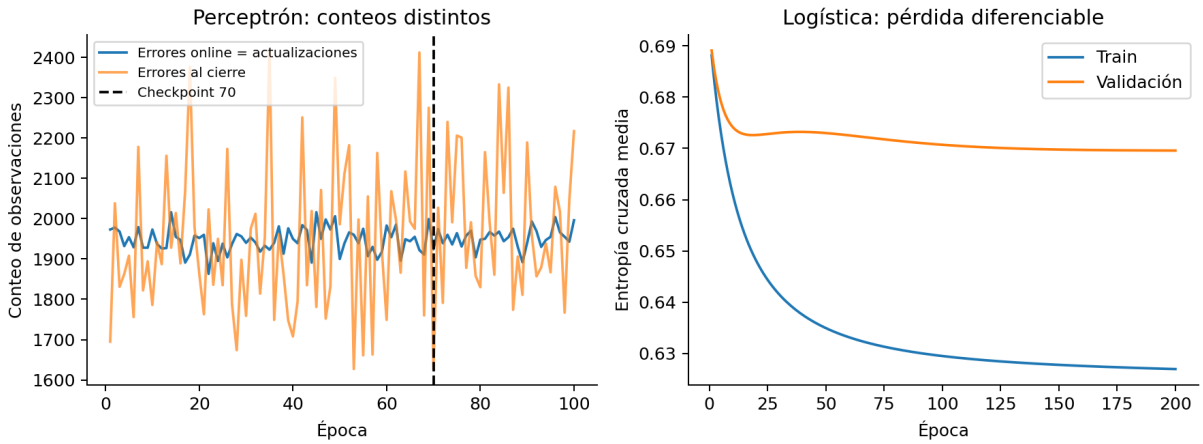


Figura 10: Comparación con ejes separados: errores online y al cierre del perceptrón (conteos) frente a entropía cruzada logística (pérdida media). No son magnitudes equivalentes.

9. Reducción dimensional para visualización

La transformación PCA aprobada se ajustó con las 4 599 filas de entrenamiento y se aplicó a las 2 628 de validación, usando el mismo centrado. Las etiquetas solo colorean los puntos; no entran en el ajuste SVD. No se ajustó PCA con test ni se utilizaron las coordenadas bidimensionales para entrenar los clasificadores.

PC1 explica 32,987763 % y PC2 16,630823 %; juntas conservan 49,618586 %, por lo que 50,381414 % no se representa en el plano. La varianza total de entrenamiento es 20,0043497173 con $ddof = 1$ y el rango numérico es 17. El rango menor que 20 es compatible con redundancias de las variables históricas; no impide conservar las dos primeras direcciones.

Tabla 8: Cinco mayores coeficientes por magnitud en cada componente. El cuadrado es participación en la norma del vector, no importancia predictiva.

Comp.	Característica	Coeficiente	Cuadrado (%)
PC1	unidades_media_3	0.386556480	14.943
PC1	unidades_mediana_3	0.384643640	14.795
PC1	unidades_lag_1	0.379973488	14.438
PC1	unidades_por_factura_lag_1	0.377059706	14.217
PC1	unidades_lag_2	0.371108446	13.772
PC2	facturas_lag_1	0.494616346	24.465
PC2	clientes_distintos_lag_1	0.492434743	24.249
PC2	variacion_relativa_1	0.367933782	13.538
PC2	cambio_unidades_1	0.345813511	11.959
PC2	tendencia_unidades_3	0.300490423	9.029

PC1 combina principalmente nivel histórico de unidades, con coeficientes positivos grandes en media, mediana, lags y unidades por factura. PC2 combina frecuencia comercial (facturas y clientes distintos) y cambios recientes de unidades. La convención de signo hace positivo el coeficiente de mayor magnitud: invertir un vector no modifica la varianza ni aporta una clase nueva. Los coeficientes negativos menores de PC2 incluyen unidades de los retardos segundo y tercero; su lectura es algebraica, no causal.

Las clases se solapan visualmente. La pérdida de más de la mitad de la varianza limita cualquier inferencia sobre separabilidad en las 20 entradas. PCA no es un clasificador; el solapamiento no demuestra la causa del rendimiento ni invalida una señal fuera del plano. Ninguna línea bidimensional se presenta como frontera exacta de los modelos multidimensionales.

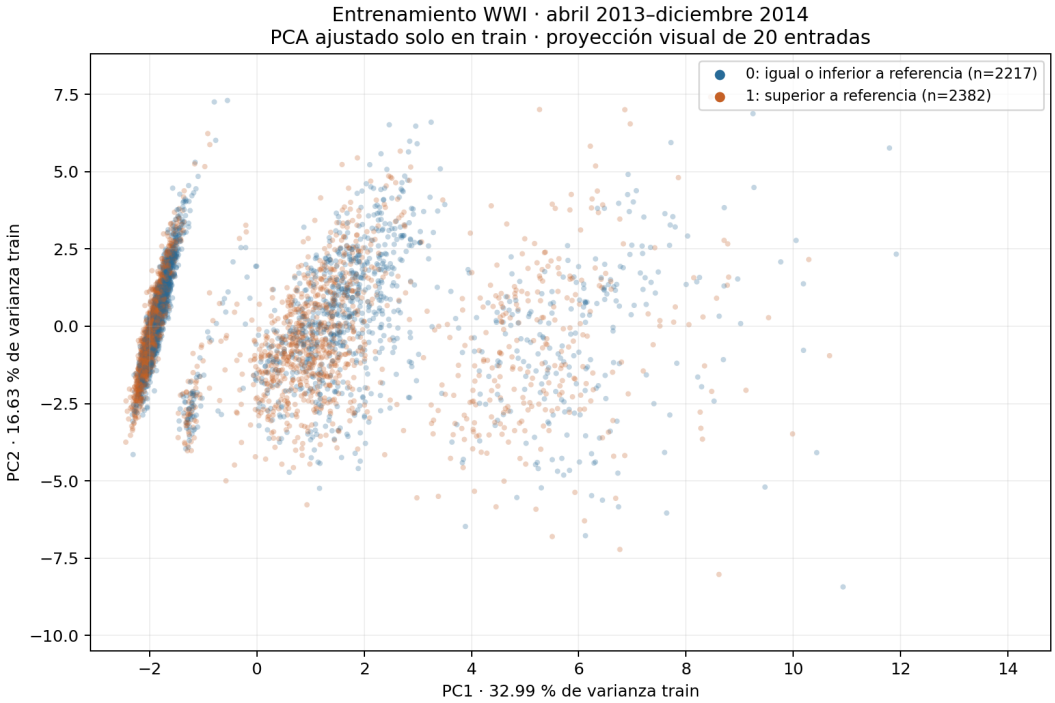


Figura 11: Proyección PCA de entrenamiento, coloreada por etiqueta real. Todos los puntos proceden del artefacto aprobado, sin selección ni desplazamiento artificial.

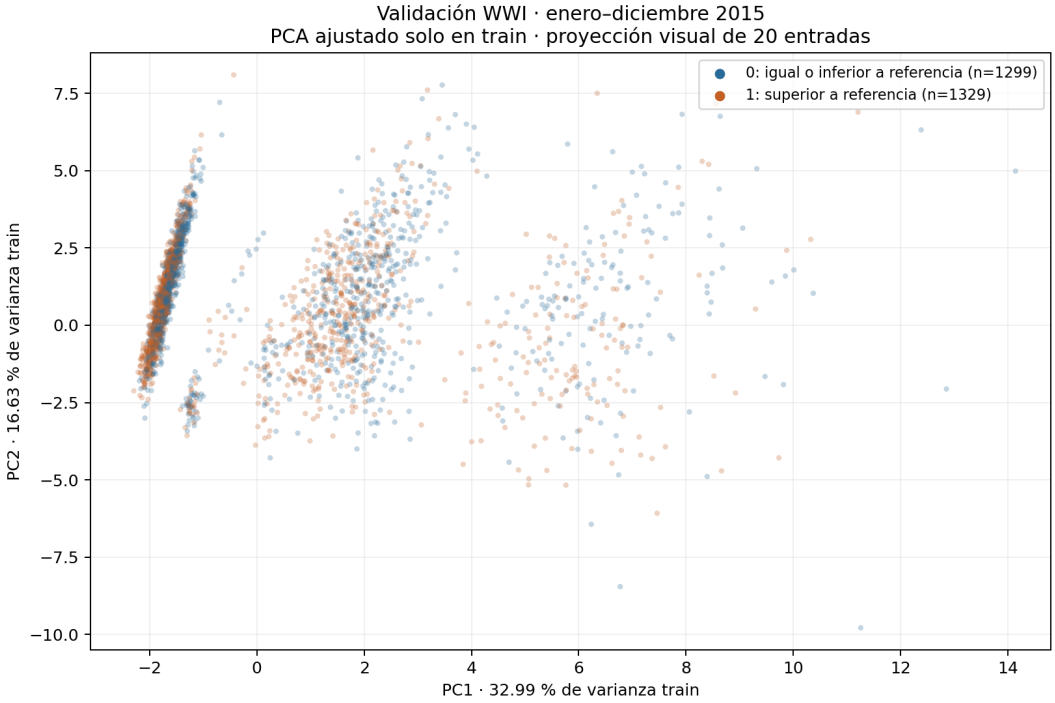


Figura 12: Validación proyectada con media y componentes de entrenamiento. Se conserva la escala de ejes utilizada en la visualización aprobada.

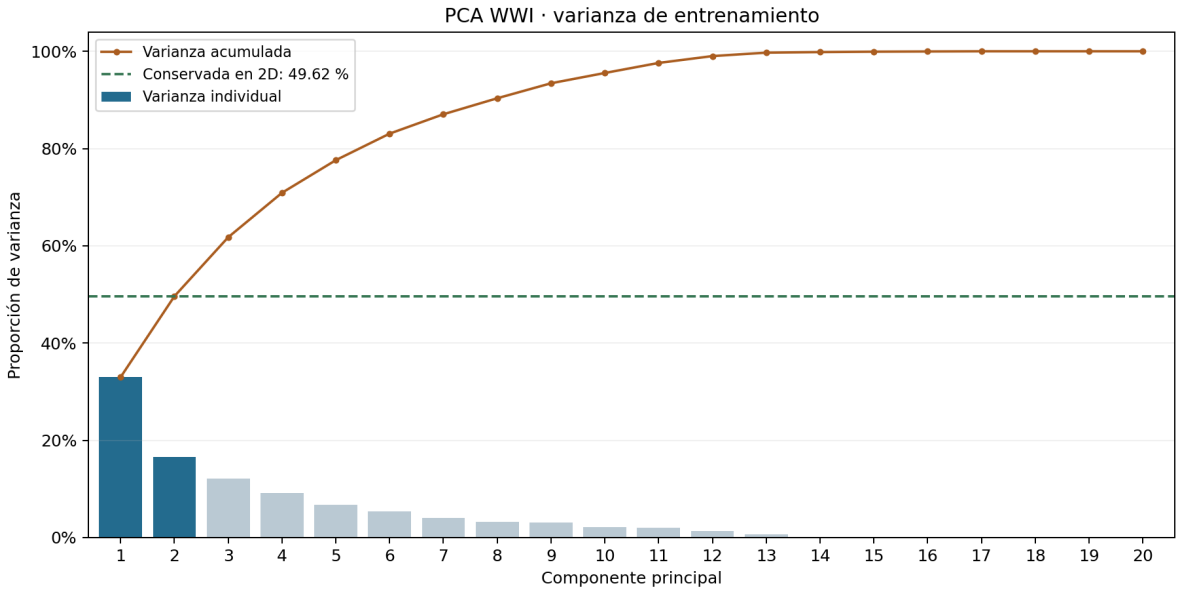


Figura 13: Varianza individual y acumulada de los componentes obtenidos de entrenamiento. El denominador incluye las 20 direcciones.

10. Resultados experimentales

10.1. Comparación común de entrenamiento, validación y prueba

Las métricas de la tabla 9 proceden de los estados exportados, no de una ejecución nueva. La evaluación final contiene exactamente 1 111 observaciones de enero a mayo de 2016: 558 negativas y 553 positivas. La alineación de identificadores, productos, meses y etiquetas fue comprobada contra los metadatos aprobados; las matrices y métricas se reproducen desde las predicciones existentes. La logística tiene la mayor BA global observada: 62,415 %, 8,311 puntos sobre el

Tabla 9: Métricas finales por partición (%). Estados seleccionados en validación; no corresponden a la última época del perceptrón.

Método	Conjunto	Acc.	Prec.	Recall	Espec.	F1	BA
Perceptrón	Train	64.623	66.815	62.972	66.396	64.837	64.684
Perceptrón	Validación	61.720	60.632	69.300	53.965	64.677	61.632
Perceptrón	Test	53.915	52.008	96.022	12.186	67.471	54.104
Logística	Train	65.840	66.544	68.472	63.013	67.494	65.742
Logística	Validación	61.149	62.812	56.810	65.589	59.660	61.199
Logística	Test	62.286	57.666	91.139	33.692	70.638	62.415
Mayoritario	Train	51.794	51.794	100.000	0.000	68.242	50.000
Mayoritario	Validación	50.571	50.571	100.000	0.000	67.172	50.000
Mayoritario	Test	49.775	49.775	100.000	0.000	66.466	50.000
Histórico	Train	49.272	51.540	34.425	65.223	41.279	49.824
Histórico	Validación	49.049	49.453	34.011	64.434	40.303	49.222
Histórico	Test	51.395	51.884	32.369	70.251	39.866	51.310

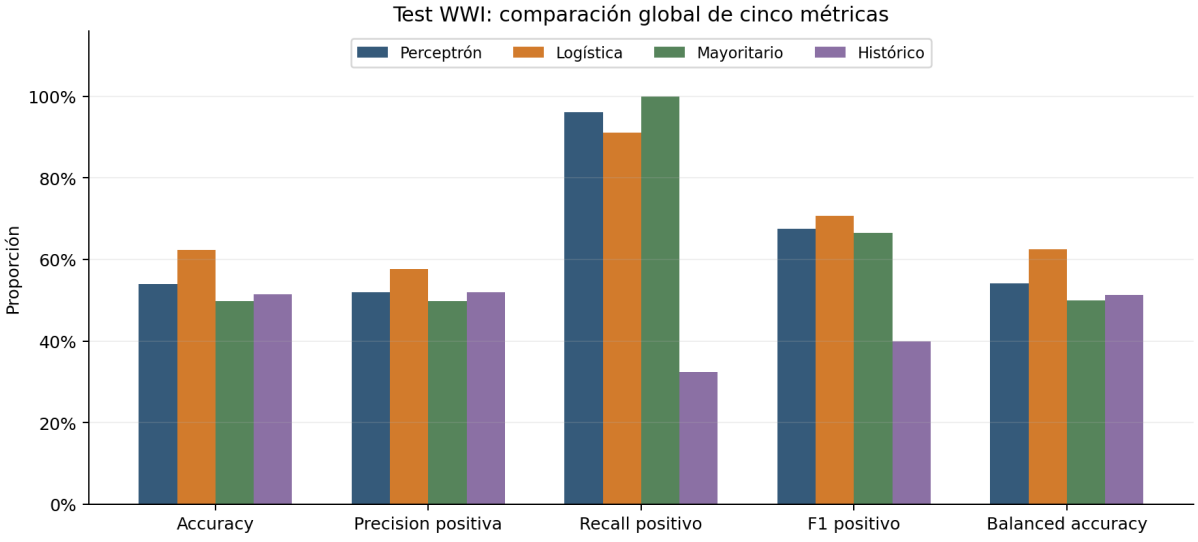


Figura 14: Métricas globales de test sobre los mismos casos. Todas son proporciones o porcentajes según la escala rotulada; ninguna mide beneficio económico.

perceptrón, 12,415 sobre mayoritario y 11,106 sobre histórico. El perceptrón supera esos baselines en 4,104 y 2,794 puntos de BA. Son diferencias descriptivas de la reserva final, sin prueba de superioridad universal ni significación estadística.

El baseline mayoritario alcanza recall 100 % sin reconocer un solo negativo. Esto demuestra por qué accuracy o sensibilidad aisladas no resumen el equilibrio entre clases. El histórico obtiene

especificidad 70,251 %, pero recall 32,369 %, y BA cercana a 50 %.

10.2. Matrices de confusión, sensibilidad y exceso de positivos

Tabla 10: Conteos de test y tasas de error (%). Filas reales y columnas predichas en orden 0,1.

Método	TN	FP	FN	TP	FPR	FNR	Pred. 1
Perceptrón	68	490	22	531	87.814	3.978	1021
Logística	188	370	49	504	66.308	8.861	874
Mayoritario	0	558	0	553	100.000	0.000	1111
Histórico	392	166	374	179	29.749	67.631	345

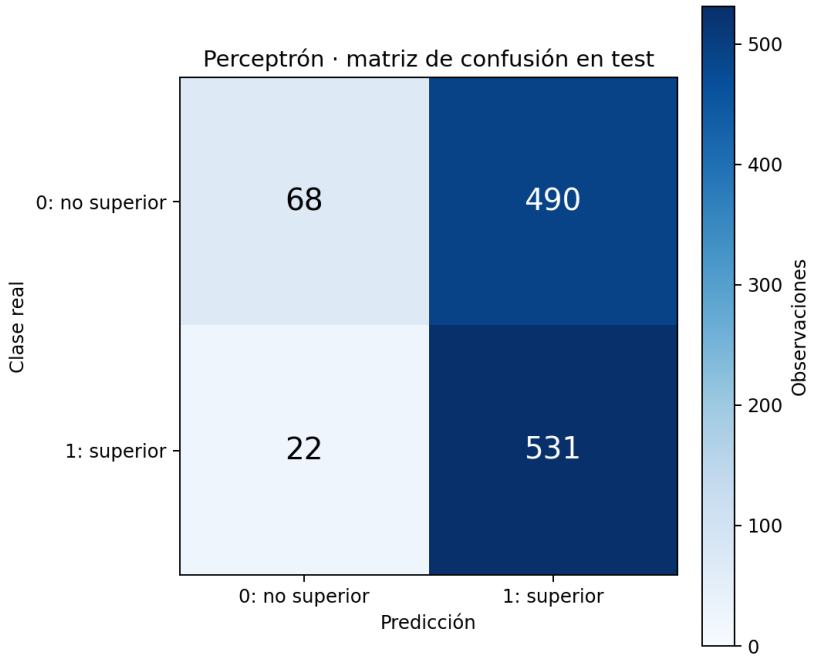


Figura 15: Matriz de confusión de test del perceptrón. Filas: etiqueta real; columnas: clase predicha. La elevada sensibilidad coexiste con 490 falsos positivos.

El perceptrón predice 1 en 1 021 casos (91,899 %) y logística en 874 (78,668 %), frente a 553 positivos reales (49,775 %). Su exceso es de 42,124 y 28,893 puntos porcentuales, respectivamente. Predecir positivo frecuentemente captura muchos positivos reales, pero también eleva FP. La precisión positiva es solo 52,008 % en perceptrón y 57,666 % en logística. F1 positivo no garantiza reconocimiento de la clase negativa.

La logística reconoce 120 negativos adicionales frente al perceptrón, con 27 positivos reconocidos menos. Así disminuye 93 errores totales y mejora BA, calculada con denominadores específicos de cada clase. Esta explicación aritmética no establece una causa empresarial de la diferencia.

10.3. Generalización temporal y error por partición

La BA test menos validación cambia $-7,528$ puntos en perceptrón y $+1,216$ en logística. El aumento global de logística no acredita estabilidad en cada mes. Las proporciones positivas reales son 51,794 % en train, 50,571 % en validación y 49,775 % en test, mientras las predicciones positivas del perceptrón pasan de 48,815 % a 57,801 % y 91,899 %; las de logística, de 53,294 % a 45,738 % y 78,668 %. Hay un cambio descriptivo marcado en las decisiones, con prevalencia

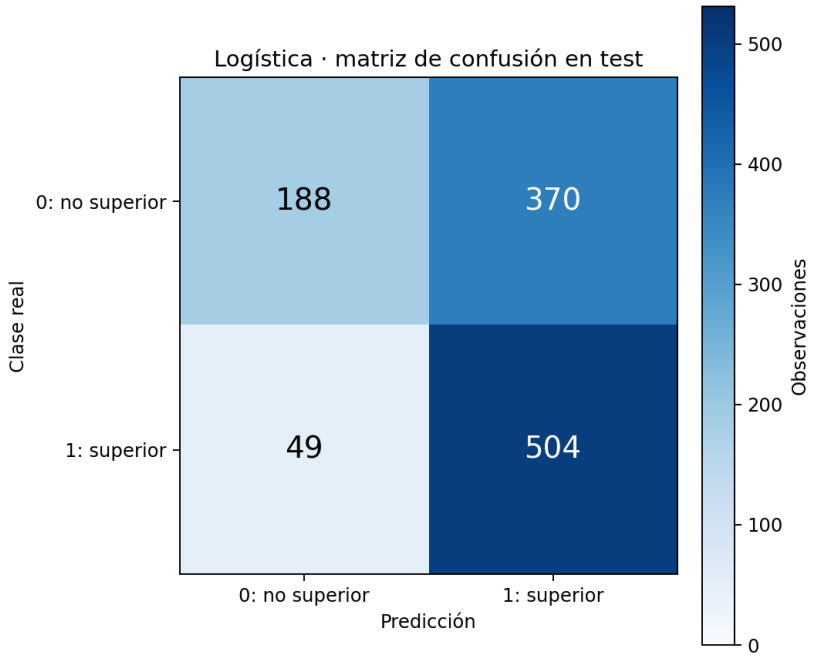


Figura 16: Matriz de confusión de test de logística con umbral congelado 0,5. Reconoce 188 negativos y 504 positivos, con 370 FP y 49 FN.

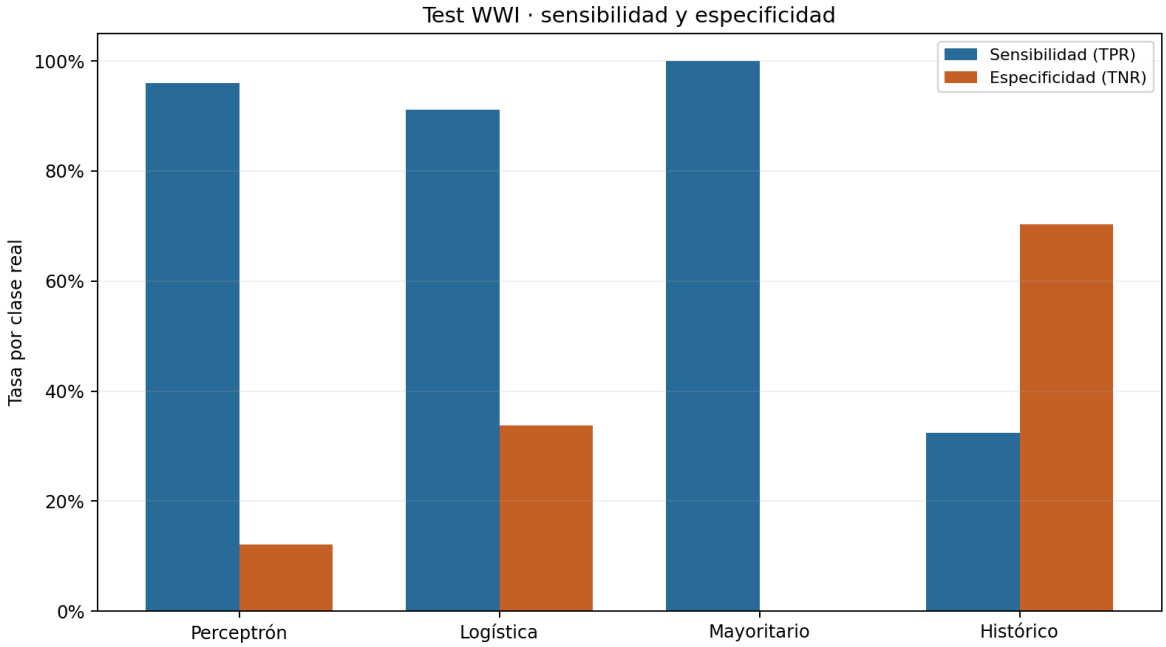


Figura 17: Sensibilidad y especificidad de los cuatro métodos en test. Logística mejora el reconocimiento negativo frente al perceptrón, pero conserva especificidad limitada.

global relativamente próxima. En logística, la especificidad desciende de 64,516 % en febrero a

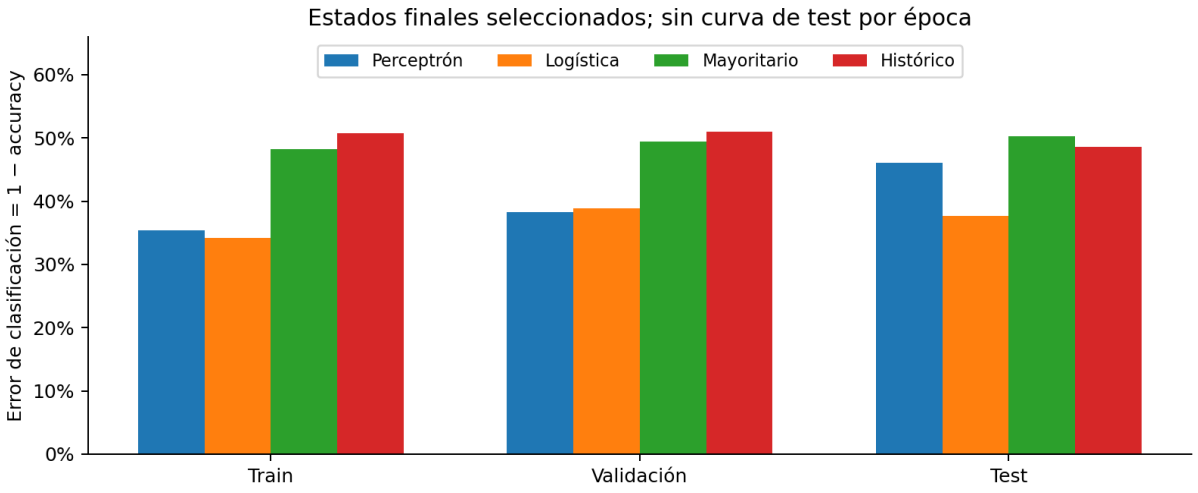


Figura 18: Error de clasificación final, definido como $1-\text{Accuracy}$, por método y partición. No es pérdida logística ni conteo de actualizaciones. No existe una curva de test por época.

Tabla 11: Todos los meses de test. Tasas en %; soporte negativo/positivo.

Mes	0/1	BA perc.	BA log.	Prec. log.	Recall log.	Espec. log.
2016-01	125/94	55.740	63.753	52.632	85.106	42.400
2016-02	155/64	54.667	65.071	43.299	65.625	64.516
2016-03	81/138	51.235	56.065	66.019	98.551	13.580
2016-04	107/120	51.238	56.012	56.281	93.333	18.692
2016-05	90/137	52.620	51.127	60.909	97.810	4.444

4,444 % en mayo, mientras el recall de mayo es 97,810 %. Su BA mensual cae hasta 51,127 %. El perceptrón supera a logística en BA de mayo (52,620 %), a pesar de la ventaja global de esta última. El desempeño cambia con el período y no se resume correctamente con una declaración universal de superioridad.

10.3.1. Por qué BA global y promedio mensual difieren

Si $P_t = TP_t + FN_t$ y $N_t = TN_t + FP_t$, al agrupar los conteos se obtiene

$$TPR_G = \sum_t \frac{P_t}{\sum_s P_s} TPR_t, \qquad TNR_G = \sum_t \frac{N_t}{\sum_s N_s} TNR_t, \tag{14}$$

$$BA_G = \tfrac{1}{2}(TPR_G + TNR_G), \qquad BA_M = \frac{1}{5}\sum_t BA_t. \tag{15}$$

Por tanto,

$$BA_G - BA_M = \frac{1}{2}\sum_t \left[\left(\frac{P_t}{\sum_s P_s} - \frac{1}{5}\right) TPR_t + \left(\frac{N_t}{\sum_s N_s} - \frac{1}{5}\right) TNR_t\right]. \tag{16}$$

Los pesos son distintos para positivos y negativos; no basta ponderar cada BA mensual por el total de filas. En logística, los soportes positivos mensuales son 94, 64, 138, 120 y 137; los negativos son 125, 155, 81, 107 y 90. La agrupación produce recall 0,911392405 y especificidad 0,336917563. De ellos resulta BA 62,415 %, frente a 58,406 % del promedio mensual sin ponderar.

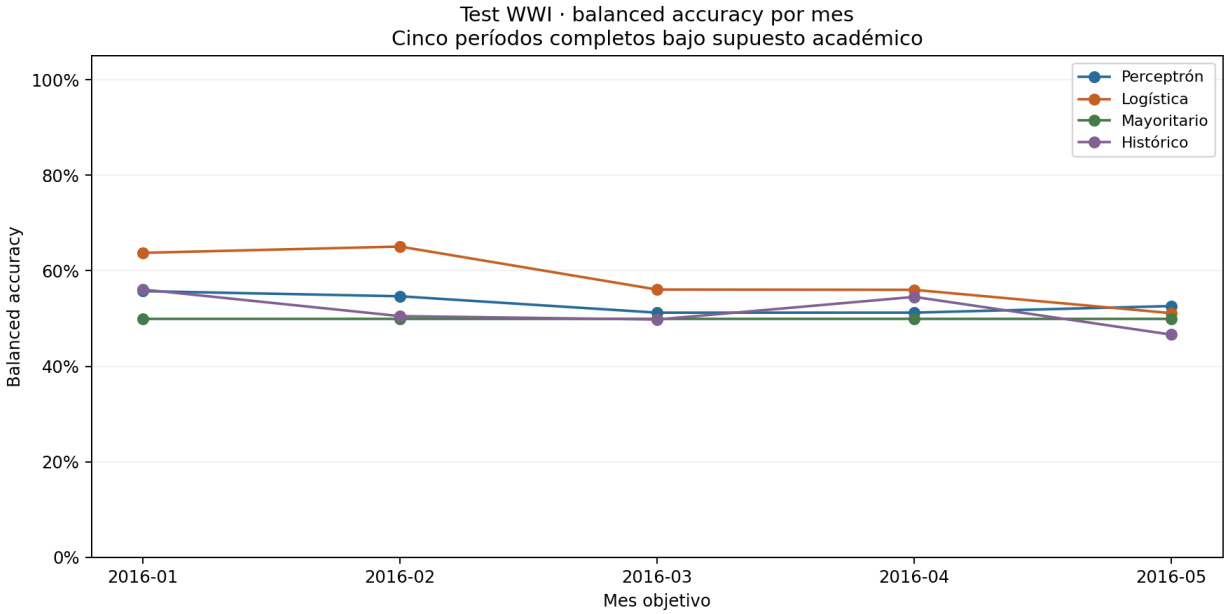


Figura 19: BA de los cuatro métodos en todos los meses de test. No se excluyen meses difíciles ni se selecciona un subperíodo por rendimiento.

La diferencia de 4,009691 puntos se verifica con tolerancia 10^{-12} en puntos porcentuales, utilizando las contribuciones por mes registradas en el análisis temporal. No es una contradicción ni un error de cálculo.

10.4. Productos conocidos y nuevos

Tabla 12: Comparación de cohortes en test, sin excluir los productos nuevos.

Cohorte	Método	N	0/1	TN	FP	FN	TP	BA (%)
conocidos	Perceptrón	1095	552/543	62	490	14	529	54.327
conocidos	Logística	1095	552/543	184	368	46	497	62.431
conocidos	Mayoritario	1095	552/543	0	552	0	543	50.000
conocidos	Histórico	1095	552/543	389	163	367	176	51.442
nuevos	Perceptrón	16	6/10	6	0	8	2	60.000
nuevos	Logística	16	6/10	4	2	3	7	68.333
nuevos	Mayoritario	16	6/10	0	6	0	10	50.000
nuevos	Histórico	16	6/10	3	3	7	3	40.000

Se consideran conocidos los nombres presentes en train, según la regla congelada. En test hay 219 conocidos con 1 095 filas y ocho nuevos con 16 filas de abril y mayo. Se conservan todos en el global. Entre los nuevos, el perceptrón tiene precision 100 % sobre solo dos positivos predichos, pero omite ocho de diez positivos reales. Logística reconoce siete de diez positivos y cuatro de seis negativos. Los conteos son insuficientes para sostener estabilidad de porcentajes o una ventaja extrapolable a nuevos catálogos.

10.5. Concordancias y desacuerdos

Ambos modelos aciertan 554 casos y ambos fallan 374; solo perceptrón acierta 45 y solo logística 138. Las cuatro categorías son excluyentes y suman 1 111. Coinciden en 928 decisiones y discrepan en 183: acuerdo no equivale a acierto. Los 93 aciertos exclusivos netos de logística explican la

diferencia de accuracy. Las agrupaciones por mes y cohorte están disponibles en el archivo de acuerdos; no se usaron para construir un clasificador combinado.

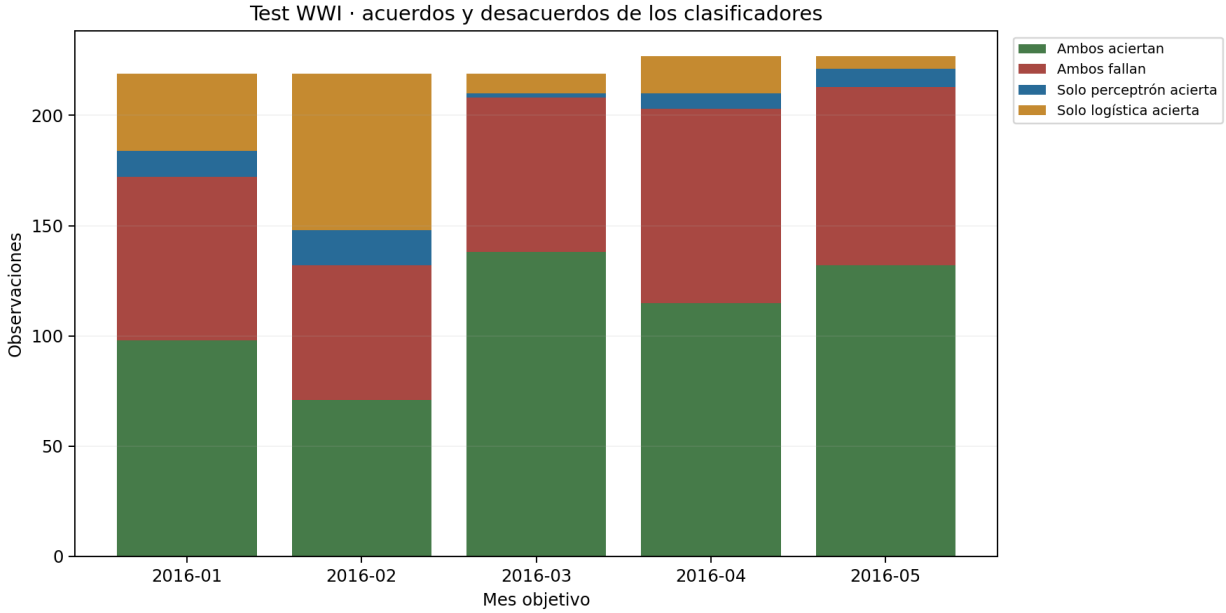


Figura 20: Descomposición de aciertos y errores compartidos y exclusivos por mes. Las categorías conservan los conteos de las mismas predicciones alineadas; los detalles por cohorte están en el archivo estructurado.

11. Comparación estadística y cambios de distribución

11.1. Distribuciones observadas frente a hipótesis de cambio

El análisis descriptivo conserva medias, desviaciones y cuantiles 5/25/50/75/95 de las 20 entradas transformadas en cada partición, sin ajustar un nuevo escalador. Las mayores diferencias de media test menos train, medidas en desviaciones de train, corresponden a antigüedad observada (+4,046562), seno del mes (+0,992743) y coseno (+0,700490). Facturas medias de tres meses cambia +0,485939. La figura 21 muestra el conjunto completo de columnas. La antigüedad cre-

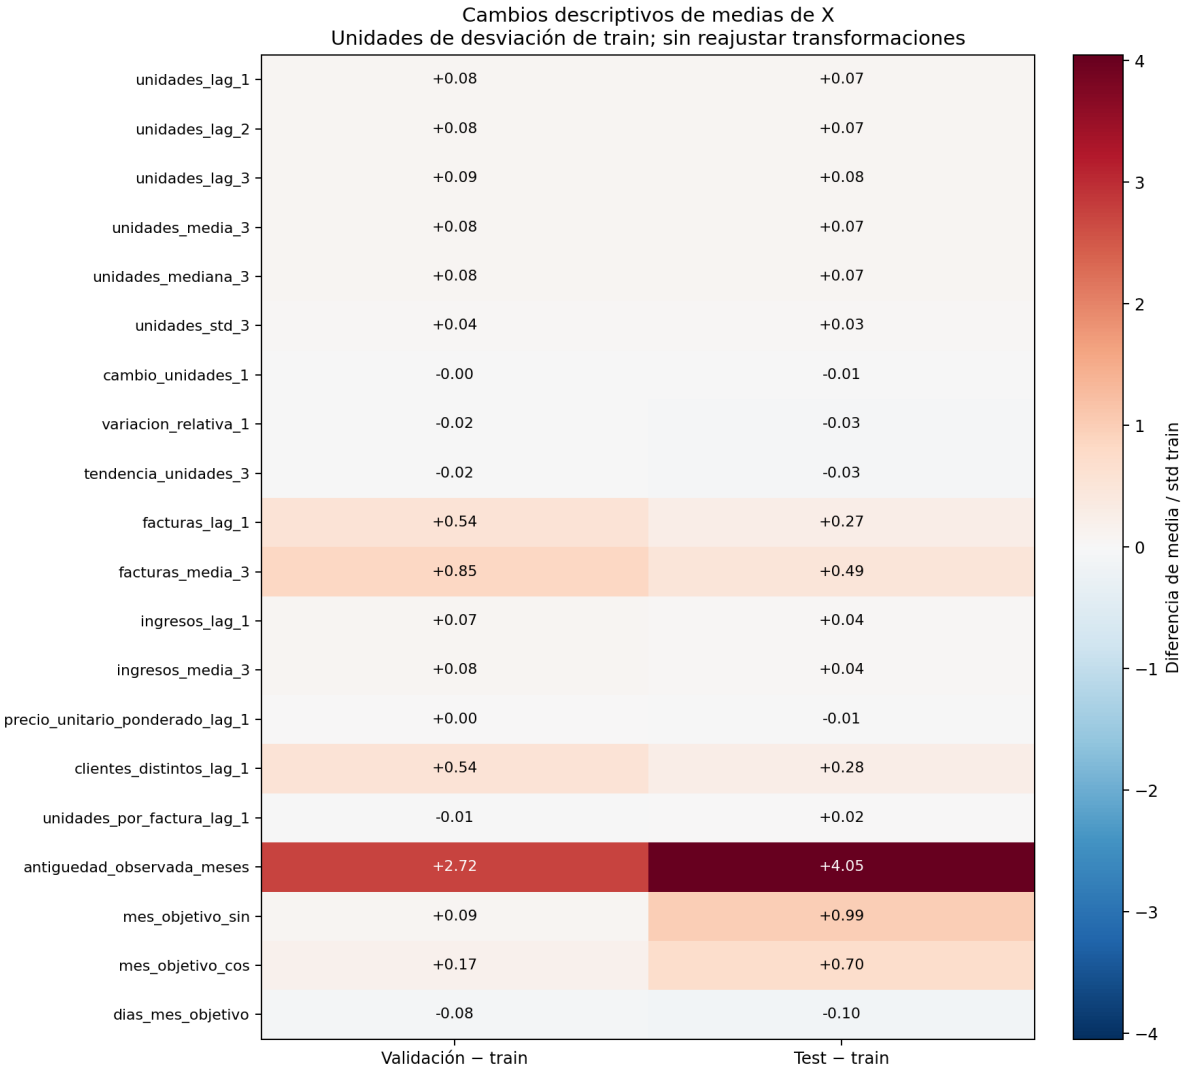


Figura 21: Cambios descriptivos de media en las 20 entradas existentes respecto a train, expresados en su desviación de entrenamiento. No son parámetros de una transformación nueva ni pruebas de deriva de concepto.

ce por definición del tiempo: los productos conocidos tienen entre 36 y 40 meses observados en test, frente a tres o cuatro en los nuevos. Además, test contiene enero–mayo, validación un año completo y train 21 meses objetivo: las mezclas del calendario no son idénticas. La mediana de unidades del mes previo en test es 192 entre conocidos y 3 336 entre nuevos, señal de escalas comerciales diferentes. Los resúmenes de historia mensual se conservan en el artefacto descriptivo, sin reinterpretar ausencia de una línea como falta de demanda.

Estos hallazgos prueban cambios descriptivos de X y mezcla de población, pero no demuestran un cambio de $P(y \mid X)$ o *concept drift*. Posibles explicaciones incluyen extrapolación temporal del

modelo lineal, comportamiento comercial variable, cobertura incompleta o identidad provisional; son hipótesis que los CSV no permiten discriminar causalmente. No se modifican características tras observarlas.

11.2. Incertidumbre y dependencia

Las 1 111 filas no son réplicas independientes. Se repiten productos, se solapan ventanas de historia y productos distintos comparten condiciones de un mismo mes. Solo hay cinco bloques temporales de test. No se utilizan intervalos iid, bootstrap de líneas de factura, p-valores ni declaraciones de superioridad estadística universal.

El análisis exploratorio omite sistemáticamente cada mes completo por turno y vuelve a agregar las mismas predicciones de los cuatro restantes. La BA logística resultante varía de 58,157 % a 64,129 %. Ese rango no es un intervalo de confianza, no corrige toda dependencia temporal y no reemplaza la evaluación oficial de los cinco meses. Se conservan todas las omisiones, sin elegir la favorable. La evidencia permite describir sensibilidad al período observado, no estimar de forma fiable la distribución de rendimiento futuro.

12. Interpretación para Inteligencia de Negocios

La mejor comparación global observada corresponde a logística, que también mejora BA y especificidad respecto al perceptrón. No obstante, 370 falsos positivos pueden generar revisiones comerciales innecesarias; los 49 falsos negativos pueden omitir meses superiores a la mediana reciente. No se traduce un FP automáticamente en sobrestock ni se inventan costos de revisión o ventas perdidas. El histórico reconoce más negativos, pero omite 374 positivos, por lo que tampoco es una solución comercial suficiente.

La utilidad de una alerta depende de la acción, su costo, la capacidad de revisión y el valor de detectar una subida relativa. Esos datos no están registrados. La comparación actual debe servir para comprender una primera aplicación académica y diseñar una validación operacional independiente, no para afirmar retorno de inversión.

Se requieren claves operativas y catálogos vigentes, unidades y empaques consistentes, cierres e ingestiones verificables, promociones y precios planificados, inventarios, faltantes de stock y demanda no atendida. También hacen falta acciones registradas y costos FP/FN validados por el negocio. La extracción de ventas observadas no sustituye esa información.

13. Limitaciones y decisiones pendientes

La identidad por nombre no prueba continuidad de producto y la cobertura al cierre es académica, no certificada. La respuesta mide facturación observada y un cambio relativo que puede ser pequeño; no incorpora relevancia económica ni disponibilidad de inventario. Las probabilidades logísticas no cuentan con calibración validada. La selección de tasa, checkpoint y umbral en una misma validación introduce optimismo en las métricas de desarrollo.

Las fronteras lineales pueden no representar todas las interacciones, pero el análisis no demuestra que esa limitación sea la causa del resultado. El presupuesto de épocas es finito y no certifica convergencia completa; PCA pierde 50,38 % de varianza en 2D. Cinco meses de test y 16 filas de productos nuevos restringen generalización e inferencia estadística. No se reutiliza la reserva consumida para mejorar las cifras.

En identificación académica, los informes previos coinciden en autores, asignatura, nivel y paralelo, pero sus fechas no permiten fijar inequívocamente el ciclo de esta entrega. La portada

deja ciclo y fecha pendientes; la forma del nombre y grado del docente sigue la solicitud actual. Las referencias locales no declaran con certeza una autoría bibliográfica individual para todos sus textos; se citan como documentos académicos del proyecto, sin inventar metadatos.

14. Conclusiones parciales del Data Mart de Ventas

La preparación temporal y los artefactos alineados permiten una comparación reproducible de dos modelos propios y dos baselines. El uso común de 20 entradas y particiones cronológicas evita atribuir diferencias a cambios de muestra o de representación entre clasificadores. Las etiquetas significan exclusivamente superar la mediana de tres meses del propio producto.

La regresión logística obtiene la mayor BA de test (62,42 %), con mejora observada frente a perceptrón y baselines. Su elevada tasa de falsos positivos y variación mensual impiden recomendar decisiones automáticas inmediatas. La BA global supera su promedio mensual por ponderaciones diferentes de clases, comprobadas algebraicamente, sin contradicción entre ambas cifras.

El perceptrón no deja de actualizarse y sus errores fluctúan; el checkpoint 70 debe distinguirse del último estado. La logística reduce monótonamente la entropía cruzada y el gradiente, pero termina por el máximo de épocas y mantiene gradiente no nulo. La conclusión verificable es descenso estable sin convergencia completa demostrada. La proyección PCA aporta una vista exploratoria, sin explicar causalmente el rendimiento ni sustituir los modelos de 20 dimensiones.

Las conclusiones se circunscriben al trabajo efectivamente realizado en Ventas. **La ampliación a los demás Data Marts es parte obligatoria del alcance académico pendiente**. Para cada uno deberán verificarse modelo dimensional y disponibilidad, formular una respuesta propia, fijar cortes y transformaciones y ejecutar una evaluación independiente. Este informe admite esa ampliación mediante nuevos módulos de metodología y resultados; no declara implementadas esas aplicaciones ni cierra definitivamente todas las obligaciones del proyecto.

Referencias

[1] F. Rosenblatt. "The perceptron: a probabilistic model for information storage and organization in the brain". *Psychological Review*, 65(6), 386–408, 1958. DOI: 10.1037/h0042519. Metadatos contrastados con PubMed, PMID 13602029. Referencia histórica; no se atribuye a este artículo la implementación particular del proyecto.

[2] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. ISBN 978-0-387-31073-2. Capítulos 4 (clasificación lineal) y 12 (reducción dimensional). Edición disponible desde Microsoft Research.

[3] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. Capítulos 3 y 9. Sitio de los autores: `https://web.stanford.edu/~boyd/cvxbook/`.

[4] NumPy Developers. *numpy.linalg.svd*, documentación oficial de la descomposición en valores singulares. `https://numpy.org/doc/stable/reference/generated/numpy.linalg.svd.html`. Consulta: 2 de noviembre de 2026. La versión ejecutada por el proyecto se registra en los manifiestos; la documentación enlazada es la estable al consultar.

[5] Proyecto académico de Inteligencia de Negocios. *Formato de levantamiento de datos para la planificación de un modelo OLAP: Wide World Importers*. Universidad Técnica de Ambato, 18/08/2026, versión 1.0. Documento local: `referencias/Carta_de_DiseÃśo(2).pdf`. Integrantes consignados: Jonathan López y Josue Guevara. Autoría editorial no declarada.

[6] Proyecto académico de Inteligencia de Negocios. *Limpieza y preparación de datos utilizando OpenRefine*. Universidad Técnica de Ambato, ciclo indicado enero–julio de 2026. Documento local: `referencias/Openrefine_Cluster(2).pdf`. Participantes consignados: Josue Guevara y Jonathan López.

[7] Proyecto académico de Inteligencia de Negocios. *Dashboard de Business Intelligence para el Análisis de Ventas*. Universidad Técnica de Ambato, ciclo indicado enero–julio de 2026. Documento local: `referencias/Dashboard(1).pdf`. Participantes consignados: Josue Guevara y Jonathan López.

A. Catálogo de características efectivas

Las fórmulas de la tabla 13 son transcripción del contrato estructurado, antes de imputación y estandarización. q_1, q_2, q_3 denotan unidades de los tres meses anteriores. Las unidades monetarias son las de la extracción: no se infiere una moneda empresarial sin metadatos adicionales.

Tabla 13: Entradas efectivas y fórmulas del contrato. $q_j = Q_{p,t-j}$.

Índice	Nombre	Fórmula registrada
1	`unidades_lag_1`	Q(p,t-1)
2	`unidades_lag_2`	Q(p,t-2)
3	`unidades_lag_3`	Q(p,t-3)
4	`unidades_media_3`	(q1+q2+q3)/3
5	`unidades_mediana_3`	mediana(q1,q2,q3)
6	`unidades_std_3`	std(q1,q2,q3), ddof=0
7	`cambio_unidades_1`	q1-q2
8	`variacion_relativa_1`	(q1-q2)/q2 si q2>0; nulo en otro caso
9	`tendencia_unidades_3`	(q1-q3)/2
10	`facturas_lag_1`	COUNT DISTINCT InvoiceID(p,t-1)
11	`facturas_media_3`	media de facturas distintas en t-1,t-2,t-3
12	`ingresos_lag_1`	SUM VentaSinImpuesto(p,t-1)
13	`ingresos_media_3`	media de ingresos de t-1,t-2,t-3
14	`precio_unitario_ponderado_lag_1`	ingresos_lag_1/q1 si q1>0; nulo si q1=0
15	`clientes_distintos_lag_1`	COUNT DISTINCT NombreCliente(p,t-1)
16	`unidades_por_factura_lag_1`	q1/facturas_lag_1 si facturas_lag_1>0; nulo si no
17	`antiguedad_observada_meses`	ordinal(t)-ordinal(primer mes observado antes del corte)
18	`mes_objetivo_sin`	sin(2*pi*(mes(t)-1)/12)
19	`mes_objetivo_cos`	cos(2*pi*(mes(t)-1)/12)
20	`dias_mes_objetivo`	días calendario de t, con bisiestos

B. Trazabilidad y reproducción documental

B.1. Relación entre afirmaciones y evidencia

El archivo `informe/evidencias/trazabilidad.json` relaciona cada tabla y figura con su fuente y hash SHA-256. Las afirmaciones cuantitativas sobre convergencia se derivan de los CSV por época y del registro de inicialización; las de evaluación se contrastan con las matrices, predicciones y análisis estadístico. Los pesos se comparan exactamente con el estado del archivo de congelación. Las figuras copiadas mantienen los mismos bytes de su origen; las nuevas vistas de soporte temporal, comparación global con cinco métricas, convergencia, paneles de error y error por partición se generan desde registros guardados.

La procedencia principal se organiza así:

- Calidad, grano y cardinalidades: `resultados/auditoria/`, especialmente `perfilado_datos.json` y `comparacion_csv.json`.
- Fórmulas, parámetros y particiones: `datos/Procesados/fase_03/` y su manifiesto.

- Pesos y recorrido del perceptrón: `resultados/fase_04/modelo_seleccionado.json` e `historial_orden_barajado.csv`.
- Logística, gradientes y selección: `resultados/fase_05/`, sus JSON y `historial_eta_010.csv`.
- PCA y estados congelados: `resultados/fase_06/`.
- Métricas y predicciones finales alineadas: `resultados/fase_07/`.
- Descomposición temporal, acuerdos, distribuciones y sensibilidad agrupada: `resultados/fase_08/`.

Los nombres técnicos de directorio se mantienen para reproducibilidad; no organizan la narrativa académica.

B.2. Comandos sin reentrenamiento

Desde la raíz del proyecto, el exportador documental lee artefactos y escribe únicamente dentro de `informe/`:

```
python informe/herramientas/generar_informe.py
cd informe
pdflatex -interaction=nonstopmode -halt-on-error main.tex
pdflatex -interaction=nonstopmode -halt-on-error main.tex
pdflatex -interaction=nonstopmode -halt-on-error main.tex
```

No ejecutar los entrenadores, la preparación del dataset ni la evaluación final para compilar. Los archivos `README.md` y `evidencias/verificacion_informe.json` documentan los comandos efectivos, número de tablas/figuras y controles de integridad. Se comprueban referencias cruzadas, ecuaciones, archivos gráficos y dimensiones de tablas, además de la inspección visual del PDF.

Los antecedentes registran 104 pruebas satisfactorias, sin fallos ni omisiones, antes de esta elaboración documental. El informe verifica nuevamente integridad y consistencia de las fuentes sin modificar esas pruebas o artefactos. Las pruebas matemáticas históricas usan ejemplos de control y no deben confundirse con reentrenamientos de WWI.

B.3. Parámetros y series que no deben confundirse

Los JSON conservan precisión completa de pesos y sesgos; los porcentajes del texto se redondean solo para lectura. Las curvas de accuracy y BA registran estados por época; las métricas finales corresponden al checkpoint restaurado. La norma del gradiente logístico incluye el sesgo y se registra después de cada actualización; `gradient_used_norm` corresponde al estado previo. No se transforma una curva de entrenamiento en una curva de test.

C. Continuidad obligatoria del proyecto académico

La siguiente ampliación documental deberá agregar, para cada Data Mart verificado, su formulación, procedencia, metodología, resultados y conclusiones parciales. No se presupone que Cliente o Producto constituyan Data Marts distintos; deben identificarse los procesos reales del DW y las extracciones disponibles. No se incluyen capítulos de resultados vacíos o ficticios. Antes de una entrega definitiva quedan pendientes la identificación del ciclo actual y la evidencia operacional de cobertura, claves y unidades. Esta versión termina con Ventas documentado y evaluado, manteniendo explícita la obligación de completar las demás aplicaciones.