UNIVERSIDAD TÉCNICA DE AMBATO

Facultad de Ingeniería en Sistemas, Electrónica e Industrial

Carrera de Software

Machine Learning aplicado al Data Warehouse Wide World Importers

Clasificación binaria de ventas y cobros mediante perceptrón simple y regresión logística

Informe académico incremental

Aplicaciones desarrolladas y evaluadas: Ventas y Transacciones Financieras

Asignatura: Inteligencia de Negocios
Autores: Josue Guevara
Jonathan López
Docente: Ing. Rubén Nogales Portero, Ph.D.
Nivel y paralelo: Sexto «A»
Unidad curricular: Profesional

Autores, nivel y unidad curricular verificados en los informes académicos previos.

Ciclo y fecha de entrega de esta versión: pendientes de confirmación.

Las referencias previas indican enero–julio de 2026 y una carta de diseño fechada el 18/08/2026.

Resumen

Se estudia la clasificación binaria de ventas unitarias mensuales de Wide World Importers (WWI), a partir de una extracción de su Data Mart de Ventas. La respuesta indica si las unidades observadas de un producto superan la mediana de sus tres meses previos. Se auditaron 228 265 líneas de factura y se construyeron observaciones producto-mes con información disponible antes del horizonte objetivo. El perceptrón simple y la regresión logística se implementaron mediante NumPy sobre las mismas 20 características transformadas, con particiones temporales de 4 599 observaciones de entrenamiento, 2 628 de validación y 1 111 de prueba.

La selección utilizó únicamente validación; las predicciones finales se conservaron y su consistencia se comprobó sin reentrenar. En prueba, la regresión logística alcanzó balanced accuracy de 62,42 %, frente a 54,10 % del perceptrón, 50,00 % del baseline mayoritario y 51,31 % de la regla histórica. La logística registró 370 falsos positivos y 49 falsos negativos, lo que limita su utilidad para alertas automáticas. El perceptrón mantuvo actualizaciones hasta la última época; la logística mostró descenso estable de entropía cruzada, sin demostración de convergencia completa al agotar 200 épocas. PCA se empleó solo para visualización y conservó 49,62 % de la varianza en dos componentes.

La ampliación financiera estudia una respuesta empresarial distinta: frecuencia de cobros registrados por cuenta cliente superior a la mediana de tres meses anteriores. A partir de eventos operacionales tipo 3 se prepararon 16 características y 4 612/2 943/1 284 observaciones de entrenamiento/validación/prueba. En la población principal de prueba, el perceptrón alcanzó BA de 66,222 % y logística 62,809 %, con mayor sensibilidad y más falsas alertas en el primero. El histórico contractual requiere cuatro meses y se compara por separado sobre 1 276 filas. El PCA financiero, solo visual, conserva 45,021 % de varianza en dos componentes. Ninguno de los historiales demuestra convergencia completa.

Las conclusiones son descriptivas de cinco meses de prueba por aplicación, con observaciones dependientes y cobertura académica, no certificada operacionalmente. Ventas conserva identidad provisional por nombre; Transacciones usa CustomerID operacional y supuestos explícitos de conservación del libro de eventos. Este informe unifica ambas aplicaciones sin comparar sus porcentajes como si correspondieran a la misma etiqueta o población. Pedidos y Compras permanecen como investigaciones de viabilidad con limitaciones documentadas; Inventario/Movimientos y la revisión de los procesos bloqueados forman parte del trabajo académico pendiente.

Palabras clave: Inteligencia de Negocios; Data Warehouse; clasificación temporal; perceptrón; regresión logística; PCA; trazabilidad.

Índice

Resumen I

1. Introducción 1

1.1. Alcance académico incremental 1

2. Problema empresarial y objetivos 1

2.1. Pregunta de negocio y respuesta operativa 1

2.2. Objetivo general 1

2.3. Objetivos específicos 1

3. Fundamentos matemáticos 2

3.1. Neurona artificial y perceptrón simple 2

3.2. Regresión logística binaria 3

3.2.1. Verificación de gradientes y condiciones de descenso 3

3.3. PCA mediante descomposición SVD 3

3.4. Métricas y magnitudes de error 4

4. Data Warehouse WWI y evidencia de origen 5

5. Metodología y preparación causal de datos 5

5.1. Grano producto-mes, etiqueta e instante de predicción 5

5.2. Completitud y disponibilidad asumidas 5

5.3. Características permitidas y exclusiones 6

5.4. Particiones temporales y control de fuga 6

5.5. Baselines comunes 7

6. Implementación del perceptrón simple 8

7. Implementación de la regresión logística binaria 11

8. Verificación de convergencia y comportamiento del error 15

8.1. Evidencia y definición de los diagnósticos 15

8.2. Perceptrón: fluctuaciones sin cese de actualizaciones 15

8.3. Logística: descenso estable, límite de épocas 15

9. Reducción dimensional para visualización 18

10. Resultados experimentales 21

10.1. Comparación común de entrenamiento, validación y prueba 21

10.2. Matrices de confusión, sensibilidad y exceso de positivos 22

10.3. Generalización temporal y error por partición 22

10.3.1. Por qué BA global y promedio mensual difieren 24

10.4. Productos conocidos y nuevos . . . 25
10.5. Concordancias y desacuerdos . . . 25

11. Comparación estadística y cambios de distribución 27
11.1. Distribuciones observadas frente a hipótesis de cambio . . . 27
11.2. Incertidumbre y dependencia . . . 28

12. Interpretación para Inteligencia de Negocios 28

13. Limitaciones y decisiones pendientes 28

14. Conclusiones parciales del Data Mart de Ventas 29

15. Clasificación de la frecuencia de cobros en Transacciones Financieras 30
15.1. Problema empresarial, eventos e identidad . . . 30
15.2. Contrato temporal, cobertura y etiqueta . . . 30
15.3. Preparación causal y representación de 16 entradas . . . 31
15.4. Configuración experimental y modelos congelados . . . 32
15.4.1. Perceptrón financiero . . . 32
15.4.2. Regresión logística financiera . . . 33
15.5. Convergencia observada y comportamiento durante el entrenamiento . . . 34
15.5.1. Perceptrón: oscilación y checkpoint temprano . . . 34
15.5.2. Logística: descenso estable sin alcanzar tolerancia . . . 34
15.6. PCA financiero: estructura de variación y solapamiento . . . 39
15.7. Evaluación final: apertura, poblaciones y baselines . . . 42
15.8. Generalización temporal, cuentas nuevas y análisis de errores . . . 45
15.9. Limitaciones y conclusión parcial financiera . . . 47

16. Comparación académica entre Ventas y Transacciones 48

17. Conclusiones integradas y continuidad del alcance académico 48

Referencias bibliográficas 50

A. Catálogo de características efectivas 51

B. Trazabilidad y reproducción documental 51
B.1. Relación entre afirmaciones y evidencia . . . 51
B.2. Comandos sin reentrenamiento . . . 52
B.3. Parámetros y series que no deben confundirse . . . 52
B.4. Trazabilidad de la ampliación financiera . . . 52

C. Continuidad obligatoria del proyecto académico 53

Índice de figuras

1. Clases y calendario por partición . . . 6
2. Errores online del perceptrón . . . 9
3. Accuracy por época del perceptrón . . . 9
4. BA de validación del perceptrón . . . 10
5. Entropía cruzada de entrenamiento y validación . . . 12
6. Norma del gradiente logístico . . . 13
7. Accuracy por época de logística . . . 13
8. BA de validación de logística . . . 14
9. Diagnóstico detallado de convergencia logística . . . 16
10. Conteos del perceptrón y pérdida logística en paneles separados . . . 17
11. Dispersión PCA de entrenamiento . . . 19
12. Dispersión PCA de validación . . . 19
13. Varianza individual y acumulada del PCA . . . 20
14. Comparación de métricas globales de test . . . 21
15. Matriz de confusión de test del perceptrón . . . 22
16. Matriz de confusión de test de logística . . . 23
17. Sensibilidad y especificidad por método . . . 23
18. Error de clasificación por partición . . . 24
19. BA de todos los meses de test . . . 25
20. Aciertos compartidos y exclusivos por mes . . . 26
21. Cambios de medias en las entradas existentes . . . 27
22. Errores online del perceptrón financiero . . . 34
23. Actualizaciones del perceptrón financiero . . . 35
24. Accuracy por época del perceptrón financiero . . . 35
25. BA de validación del perceptrón financiero . . . 36
26. Entropía cruzada logística de Transacciones . . . 37
27. Gradiente logístico de Transacciones . . . 37
28. Accuracy logística por época en Transacciones . . . 38
29. BA logística por época en Transacciones . . . 38
30. PCA financiero de entrenamiento . . . 40
31. PCA financiero de validación . . . 40
32. Varianza explicada del PCA financiero . . . 41
33. Confusión del perceptrón financiero en test . . . 43
34. Confusión logística financiera en test . . . 43
35. BA financiera en soporte común . . . 44
36. Métricas financieras en soporte común . . . 44
37. Sensibilidad y especificidad financieras . . . 45
38. BA financiera mensual en soporte común . . . 46
39. Generalización temporal financiera . . . 46

Índice de tablas

1. Particiones por mes objetivo y soporte de clases; historia disponible desde enero de 2013. . . . 6
2. Pesos del modelo congelado perceptrón. Valores float64 conservados con representación decimal de ida y vuelta. . . . 8
3. Verificación original por diferencias finitas centrales. Todos los casos cumplen tolerancias. . . . 11
4. Presupuesto logístico previo: 200 épocas por tasa; checkpoint elegido por BA de validación a umbral 0,5. . . . 11
5. Pesos del modelo congelado logístico. Valores float64 conservados con representación decimal de ida y vuelta. . . . 12
6. Recorrido seleccionado del perceptrón: errores online y al cierre son magnitudes diferentes. . . . 15
7. Diagnóstico documental por época. ΔL y r se derivan del historial sin modificar el criterio de parada. . . . 16
8. Cinco mayores coeficientes por magnitud en cada componente. El cuadrado es participación en la norma del vector, no importancia predictiva. . . . 18
9. Métricas finales por partición (%). Estados seleccionados en validación; no corresponden a la última época del perceptrón. . . . 21
10. Conteos de test y tasas de error (%). Filas reales y columnas predichas en orden 0,1. 22
11. Todos los meses de test. Tasas en %; soporte negativo/positivo. . . . 24
12. Comparación de cohortes en test, sin excluir los productos nuevos. . . . 25
13. Las 16 características financieras antes de estandarizar. $n_k = N_{c,t-k}$. . . . 31
14. Transacciones: particiones temporales y poblaciones principal y común. . . . 32
15. Presupuesto financiero predefinido: cuatro ejecuciones, sin ampliación adaptativa. . 32
16. Pesos financieros congelados: perceptrón. Precisión decimal suficiente para recuperar float64. . . . 33
17. Pesos financieros congelados: logística. Precisión decimal suficiente para recuperar float64. . . . 33
18. Métricas financieras de los checkpoints seleccionados en soporte principal (%). . . . 34
19. Coeficientes de mayor magnitud del PCA financiero en entradas estandarizadas. . . 39
20. Test financiero: métricas sobre las 1 284 filas principales (%). . . . 42
21. Conteos financieros principales y tasas FPR/FNR y predicción positiva (%). . . . 42
22. Comparación financiera secundaria: los cuatro métodos en 1 276 filas (%). . . . 42
23. Todos los meses de test financiero: soporte principal y BA principal, sin sustituirla por la común. . . . 45
24. Cuentas financieras conocidas y nuevas; cinco filas nuevas no acreditan generalización estable. . . . 45
25. Contraste descriptivo entre problemas distintos: porcentajes de test, sin comparación estadística emparejada. . . . 48
26. Entradas efectivas y fórmulas del contrato. $q_j = Q_{p,t-j}$. . . . 51

1. Introducción

El análisis descriptivo de un Data Warehouse permite comparar indicadores por tiempo, producto, cliente y territorio. La clasificación predictiva plantea una pregunta distinta: qué información disponible antes de un mes permite anticipar un comportamiento de sus ventas. Este trabajo enlaza ambas perspectivas mediante un problema reproducible, con reglas temporales explícitas y evaluación común de dos clasificadores lineales.

La carta de diseño plantea necesidades de seguimiento comercial, clientes e inventario; los informes de limpieza y dashboard documentan la preparación y exploración del ámbito de ventas [5, 6, 7]. La extracción disponible respalda esa primera aplicación, pero no acredita la disponibilidad ni implementación de todos los procesos del Data Warehouse. Las dimensiones Producto y Cliente no se consideran Data Marts independientes por el solo hecho de existir como dimensiones.

1.1. Alcance académico incremental

La instrucción proporcionada para esta entrega es: «Perfeccionen todo con un data mart y de ahí háganlo con el resto de Data Marts». Ventas constituye la primera aplicación desarrollada y evaluada; esta versión incorpora una segunda aplicación completa en Transacciones Financieras, mediante eventos de cobro por cuenta cliente. La continuación obligatoria exige verificar modelo, datos y problema propio de cada proceso. Pedidos y Compras cuentan con investigaciones de viabilidad, pero no con clasificadores aprobados; Inventario/Movimientos continúa pendiente. La estructura del informe comparte fundamentos y criterios temporales, mientras distingue las unidades, fuentes y resultados de cada aplicación.

2. Problema empresarial y objetivos

2.1. Pregunta de negocio y respuesta operativa

Al cierre del mes anterior se busca identificar productos cuyas unidades facturadas observadas en el siguiente mes superarán su mediana reciente. La comparación se realiza contra la historia del propio producto, no contra un umbral absoluto común. Un positivo puede corresponder a una diferencia de una sola unidad; su relevancia comercial necesita validación adicional.

La respuesta no representa rentabilidad, demanda insatisfecha, inventario disponible ni cantidad exacta futura. Una alerta podría orientar la revisión de un analista comercial; no establece por sí sola una orden de compra o reposición. No se dispone de costos de falsos positivos o negativos para cuantificar beneficio económico.

2.2. Objetivo general

Desarrollar y documentar aplicaciones verificables de clasificación binaria en Ventas y Transacciones Financieras de WWI, comparando un perceptrón simple y una regresión logística implementados matemáticamente, con prevención de fuga temporal y conclusiones sustentadas en resultados congelados. La formulación comercial que sigue corresponde a Ventas; la pregunta financiera y sus restricciones se desarrollan en la sección 15.

2.3. Objetivos específicos

1. Auditar el grano, identidad, calidad y disponibilidad temporal de los datos antes de definir las entradas y la etiqueta.

2. Preparar una representación común de dimensión dinámica y particiones cronológicas, con parámetros de transformación ajustados solo en entrenamiento.

3. Implementar las reglas del perceptrón y los gradientes logísticos, comprobar su matemática y analizar sus historiales reales.

4. Comparar ambos modelos con baselines mediante matrices de confusión, métricas por clase y evaluación temporal.

5. Interpretar PCA únicamente como visualización e identificar las limitaciones estadísticas y empresariales de la evidencia.

6. Contrastar la clasificación de unidades vendidas con la frecuencia de cobros, sin confundir sus poblaciones ni atribuir superioridad universal a un algoritmo.

7. Mantener una estructura documental reproducible para la ampliación obligatoria a los procesos pendientes, sin presentarlos como implementados.

3. Fundamentos matemáticos

3.1. Neurona artificial y perceptrón simple

Una observación transformada es un vector $x \in \mathbb{R}^d$, con $d = 20$ en Ventas y $d = 16$ en Transacciones Financieras. La implementación conserva dimensionalidad dinámica. Una neurona lineal combina cada entrada con un peso w_j y añade un sesgo b:

$$z = w^\top x + b = \sum_{j=1}^{d} w_j x_j + b, \qquad \widehat{y} = \mathbf{1}[z \geq 0]. \tag{1}$$

El peso controla la contribución algebraica de una entrada y el sesgo desplaza el hiperplano. La función escalón devuelve una clase, no una probabilidad. Con etiquetas canónicas $y \in \{0, 1\}$, la implementación usa

$$e_i = y_i - \widehat{y}_i, \quad w \leftarrow w + \eta e_i x_i, \quad b \leftarrow b + \eta e_i, \tag{2}$$

solo si $e_i \neq 0$. La tasa $\eta > 0$ determina la magnitud del paso. Una época recorre todas las observaciones de entrenamiento; cada error durante ese recorrido produce una actualización. Los errores al finalizar una época se calculan con un único estado de parámetros y pueden diferir del conteo online, que mezcla los estados sucesivos.

La separabilidad lineal supone que existe un hiperplano que clasifica estrictamente todos los ejemplos. Para expresar la condición teórica, se incorporan sesgo y entrada aumentada $\widetilde{x} = (x, 1)$, etiquetas $s = 2y - 1$ y un separador unitario u con margen $s_i u^\top \widetilde{x}_i \geq \gamma > 0$. Si $\|\widetilde{x}_i\| \leq R$, la regla clásica desde cero realiza a lo sumo $(R/\gamma)^2$ errores bajo esas hipótesis. El escalado constante positivo de la actualización no cambia el argumento geométrico. La convención de empate del programa asigna 1; ello no autoriza inferir separabilidad de los datos.

La garantía requiere un margen positivo y presentación reiterada de los ejemplos. No establece que cualquier conjunto real sea separable, ni que 100 épocas basten, ni que un checkpoint con buena validación tenga cero errores. En ausencia de una prueba de separabilidad, las oscilaciones observadas solo describen el comportamiento de esta ejecución. El modelo corresponde al antecedente clásico del perceptrón [1]; su optimización no es descenso de entropía cruzada.

3.2. Regresión logística binaria

Para el mismo $z_i = w^\top x_i + b$, se estima $p_i = \sigma(z_i) = 1/(1+\exp(-z_i))$. El umbral τ transforma la salida en $\widehat{y}_i = \mathbf{1}[p_i \geq \tau]$. Aquí $\tau = 0,5$ está congelado: la frontera es $z = 0$. La salida está comprendida entre cero y uno, pero su calibración empírica no se deduce de esa propiedad.

La pérdida media para m ejemplos es la entropía cruzada binaria:

$$\begin{aligned} L(w,b) &= -\frac{1}{m}\sum_{i=1}^{m}[y_i \log p_i + (1-y_i)\log(1-p_i)] \\ &= \frac{1}{m}\sum_{i=1}^{m}[\log(1+\exp(z_i)) - y_i z_i]. \end{aligned} \tag{3}$$

Derivando con respecto al logit se obtiene $\partial \ell_i / \partial z_i = p_i - y_i$; la regla de la cadena conduce a

$$\nabla_w L = \frac{1}{m} X^\top (p - y), \qquad \partial_b L = \frac{1}{m}\sum_i (p_i - y_i). \tag{4}$$

El descenso por lote completo actualiza $w \leftarrow w - \eta \nabla_w L$ y $b \leftarrow b - \eta \partial_b L$ una vez por época. Utiliza toda la matriz, no únicamente ejemplos mal clasificados. El objetivo suave refleja también cambios de confianza que no cruzan el umbral, por lo que resulta más informativo para estudiar la optimización que el conteo discreto de errores. Las convenciones de clasificación y pérdida siguen el tratamiento de modelos lineales probabilísticos [2].

La estabilidad numérica se favorece evaluando la sigmoidea por ramas: para $z \geq 0$, $1/(1+e^{-z})$; para $z < 0$, $e^z/(1+e^z)$. La pérdida utiliza `np.logaddexp(0,z)-y*z`, sin calcular logaritmos de probabilidades redondeadas a cero ni recortarlas. El programa rechaza estados no finitos.

3.2.1. Verificación de gradientes y condiciones de descenso

Para un parámetro θ_j, las diferencias centrales aproximan

$$g_j^{\text{num}} = \frac{L(\theta + h_j e_j) - L(\theta - h_j e_j)}{2h_j}, \qquad h_j = h\,\text{máx}(1, |\theta_j|), \tag{5}$$

donde e_j es el vector coordenado, incluido el sesgo. Se contrasta $|g_j - g_j^{\text{num}}| \leq \text{atol} + \text{rtol}|g_j^{\text{num}}|$. Un paso demasiado pequeño amplifica cancelación y uno demasiado grande aumenta error de truncamiento. La prueba comprueba derivadas locales en sus casos de control; no demuestra convergencia del entrenamiento WWI.

Con matriz aumentada $A = [X\ \mathbf{1}]$ y $D = \text{diag}(p_i(1-p_i))$, la Hessiana es $A^\top DA/m \succeq 0$. Así, el objetivo es convexo y tiene gradiente Lipschitz con cota $L_g \leq \|A\|_2^2/(4m)$. Un paso adecuadamente pequeño, por ejemplo $0 < \eta < 2/L_g$ cuando se dispone de esa cota, permite justificar descenso. Esta condición no se comprobó retrospectivamente para elegir otra tasa. Sin regularización, separabilidad puede impedir un minimizador finito; redundancia puede impedir unicidad. Menor pérdida, gradiente reducido y estabilización son diagnósticos distintos de certificar un óptimo [3].

3.3. PCA mediante descomposición SVD

Sea $X \in \mathbb{R}^{m\times d}$ la matriz de entrenamiento ya transformada. Se calcula su media μ y $X_c = X - \mathbf{1}\mu^\top$. La SVD real produce

$$X_c = U\Sigma V^\top, \quad W_2 = [v_1, v_2], \quad Z = (X - \mathbf{1}\mu^\top)W_2. \tag{6}$$

Los vectores v_j son ortonormales y los valores singulares σ_j están ordenados de mayor a menor, de acuerdo con la operación SVD de NumPy [4]. Las varianzas y proporciones se definen por

$$\lambda_j = \frac{\sigma_j^2}{m-1}, \qquad \rho_j = \frac{\lambda_j}{\sum_{q=1}^{d} \lambda_q}. \tag{7}$$

El denominador incluye las d direcciones, no solo las dos conservadas: 20 en Ventas y 16 en Transacciones. La proyección favorece varianza, no separación de etiquetas. El signo de cada vector es convencional; aquí se hace positivo su coeficiente de mayor magnitud. Cada aplicación ajustó centrado y componentes solo en su entrenamiento y los reutilizó en su validación. Los clasificadores conservaron las 20 o 16 entradas originales transformadas, respectivamente.

3.4. Métricas y magnitudes de error

Con matriz de confusión $C = \left[\begin{smallmatrix} TN & FP \\ FN & TP \end{smallmatrix}\right]$, filas reales y columnas predichas, se calculan

$$\text{Accuracy} = (TP + TN)/N, \qquad \text{Precision} = TP/(TP + FP), \tag{8}$$

$$\text{Recall} = TP/(TP + FN), \qquad \text{Specificity} = TN/(TN + FP), \tag{9}$$

$$F_1 = 2TP/(2TP + FP + FN), \qquad BA = \tfrac{1}{2}(\text{Recall} + \text{Specificity}), \tag{10}$$

$$FPR = FP/(TN + FP), \qquad FNR = FN/(TP + FN). \tag{11}$$

La proporción de predicciones positivas es $(TP+FP)/N$. El error de clasificación es $1-\text{Accuracy}$; no equivale a entropía cruzada ni a número de actualizaciones. Si no existen positivos predichos, precision se registra como cero con indicador de denominador nulo; recall y especificidad no son estimables si falta su clase real, y BA requiere ambas clases. Todas las particiones globales de este estudio contienen ambas clases.

4. Data Warehouse WWI y evidencia de origen

La carta de diseño describe un modelo estrella de ventas con `FactVentas` y las dimensiones Tiempo, Producto, Cliente, Ubicación y Vendedor [5]. El grano propuesto y comprobado en la extracción es una línea de factura, identificada por `InvoiceLineID`. `InvoiceID` se repite legítimamente cuando una factura contiene varias líneas; contar facturas exige identificar valores distintos, no sumar filas.

Los dos CSV auditados contienen 228 265 filas y 30 columnas. La extracción cubre del 1 de enero de 2013 al 31 de mayo de 2016, con 41 meses. Se encontraron 70 510 facturas y 227 nombres de producto, sin duplicados completos ni duplicados de la clave de línea. Las medidas monetarias satisfacen las relaciones aritméticas comprobadas. La limpieza conserva las claves y medidas; además del tratamiento de nulos, se observan 268 recortes de espacio en un nombre de cliente. La columna afectada es `NombreCliente`, según la comparación estructurada, aunque un resumen previo lo atribuye a vendedor. No se atribuye ese cambio a una operación específica sin el historial de OpenRefine.

La auditoría detectó ausencias en Marca (209 328), Tamaño (67 315) y GrupoCompra (84 297), que no justifican borrar las observaciones. Se conservaron extremos y beneficios negativos. Estos últimos no son errores demostrados: faltan costos históricos para explicar su origen. La extracción no incluye StockItemID, CustomerID ni CityID, por lo que la identidad por nombre es provisional. Inventario histórico, compras, cobros y demanda no atendida no están disponibles en los CSV usados.

Los documentos previos describen procesos analíticos y un dashboard [6, 7]; no verifican por sí solos todos los cierres, claves, medidas de otras áreas o disponibilidad al instante de predicción. Las cifras anteriores se contrastaron con `resultados/auditoria/perfilado_datos.json`, su comparación entre fuentes y los manifiestos posteriores. La trazabilidad por archivo se conserva en los anexos digitales del informe.

5. Metodología y preparación causal de datos

5.1. Grano producto-mes, etiqueta e instante de predicción

Sea $Q_{p,t}$ la suma de unidades facturadas observadas del producto provisional p en el mes t. La referencia histórica y la etiqueta son

$$R_{p,t} = \text{mediana}(Q_{p,t-1}, Q_{p,t-2}, Q_{p,t-3}), \qquad y_{p,t} = \mathbf{1}[Q_{p,t} > R_{p,t}]. \tag{12}$$

Clase 1 significa ventas unitarias superiores a la mediana reciente del mismo producto; el empate pertenece a clase 0. El horizonte es un mes y el instante de predicción es el cierre de $t-1$. La cantidad objetivo y su etiqueta se mantienen separadas de las entradas. El calendario del mes futuro sí es conocido al corte.

Un producto es elegible cuando se reconoce antes del corte y dispone de los tres meses históricos esenciales, con cobertura válida conforme al contrato. Se construyó el calendario desde su primera aparición; no se asignaron ceros antes de esa fecha. El calendario contiene 9 019 filas y 8 792 corresponden a productos ya reconocidos antes del corte. Se evitaron 288 pares previos a la primera aparición de ocho productos recientes. Las observaciones no elegibles se conservan con su estado, sin fabricar una etiqueta cero.

5.2. Completitud y disponibilidad asumidas

La ejecución aprobada utiliza modo académico: se asume completitud y disponibilidad al cierre de enero de 2013 a mayo de 2016. No es una certificación del sistema fuente. En un modo de

cobertura desconocida, una ausencia no puede convertirse automáticamente en cero ventas. Los cierres e ingestiones reales deben demostrarse para una aplicación operacional. La disponibilidad secuencial permite usar un mes ya cerrado de test como historia de uno posterior, sin reajustar transformaciones o modelos.

5.3. Características permitidas y exclusiones

Se definieron 23 entradas numéricas base. Incluyen tres retardos de unidades, media, mediana y dispersión histórica; cambio absoluto, variación relativa y tendencia; facturas, ingresos y clientes históricos; precio ponderado y unidades por factura; antigüedad observada y calendario conocido. Las 20 columnas efectivas y sus fórmulas completas constan en el anexo A.

Se excluyeron variables del horizonte, medidas monetarias y clientes futuros, identificadores directos, inventario inexistente, atributos estáticos sin historia verificable y categorías no autorizadas. Tampoco se añadieron características después de observar test. Se preservaron redundancias algebraicas: eliminarlas por rendimiento habría cambiado el contrato.

Las razones no esenciales pueden ser nulas si su denominador es cero. Se imputaron con medianas de entrenamiento; la historia esencial ausente bloquea elegibilidad. Tras imputar, se eliminaron únicamente tres columnas constantes en entrenamiento: `base_variacion_cero`, `mes_anterior_sin_ventas` y `facturas_lag_1_cero`. No se suprimieron columnas por correlación con la respuesta o por inspección del rendimiento final.

La estandarización aplica $x_j = (\widetilde{x}_j - \mu_j)/s_j$, donde $\widetilde{x}_j$ es la entrada imputada y μ_j, s_j provienen solo de entrenamiento, con desviación poblacional ($ddof = 0$). Las mismas medianas, medias, desviaciones y orden de columnas se reutilizan en validación y test. Las matrices son float64 y las etiquetas int8 canónicas 0/1. No hay codificación categórica en el contrato aprobado.

5.4. Particiones temporales y control de fuga

Tabla 1: Particiones por mes objetivo y soporte de clases; historia disponible desde enero de 2013.

Conjunto	Mes inicial–final	N	Clase 0	Clase 1	Clase 1 (%)
Entrenamiento	2013-04–2014-12	4599	2217	2382	51.794
Validación	2015-01–2015-12	2628	1299	1329	50.571
Prueba	2016-01–2016-05	1111	558	553	49.775

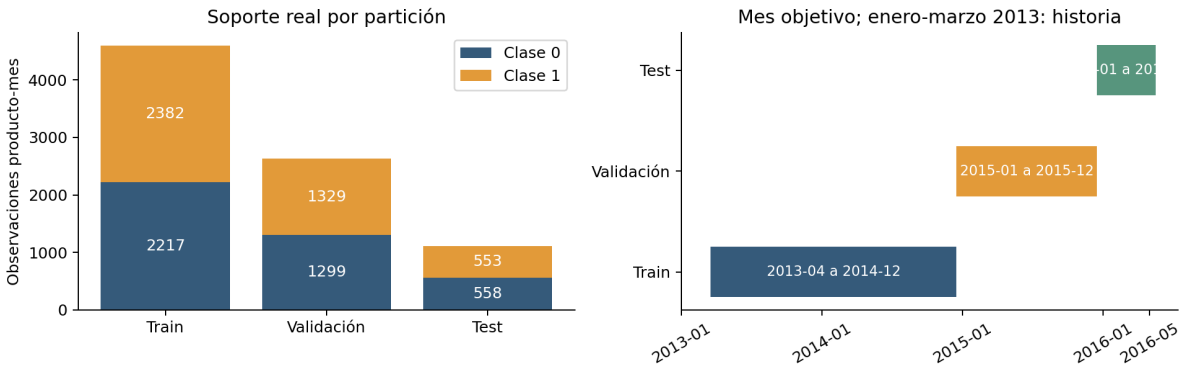


Figura 1: Distribución real de clases y períodos por mes objetivo. Enero–marzo de 2013 aportan la historia inicial, no observaciones objetivo de entrenamiento.

Las observaciones se ordenan por mes objetivo y nombre provisional de producto. Los índices e

identificadores producto-mes se conservaron alineados entre modelos. La validación seleccionó configuraciones y checkpoints; test se utilizó después de congelar las decisiones, sin volver a entrenar con train más validación. No se usó partición aleatoria de líneas de factura.

El protocolo previno fuga mediante desplazamiento por calendario, ajuste exclusivo con train, separación de respuestas y protección de hashes. Las pruebas existentes incluyen perturbaciones del horizonte y de datos futuros, fronteras de partición y persistencia del preprocesador. Ambos modelos reciben exactamente las mismas matrices, filas y etiquetas. Las métricas de validación son de selección, por lo que pueden ser optimistas; no se presentan como una reserva independiente del diseño.

5.5. Baselines comunes

El mayoritario predice la clase más frecuente de train, aquí 1, con empate resuelto hacia 0. El histórico predice $\mathbf{1}[Q_{p,t-1} > R_{p,t}]$, usando cantidades crudas comparables, no columnas estandarizadas en escalas distintas. Ambos se evaluaron sobre los mismos casos que los clasificadores; no se eligió su regla según test.

6. Implementación del perceptrón simple

La implementación propia en `src/models/perceptron.py` valida dimensión, finitud, etiquetas y orden de nombres. El número de entradas es dinámico; en esta aplicación se deduce de las 20 columnas aprobadas. Usa NumPy, la función escalón de la ecuación 1 y la actualización online de la ecuación 2, sin optimizadores externos ni pérdida probabilística.

El presupuesto previo compara orden fijo y orden barajado con tasa 0,01, semilla 42, pesos y sesgo iniciales cero y máximo de 100 épocas por recorrido. La validación selecciona máxima BA, después mayor F1 positivo, menor época y orden del plan. El estado elegido se restaura mediante copia de pesos; no se exporta automáticamente la última época ni se realiza refit.

El orden fijo seleccionó la época 80 y obtuvo BA de validación 61,508 %; el barajado seleccionó la época 70 y alcanzó 61,632 %, por lo que se conservó este último. Con inicialización cero y tasa constante positiva, cambiar solo la tasa escala la trayectoria en aritmética exacta; las operaciones flotantes pueden romper esa equivalencia. Por ello, el presupuesto aprobado no amplió tasas retrospectivamente.

El sesgo seleccionado es $b = 0{,}010000000000000004$. La tabla 2 conserva los 20 pesos extraídos del JSON congelado. Operan sobre entradas transformadas: sus magnitudes no expresan efectos en unidades crudas ni importancia causal independiente. Las métricas train/validación/test y matrices se presentan en la sección 10. El número de actualizaciones coincide exactamente con

Tabla 2: Pesos del modelo congelado perceptrón. Valores float64 conservados con representación decimal de ida y vuelta.

Índice	Característica estandarizada	Peso
1	`unidades_lag_1`	0.08604738881119216
2	`unidades_lag_2`	0.07955933295077251
3	`unidades_lag_3`	0.08643380694807037
4	`unidades_media_3`	0.08682046217511337
5	`unidades_mediana_3`	-0.3720436256352147
6	`unidades_std_3`	-0.0011423824327889114
7	`cambio_unidades_1`	0.016234371544841163
8	`variacion_relativa_1`	0.015503476495048884
9	`tendencia_unidades_3`	0.002266138406936554 8
10	`facturas_lag_1`	-0.01341653202315568
11	`facturas_media_3`	-0.07449527454509768
12	`ingresos_lag_1`	-0.08671342154352552
13	`ingresos_media_3`	0.09642870252787368
14	`precio_unitario_ponderado_lag_1`	0.14385982435183342
15	`clientes_distintos_lag_1`	-0.04867982347072822
16	`unidades_por_factura_lag_1`	0.0246007086039395
17	`antiguedad_observada_meses`	0.0478919237829946
18	`mes_objetivo_sin`	0.05422922302085315
19	`mes_objetivo_cos`	0.030914856096277414
20	`dias_mes_objetivo`	0.034500061409917425

los errores online en cada época. Una segunda figura que dibujara solo actualizaciones duplicaría la misma serie; la identidad se verificó y ambos conteos se presentan en la tabla 6. La figura 10 aporta en cambio el conteo de errores al cierre, que sí es información diferente.

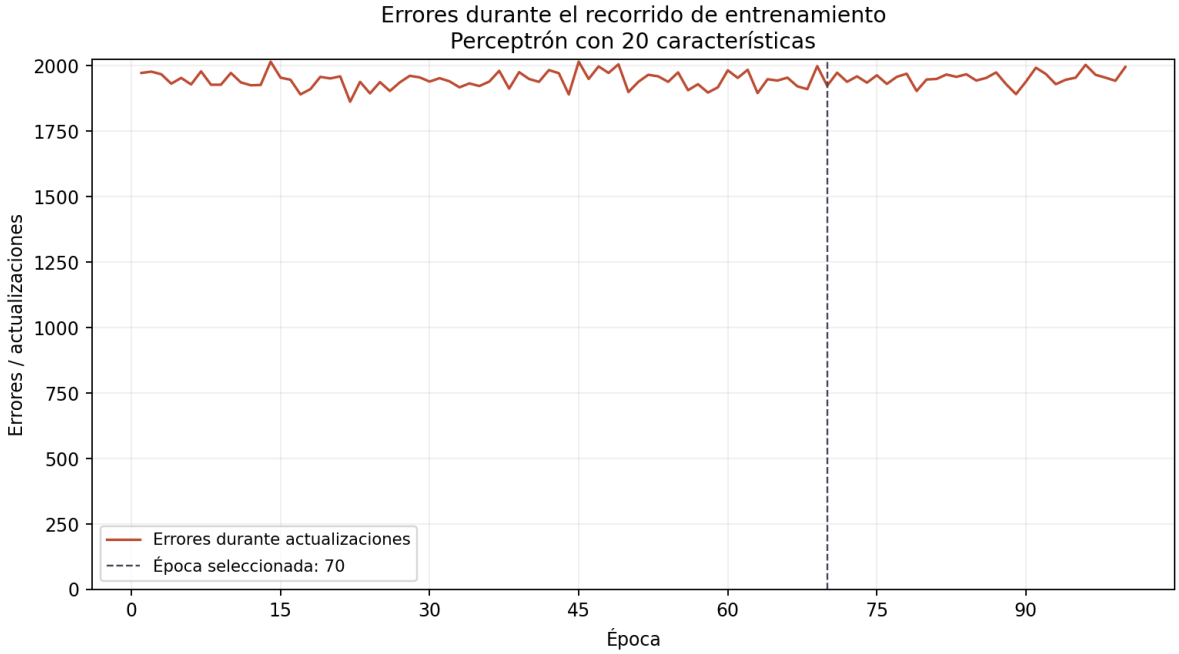


Figura 2: Errores del recorrido de entrenamiento del perceptrón. El análisis distingue conteo online de error al cierre; no es entropía cruzada. El checkpoint seleccionado es la época 70.

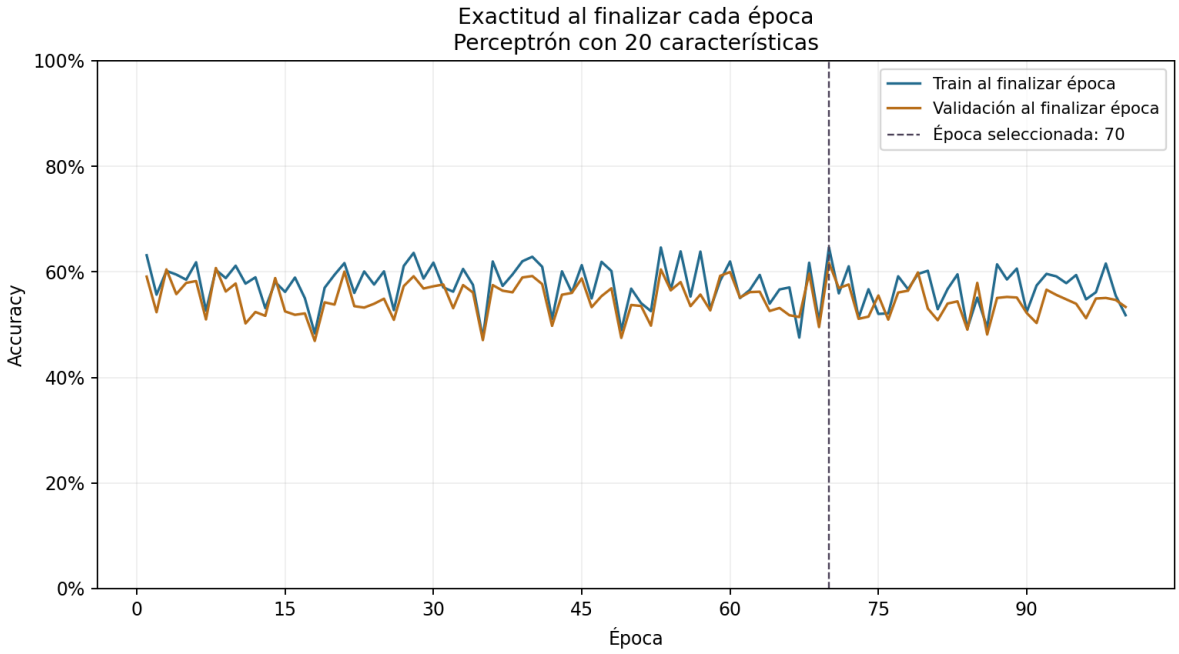


Figura 3: Accuracy de entrenamiento y validación por época del recorrido barajado. Las oscilaciones no se ocultan mediante suavizado.

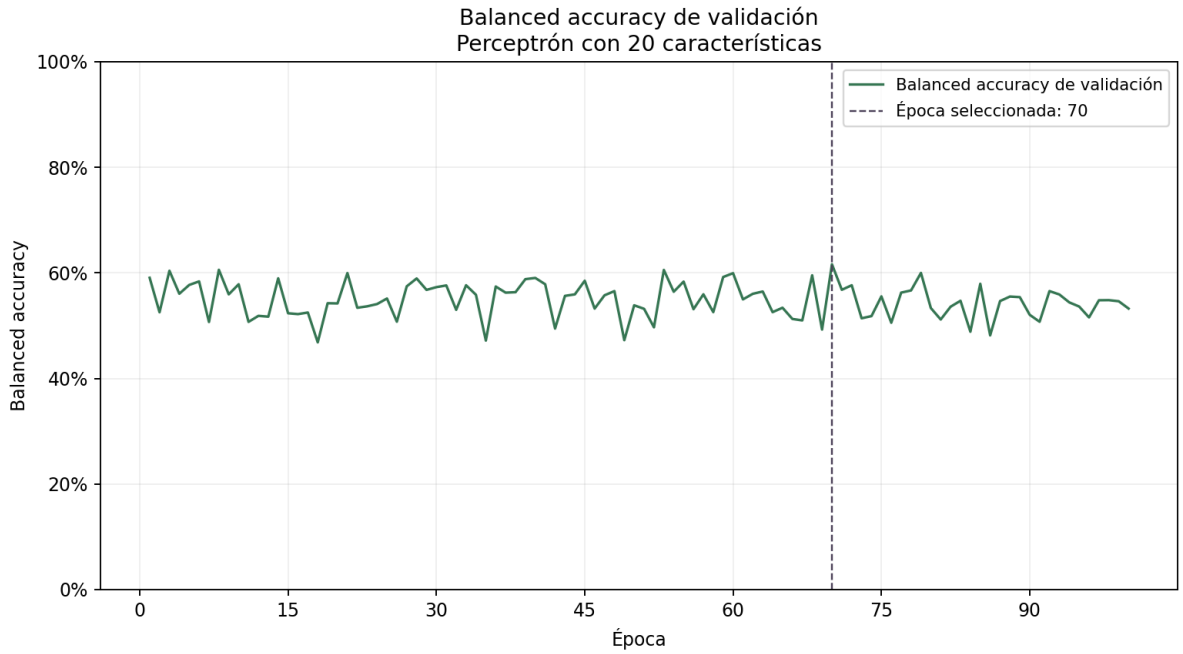


Figura 4: BA de validación por época del perceptrón; la selección responde a la métrica observada en validación, no a cero errores de entrenamiento.

7. Implementación de la regresión logística binaria

El módulo `src/models/logistic_regression.py` implementa sigmoidea estable por ramas, entropía cruzada con `np.logaddexp`, gradientes analíticos y descenso de gradiente por lote completo. La operación matricial $X^\top((p-y)/m)$ evita una suma grande antes de dividir. Se comprueban valores finitos y no se emplean scikit-learn, autodiferenciación ni regularización.

Los gradientes de pesos y sesgo se contrastaron previamente con diferencias centrales en casos moderados y logits extremos, con parámetros no nulos y etiquetas mixtas. La tabla 3 procede del registro original de esas comprobaciones; no se reejecutó el entrenamiento para construirla. La

Tabla 3: Verificación original por diferencias finitas centrales. Todos los casos cumplen tolerancias.

Caso	h	atol	rtol	Error abs. máx.	Error rel. máx.
moderado	1e-06	1e-08	1e-05	6.3527e-11	4.1054e-09
logits_extremos	1e-05	2e-06	1e-05	9.5497e-09	2.0213e-08

prueba utiliza tolerancias absolutas y relativas: cerca de derivadas cero, un error relativo aislado puede ser engañoso. Se verificaron también dimensiones alternativas y estabilidad en las pruebas de implementación. Son comprobaciones del cálculo, no garantías de utilidad predictiva.

Tabla 4: Presupuesto logístico previo: 200 épocas por tasa; checkpoint elegido por BA de validación a umbral 0,5.

Tasa	k elegido	BA val. (%)	Pérdida final train	Gradiente final
0.01	195	58.577	0.648476730	0.094666887
0.05	170	60.605	0.629514103	0.023199269
0.10	200	61.199	0.626953986	0.011097460

Se evaluaron tres tasas, 0,01, 0,05 y 0,1, con 200 épocas cada una, inicialización cero y semilla 42. Al ser lote completo con inicio cero, la semilla no altera la trayectoria de esta ejecución. La tolerancia de parada estuvo desactivada. Se eligieron tasa y checkpoint por BA de validación a umbral 0,5, con desempates por F1, menor época y orden del plan. Después se inspeccionó sobre un único checkpoint la cuadrícula de 19 umbrales entre 0,05 y 0,95; permaneció 0,5. No se buscó el producto cartesiano épocas por umbrales ni se usó test para elegirlos.

El modelo conservado corresponde a tasa 0,1, época 200 y sesgo $b = 0{,}08539078966952132$. La tabla 5 reproduce los pesos con representación decimal suficiente para recuperar el mismo float64. El historial de clasificación usa umbral 0,5, que coincide aquí con el umbral final. La serialización JSON almacena dimensión, nombres, parámetros y checkpoint sin pickle. Compartir fronteras lineales en 20 dimensiones no implica obtener los mismos parámetros: objetivo, recorrido, frecuencia de actualización y selección difieren. El perceptrón corrige errores discretos online, mientras logística optimiza una función suave por lote. Las diferencias finales no se atribuyen a una causa comercial sin evidencia.

Tabla 5: Pesos del modelo congelado logístico. Valores float64 conservados con representación decimal de ida y vuelta.

Índice	Característica estandarizada	Peso
1	`unidades_lag_1`	0.007753842937108124
2	`unidades_lag_2`	0.021919159372678004
3	`unidades_lag_3`	-0.02887438357917642
4	`unidades_media_3`	0.0003849533526338643
5	`unidades_mediana_3`	-0.1550018310751814
6	`unidades_std_3`	0.1603485307302967
7	`cambio_unidades_1`	-0.03239089609332676
8	`variacion_relativa_1`	0.13404048909634628
9	`tendencia_unidades_3`	0.08312368854459541
10	`facturas_lag_1`	-0.11308763440928998
11	`facturas_media_3`	-0.520097786700729
12	`ingresos_lag_1`	-0.037081330837846524
13	`ingresos_media_3`	0.007335190966533872
14	`precio_unitario_ponderado_lag_1`	0.0004866891244691942
15	`clientes_distintos_lag_1`	-0.11718785125889304
16	`unidades_por_factura_lag_1`	0.028211039550568473
17	`antiguedad_observada_meses`	0.16703575165447174
18	`mes_objetivo_sin`	0.24188638442783236
19	`mes_objetivo_cos`	-0.018110885050252778
20	`dias_mes_objetivo`	0.2550458337404401

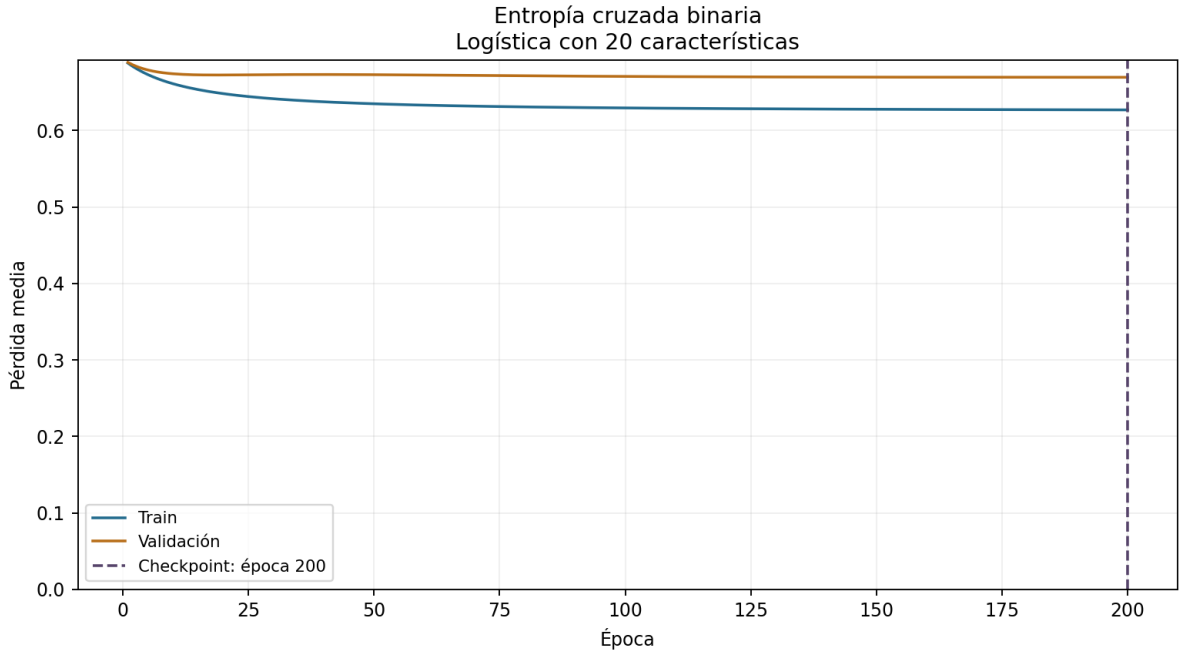


Figura 5: Entropía cruzada de entrenamiento y validación en la ejecución logística seleccionada. La pérdida inicial de ambas particiones es $\log 2$, con parámetros cero.

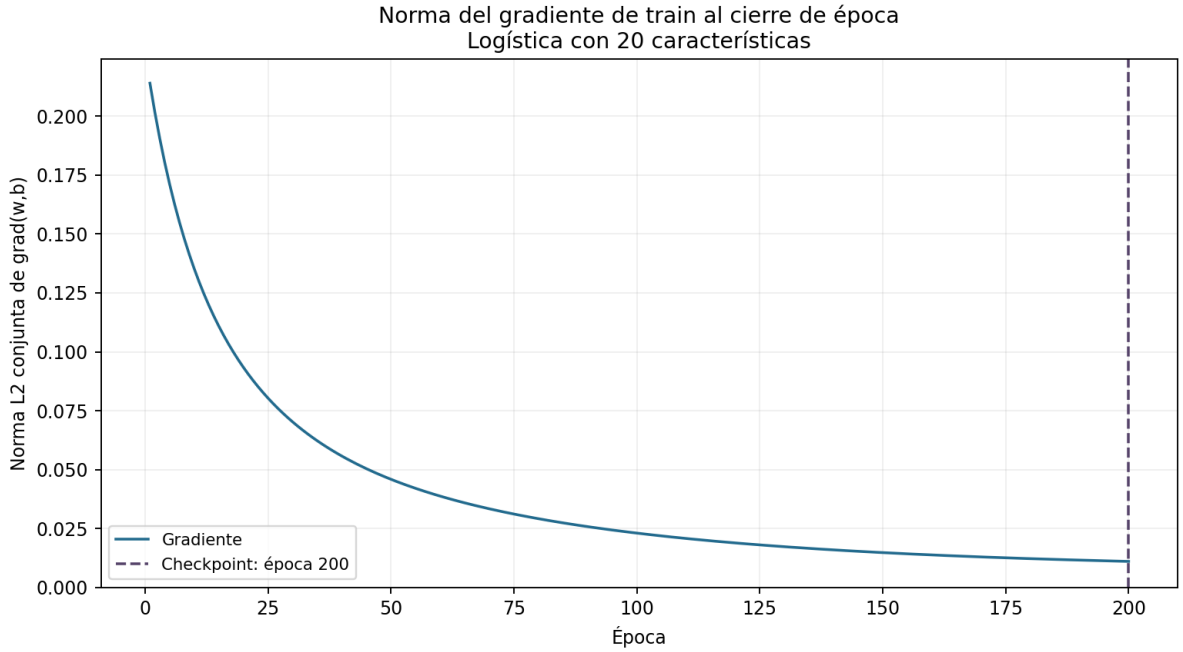


Figura 6: Norma del gradiente logístico registrada después de cada actualización. Incluye derivadas de pesos y sesgo y no se interpreta como error de clasificación.

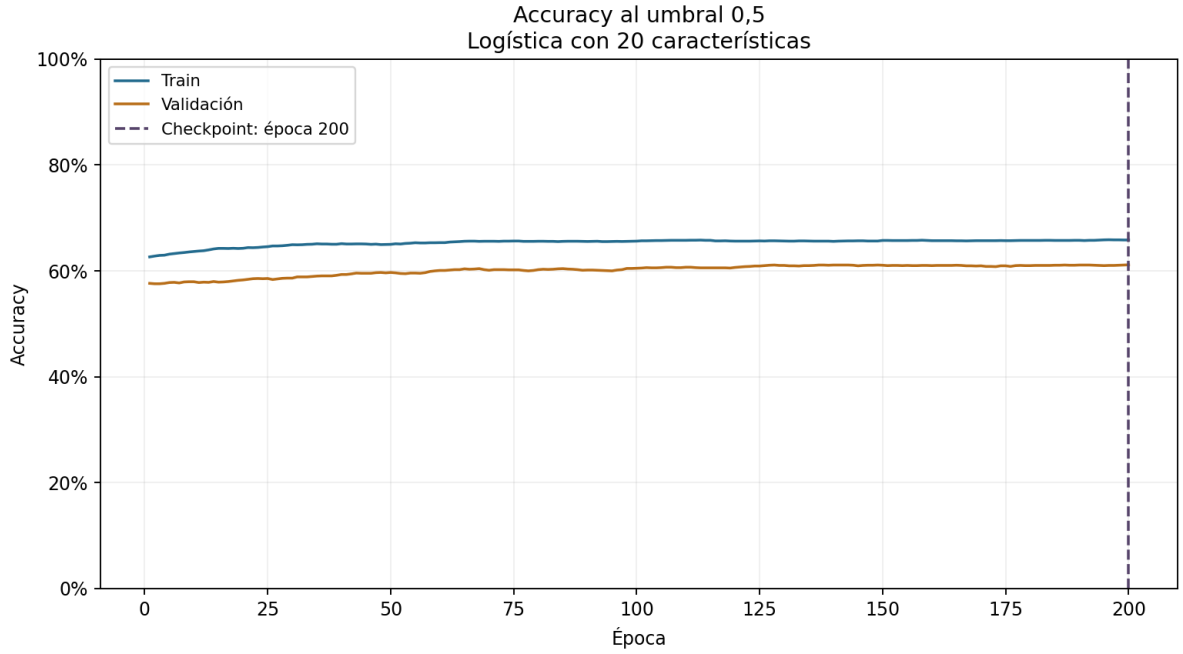


Figura 7: Accuracy train y validación por época a umbral 0,5. La disminución de pérdida no obliga a una mejora monótona de la clasificación discreta.

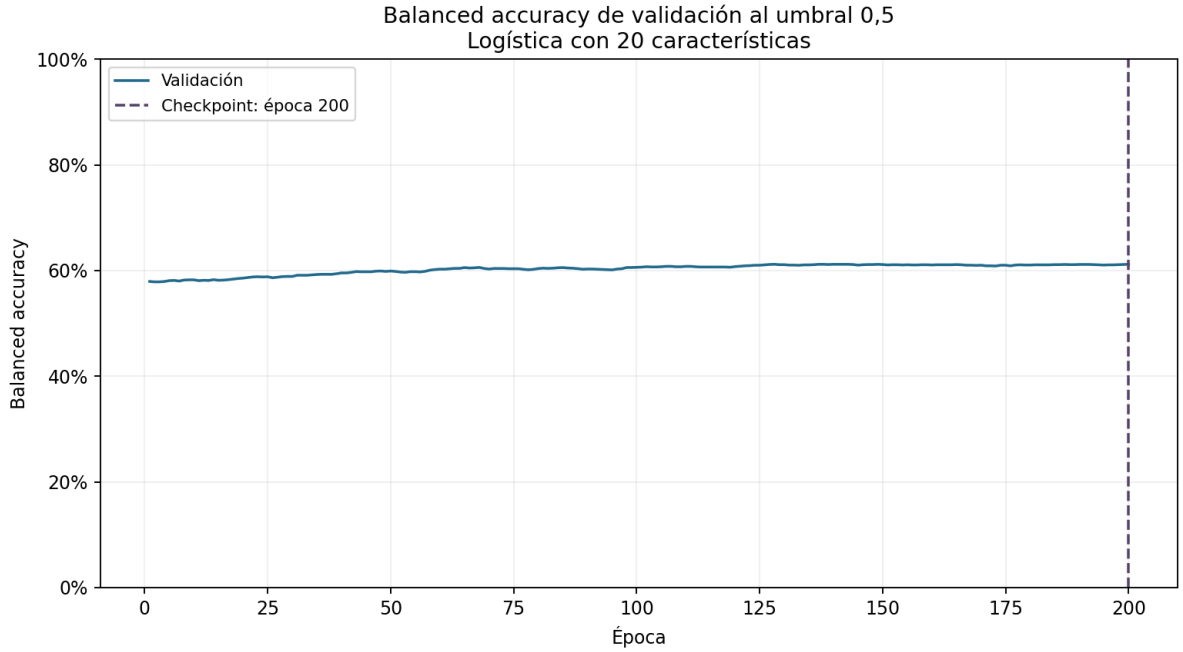


Figura 8: BA de validación por época en la ejecución logística seleccionada. El presupuesto y la selección quedaron fijados antes de la evaluación final.

8. Verificación de convergencia y comportamiento del error

8.1. Evidencia y definición de los diagnósticos

Se analizan exclusivamente los historiales aprobados del recorrido barajado del perceptrón y de la ejecución logística de tasa 0,1. Los CSV por época se conservan íntegros, junto con los cálculos documentales, en `informe/evidencias/`. No se reconstruyen curvas mediante entrenamiento, no se inventan métricas de test por época y no se aplica un criterio de parada nuevo.

Para la logística, con L_0 guardada en el registro del experimento, se calcula para $k = 1, \ldots, 200$:

$$\Delta L_k = L_{k-1} - L_k, \qquad r_k = \frac{|L_k - L_{k-1}|}{\max(1, |L_{k-1}|)}. \tag{13}$$

Como todas las pérdidas previas son menores que 1, $r_k = |\Delta L_k|$ numéricamente en este recorrido. El denominador evita exagerar un cambio relativo cuando la pérdida es pequeña. Estos diagnósticos describen la ejecución; no fueron condiciones efectivas de parada.

8.2. Perceptrón: fluctuaciones sin cese de actualizaciones

Tabla 6: Recorrido seleccionado del perceptrón: errores online y al cierre son magnitudes diferentes.

Época	Online	Actualiz.	Error cierre	Acc. train	Acc. val	BA val	Norma w
1	1973	1973	1695	63.144	59.094	59.067	0.266956
70	1924	1924	1627	64.623	61.720	61.632	0.470391
100	1996	1996	2217	51.794	53.349	53.238	0.439505

Los errores online pasan de 1 973 a 1 996, con mínimo 1 863 y máximo 2 016. En 49 transiciones aumenta su conteo. Ninguna de las 100 épocas presenta cero actualizaciones; la última conserva 1 996. La media de las primeras diez épocas es 1 954,2 errores y la de las últimas diez 1 965,8. No aparece una tendencia de reducción a cero ni un cese de aprendizaje en el presupuesto observado. La norma de pesos es 0,470390802 en el checkpoint y 0,439505108 al finalizar; cambiar de norma no prueba estabilización de la dirección o de las predicciones.

El checkpoint 70 tiene 1 924 errores online, pero 1 627 errores al cierre, porque se evalúan estados diferentes. Su accuracy train es 64,623 % y validación 61,720 %, frente a 51,794 % y 53,349 % en la época 100. La BA de validación cae de 61,632 % en el estado exportado a 53,238 % en el último. Por ello, no deben utilizarse métricas de la última época como si fueran las del modelo final conservado.

El resultado es un recorrido oscilante, sin convergencia a cero errores demostrada. La garantía teórica requiere separabilidad con margen; ni esta se ha demostrado ni su ausencia se deduce únicamente de 100 épocas. Mantener actualizaciones es evidencia de no estabilización de este recorrido, no prueba de un fallo de implementación.

8.3. Logística: descenso estable, límite de épocas

La pérdida inicial train es 0,6931471805599452 y la final es 0,6269539858615067: disminuye 0,06619319469843843, equivalente al 9,549659 % de la inicial. Las 200 diferencias ΔL_k son positivas; no hay aumentos estrictos de pérdida train. El descenso medio por época pasa de 0,003200745231 en las primeras diez a 0,000012942798 en las últimas diez. La pendiente se aplana, pero la pérdida sigue disminuyendo.

En la última época, $\Delta L_{200} = r_{200} = 1,239994026 \times 10^{-5}$. La norma del gradiente pasa de 0,2276084513231957 antes del primer paso a 0,01109745983712376 después del último; no es cero.

Tabla 7: Diagnóstico documental por época. ΔL y r se derivan del historial sin modificar el criterio de parada.

Época	L train	L val	ΔL	r	Norma grad.	BA val (%)
1	0.688123412	0.689090657	0.005024	0.005024	0.2139699	57.943
50	0.634948297	0.672987850	0.0002168	0.0002168	0.0459331	59.918
100	0.629497740	0.670700835	5.422e-05	5.422e-05	0.0230980	60.621
150	0.627772423	0.669767545	2.221e-05	2.221e-05	0.0148239	61.147
200	0.626953986	0.669574543	1.24e-05	1.24e-05	0.0110975	61.199

La norma final de pesos es 0,726685646640. La pérdida de validación pasa de 0,6931471805599452 a 0,6695745428232207, una mejora menor que en entrenamiento. Su diferencia final con train es aproximadamente 0,042620557. El menor valor registrado de validación coincide con la época 200, sin que esto pruebe que épocas posteriores serían mejores.

La tolerancia estaba desactivada (`tolerance=null`); el registro indica `converged_by_tolerance=false`. Se detuvo por máximo de 200 épocas. En este caso, checkpoint y último estado coinciden. La reducción de pérdida y gradiente respalda **descenso estable sin convergencia completa demostrada**; no certifica un óptimo numérico ni un criterio retrospectivo de suficiencia. Las redundancias impiden asumir unicidad del vector de pesos.

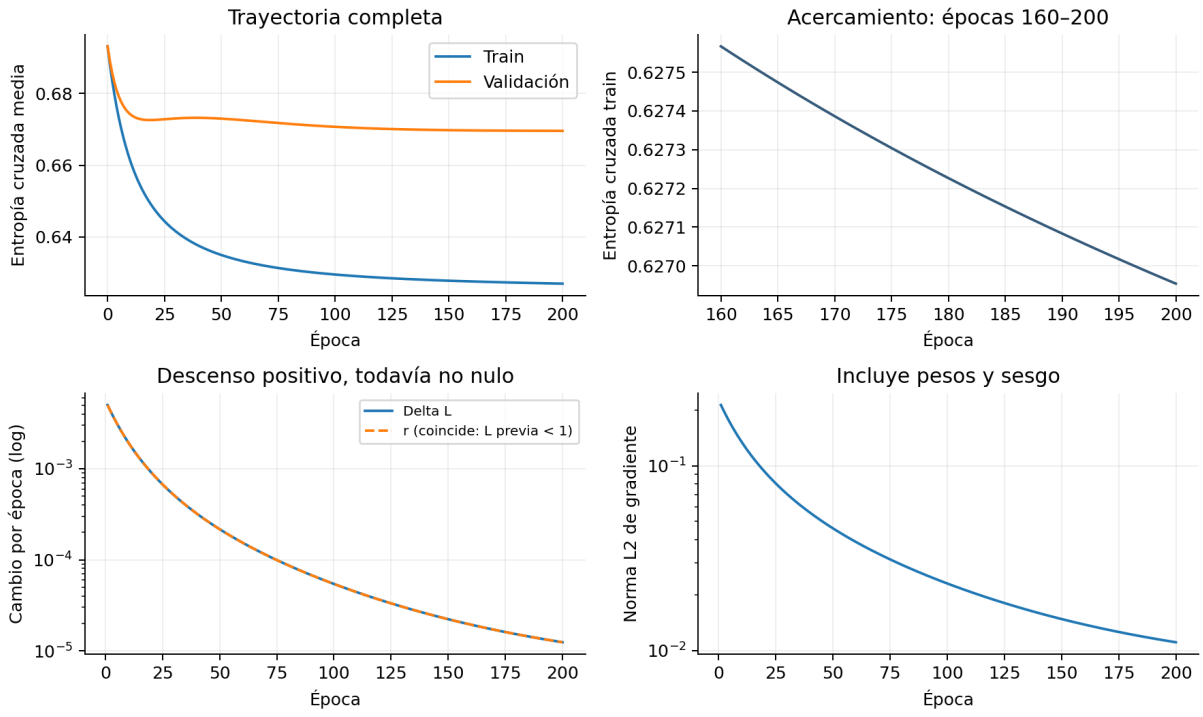


Figura 9: Diagnóstico de la ejecución logística seleccionada: pérdida completa con inicialización real, acercamiento final, cambios por época y norma del gradiente. El eje logarítmico se identifica en los paneles inferiores.

Las curvas permiten distinguir mejora del objetivo continuo y comportamiento de la clasificación. Concluyen sobre las ejecuciones conservadas, sin extender el presupuesto ni modificar tasas o modelos después de observar test.

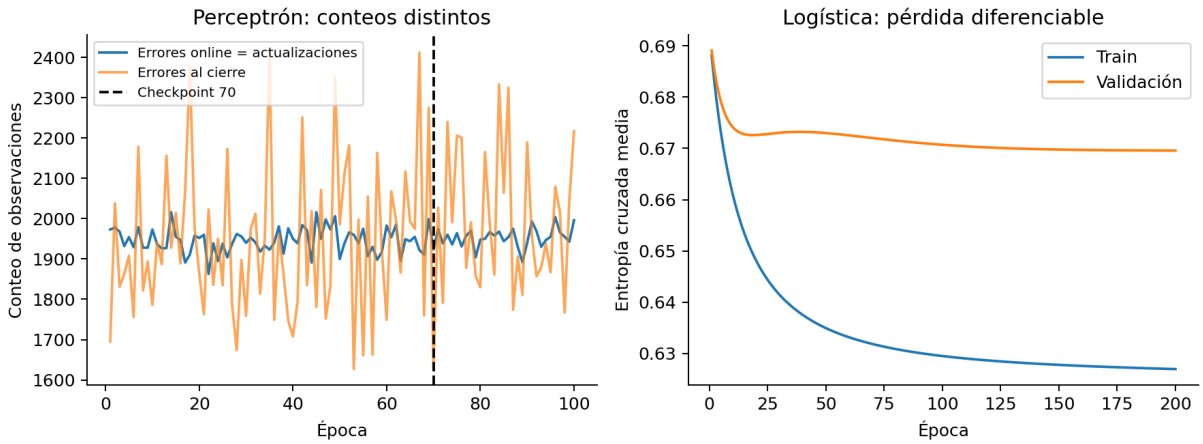


Figura 10: Comparación con ejes separados: errores online y al cierre del perceptrón (conteos) frente a entropía cruzada logística (pérdida media). No son magnitudes equivalentes.

9. Reducción dimensional para visualización

La transformación PCA aprobada se ajustó con las 4 599 filas de entrenamiento y se aplicó a las 2 628 de validación, usando el mismo centrado. Las etiquetas solo colorean los puntos; no entran en el ajuste SVD. No se ajustó PCA con test ni se utilizaron las coordenadas bidimensionales para entrenar los clasificadores.

PC1 explica 32,987763 % y PC2 16,630823 %; juntas conservan 49,618586 %, por lo que 50,381414 % no se representa en el plano. La varianza total de entrenamiento es 20,0043497173 con $ddof = 1$ y el rango numérico es 17. El rango menor que 20 es compatible con redundancias de las variables históricas; no impide conservar las dos primeras direcciones.

Tabla 8: Cinco mayores coeficientes por magnitud en cada componente. El cuadrado es participación en la norma del vector, no importancia predictiva.

Comp.	Característica	Coeficiente	Cuadrado (%)
PC1	unidades_media_3	0.386556480	14.943
PC1	unidades_mediana_3	0.384643640	14.795
PC1	unidades_lag_1	0.379973488	14.438
PC1	unidades_por_factura_lag_1	0.377059706	14.217
PC1	unidades_lag_2	0.371108446	13.772
PC2	facturas_lag_1	0.494616346	24.465
PC2	clientes_distintos_lag_1	0.492434743	24.249
PC2	variacion_relativa_1	0.367933782	13.538
PC2	cambio_unidades_1	0.345813511	11.959
PC2	tendencia_unidades_3	0.300490423	9.029

PC1 combina principalmente nivel histórico de unidades, con coeficientes positivos grandes en media, mediana, lags y unidades por factura. PC2 combina frecuencia comercial (facturas y clientes distintos) y cambios recientes de unidades. La convención de signo hace positivo el coeficiente de mayor magnitud: invertir un vector no modifica la varianza ni aporta una clase nueva. Los coeficientes negativos menores de PC2 incluyen unidades de los retardos segundo y tercero; su lectura es algebraica, no causal.

Las clases se solapan visualmente. La pérdida de más de la mitad de la varianza limita cualquier inferencia sobre separabilidad en las 20 entradas. PCA no es un clasificador; el solapamiento no demuestra la causa del rendimiento ni invalida una señal fuera del plano. Ninguna línea bidimensional se presenta como frontera exacta de los modelos multidimensionales.

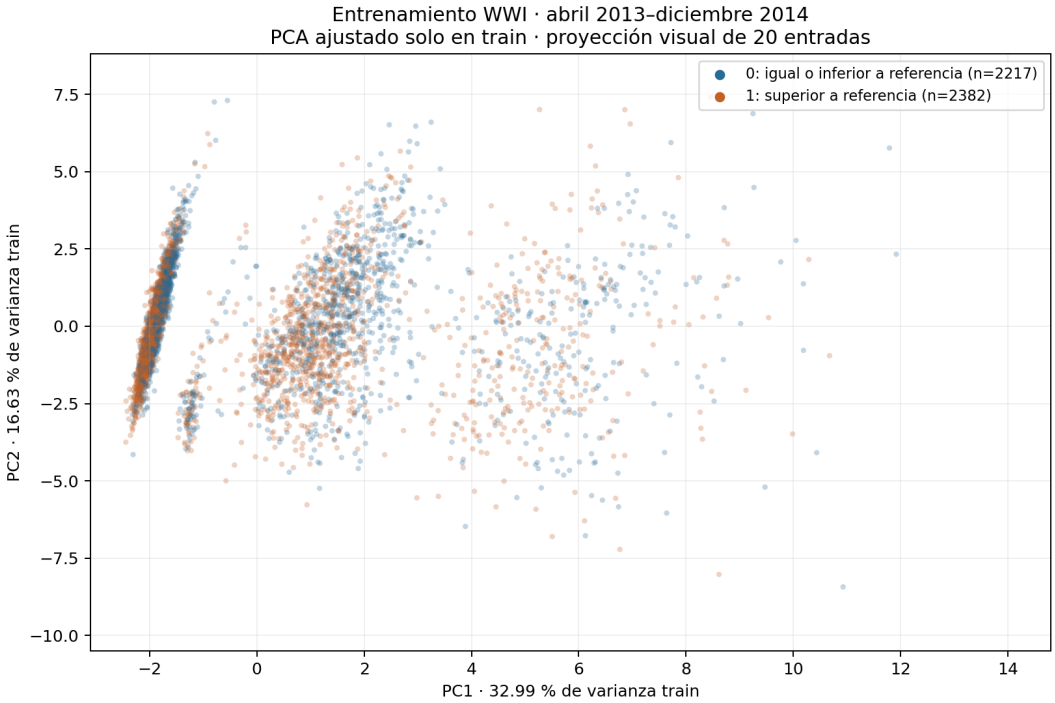


Figura 11: Proyección PCA de entrenamiento, coloreada por etiqueta real. Todos los puntos proceden del artefacto aprobado, sin selección ni desplazamiento artificial.

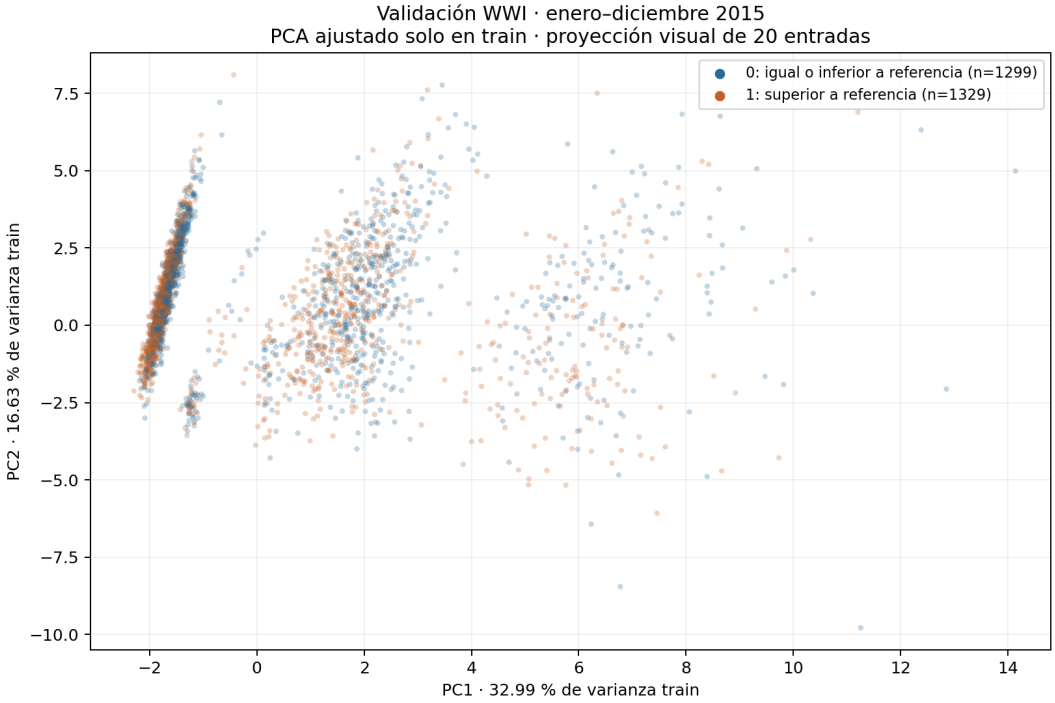


Figura 12: Validación proyectada con media y componentes de entrenamiento. Se conserva la escala de ejes utilizada en la visualización aprobada.

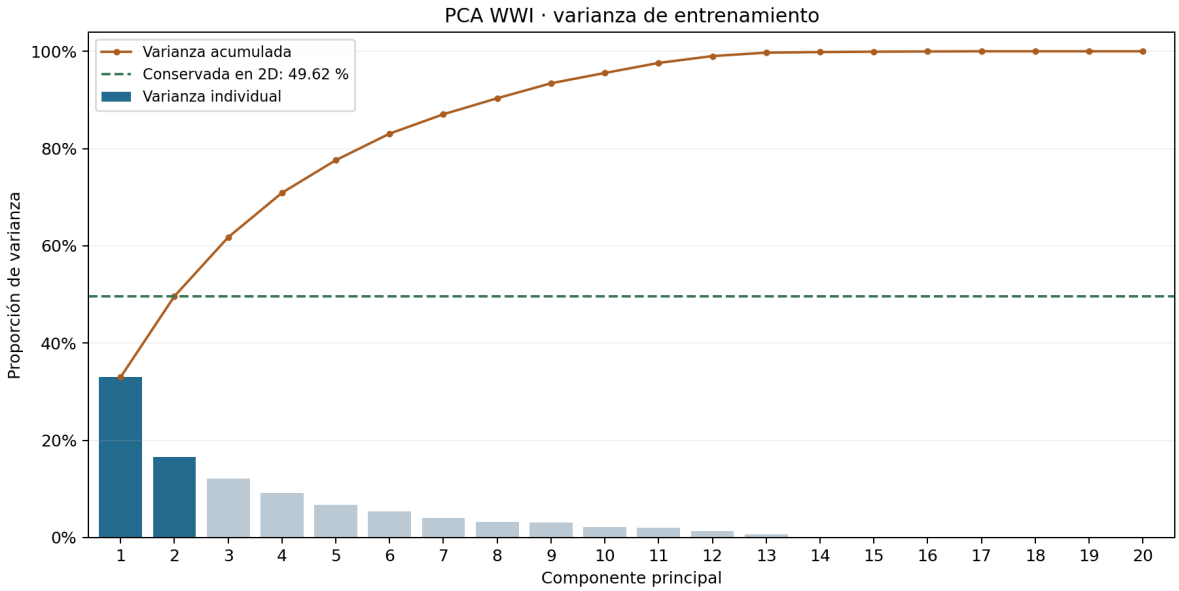


Figura 13: Varianza individual y acumulada de los componentes obtenidos de entrenamiento. El denominador incluye las 20 direcciones.

10. Resultados experimentales

10.1. Comparación común de entrenamiento, validación y prueba

Las métricas de la tabla 9 proceden de los estados exportados, no de una ejecución nueva. La evaluación final contiene exactamente 1 111 observaciones de enero a mayo de 2016: 558 negativas y 553 positivas. La alineación de identificadores, productos, meses y etiquetas fue comprobada contra los metadatos aprobados; las matrices y métricas se reproducen desde las predicciones existentes. La logística tiene la mayor BA global observada: 62,415 %, 8,311 puntos sobre el

Tabla 9: Métricas finales por partición (%). Estados seleccionados en validación; no corresponden a la última época del perceptrón.

Método	Conjunto	Acc.	Prec.	Recall	Espec.	F1	BA
Perceptrón	Train	64.623	66.815	62.972	66.396	64.837	64.684
Perceptrón	Validación	61.720	60.632	69.300	53.965	64.677	61.632
Perceptrón	Test	53.915	52.008	96.022	12.186	67.471	54.104
Logística	Train	65.840	66.544	68.472	63.013	67.494	65.742
Logística	Validación	61.149	62.812	56.810	65.589	59.660	61.199
Logística	Test	62.286	57.666	91.139	33.692	70.638	62.415
Mayoritario	Train	51.794	51.794	100.000	0.000	68.242	50.000
Mayoritario	Validación	50.571	50.571	100.000	0.000	67.172	50.000
Mayoritario	Test	49.775	49.775	100.000	0.000	66.466	50.000
Histórico	Train	49.272	51.540	34.425	65.223	41.279	49.824
Histórico	Validación	49.049	49.453	34.011	64.434	40.303	49.222
Histórico	Test	51.395	51.884	32.369	70.251	39.866	51.310

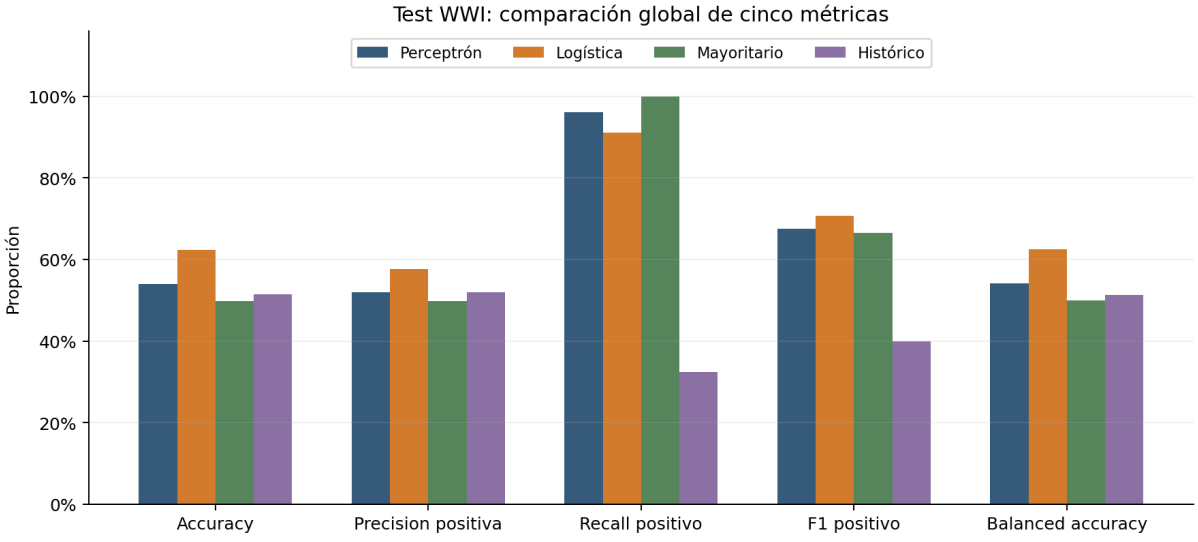


Figura 14: Métricas globales de test sobre los mismos casos. Todas son proporciones o porcentajes según la escala rotulada; ninguna mide beneficio económico.

perceptrón, 12,415 sobre mayoritario y 11,106 sobre histórico. El perceptrón supera esos baselines en 4,104 y 2,794 puntos de BA. Son diferencias descriptivas de la reserva final, sin prueba de superioridad universal ni significación estadística.

El baseline mayoritario alcanza recall 100 % sin reconocer un solo negativo. Esto demuestra por qué accuracy o sensibilidad aisladas no resumen el equilibrio entre clases. El histórico obtiene

especificidad 70,251 %, pero recall 32,369 %, y BA cercana a 50 %.

10.2. Matrices de confusión, sensibilidad y exceso de positivos

Tabla 10: Conteos de test y tasas de error (%). Filas reales y columnas predichas en orden 0,1.

Método	TN	FP	FN	TP	FPR	FNR	Pred. 1
Perceptrón	68	490	22	531	87.814	3.978	1021
Logística	188	370	49	504	66.308	8.861	874
Mayoritario	0	558	0	553	100.000	0.000	1111
Histórico	392	166	374	179	29.749	67.631	345

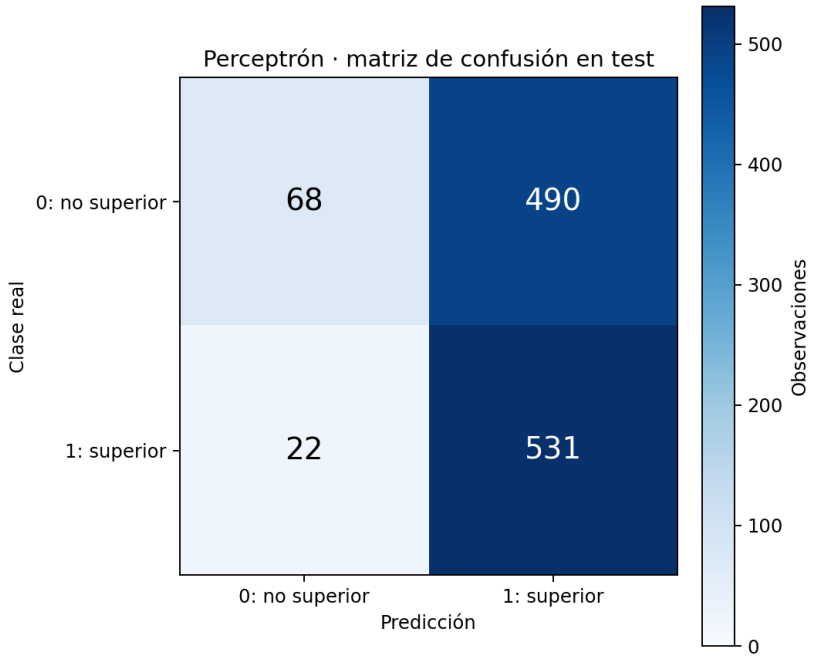


Figura 15: Matriz de confusión de test del perceptrón. Filas: etiqueta real; columnas: clase predicha. La elevada sensibilidad coexiste con 490 falsos positivos.

El perceptrón predice 1 en 1 021 casos (91,899 %) y logística en 874 (78,668 %), frente a 553 positivos reales (49,775 %). Su exceso es de 42,124 y 28,893 puntos porcentuales, respectivamente. Predecir positivo frecuentemente captura muchos positivos reales, pero también eleva FP. La precisión positiva es solo 52,008 % en perceptrón y 57,666 % en logística. F1 positivo no garantiza reconocimiento de la clase negativa.

La logística reconoce 120 negativos adicionales frente al perceptrón, con 27 positivos reconocidos menos. Así disminuye 93 errores totales y mejora BA, calculada con denominadores específicos de cada clase. Esta explicación aritmética no establece una causa empresarial de la diferencia.

10.3. Generalización temporal y error por partición

La BA test menos validación cambia $-7,528$ puntos en perceptrón y $+1,216$ en logística. El aumento global de logística no acredita estabilidad en cada mes. Las proporciones positivas reales son 51,794 % en train, 50,571 % en validación y 49,775 % en test, mientras las predicciones positivas del perceptrón pasan de 48,815 % a 57,801 % y 91,899 %; las de logística, de 53,294 % a 45,738 % y 78,668 %. Hay un cambio descriptivo marcado en las decisiones, con prevalencia

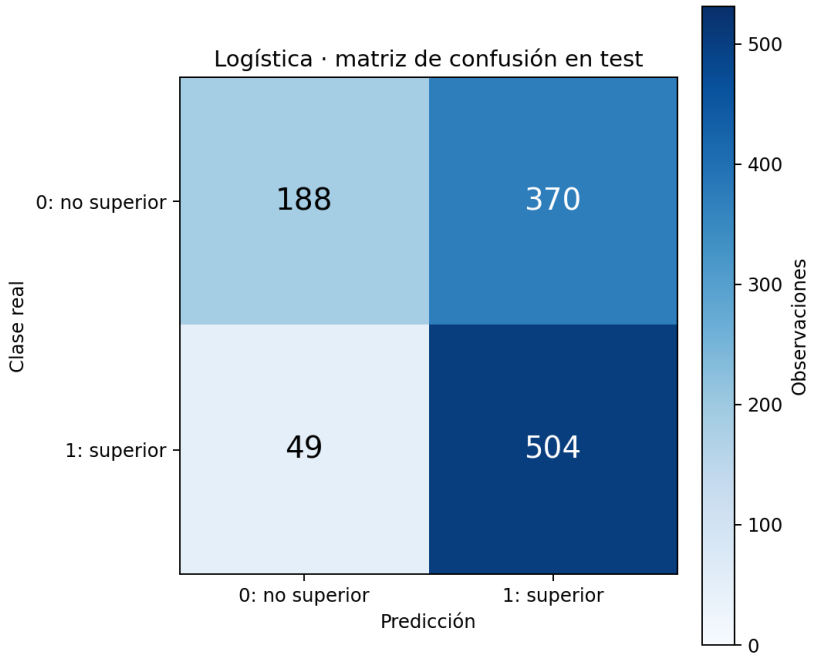


Figura 16: Matriz de confusión de test de logística con umbral congelado 0,5. Reconoce 188 negativos y 504 positivos, con 370 FP y 49 FN.

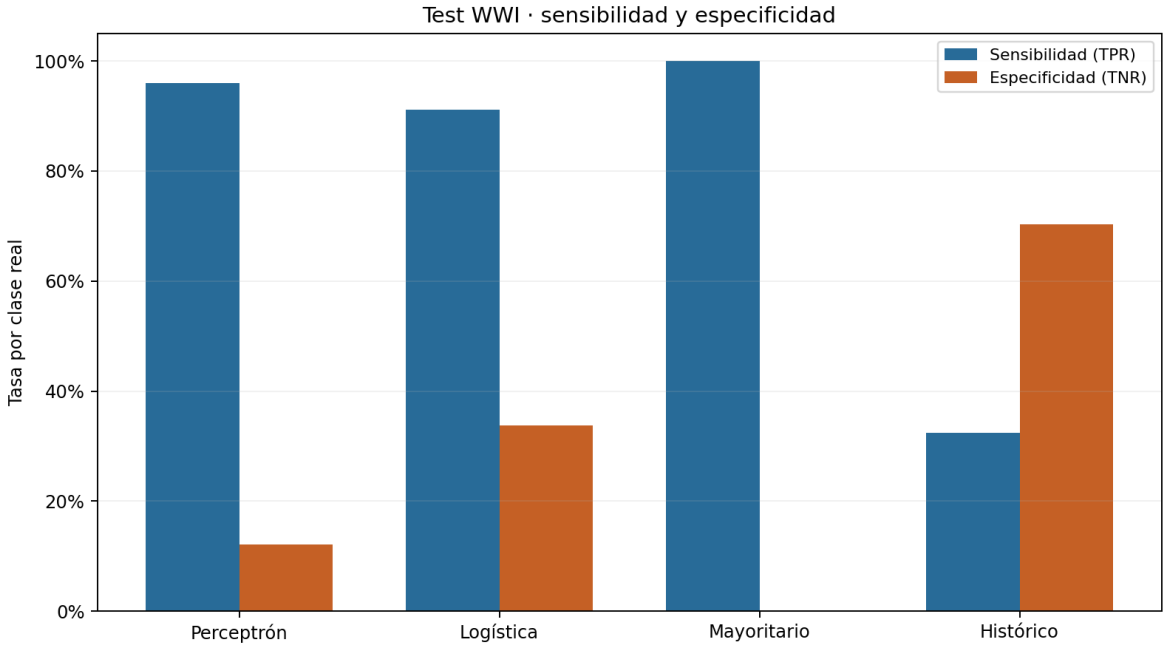


Figura 17: Sensibilidad y especificidad de los cuatro métodos en test. Logística mejora el reconocimiento negativo frente al perceptrón, pero conserva especificidad limitada.

global relativamente próxima. En logística, la especificidad desciende de 64,516 % en febrero a

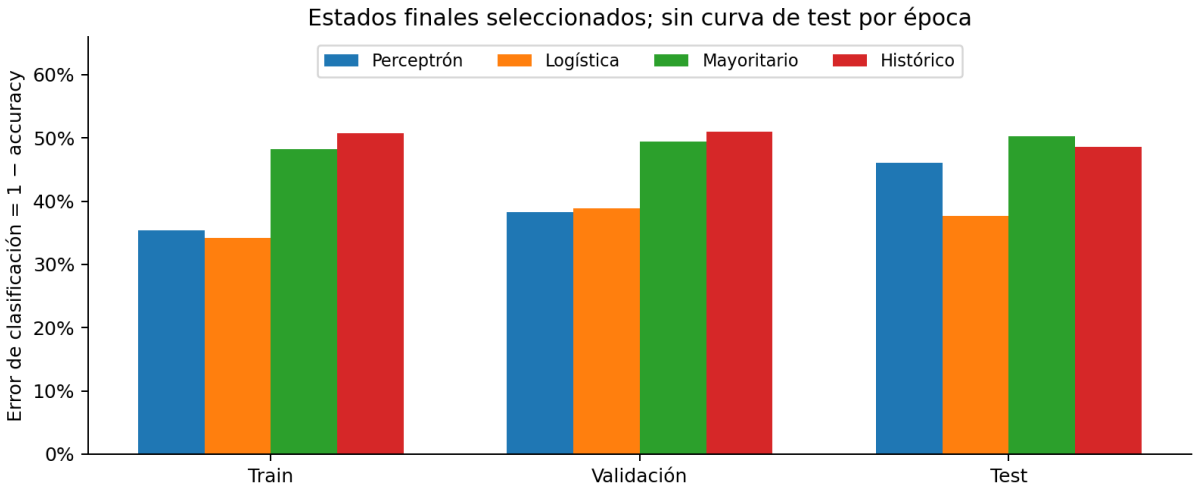


Figura 18: Error de clasificación final, definido como $1-\text{Accuracy}$, por método y partición. No es pérdida logística ni conteo de actualizaciones. No existe una curva de test por época.

Tabla 11: Todos los meses de test. Tasas en %; soporte negativo/positivo.

Mes	0/1	BA perc.	BA log.	Prec. log.	Recall log.	Espec. log.
2016-01	125/94	55.740	63.753	52.632	85.106	42.400
2016-02	155/64	54.667	65.071	43.299	65.625	64.516
2016-03	81/138	51.235	56.065	66.019	98.551	13.580
2016-04	107/120	51.238	56.012	56.281	93.333	18.692
2016-05	90/137	52.620	51.127	60.909	97.810	4.444

4,444 % en mayo, mientras el recall de mayo es 97,810 %. Su BA mensual cae hasta 51,127 %. El perceptrón supera a logística en BA de mayo (52,620 %), a pesar de la ventaja global de esta última. El desempeño cambia con el período y no se resume correctamente con una declaración universal de superioridad.

10.3.1. Por qué BA global y promedio mensual difieren

Si $P_t = TP_t + FN_t$ y $N_t = TN_t + FP_t$, al agrupar los conteos se obtiene

$$TPR_G = \sum_t \frac{P_t}{\sum_s P_s} TPR_t, \qquad TNR_G = \sum_t \frac{N_t}{\sum_s N_s} TNR_t, \tag{14}$$

$$BA_G = \tfrac{1}{2}(TPR_G + TNR_G), \qquad BA_M = \frac{1}{5}\sum_t BA_t. \tag{15}$$

Por tanto,

$$BA_G - BA_M = \frac{1}{2}\sum_t \left[\left(\frac{P_t}{\sum_s P_s} - \frac{1}{5}\right) TPR_t + \left(\frac{N_t}{\sum_s N_s} - \frac{1}{5}\right) TNR_t\right]. \tag{16}$$

Los pesos son distintos para positivos y negativos; no basta ponderar cada BA mensual por el total de filas. En logística, los soportes positivos mensuales son 94, 64, 138, 120 y 137; los negativos son 125, 155, 81, 107 y 90. La agrupación produce recall 0,911392405 y especificidad 0,336917563. De ellos resulta BA 62,415 %, frente a 58,406 % del promedio mensual sin ponderar.

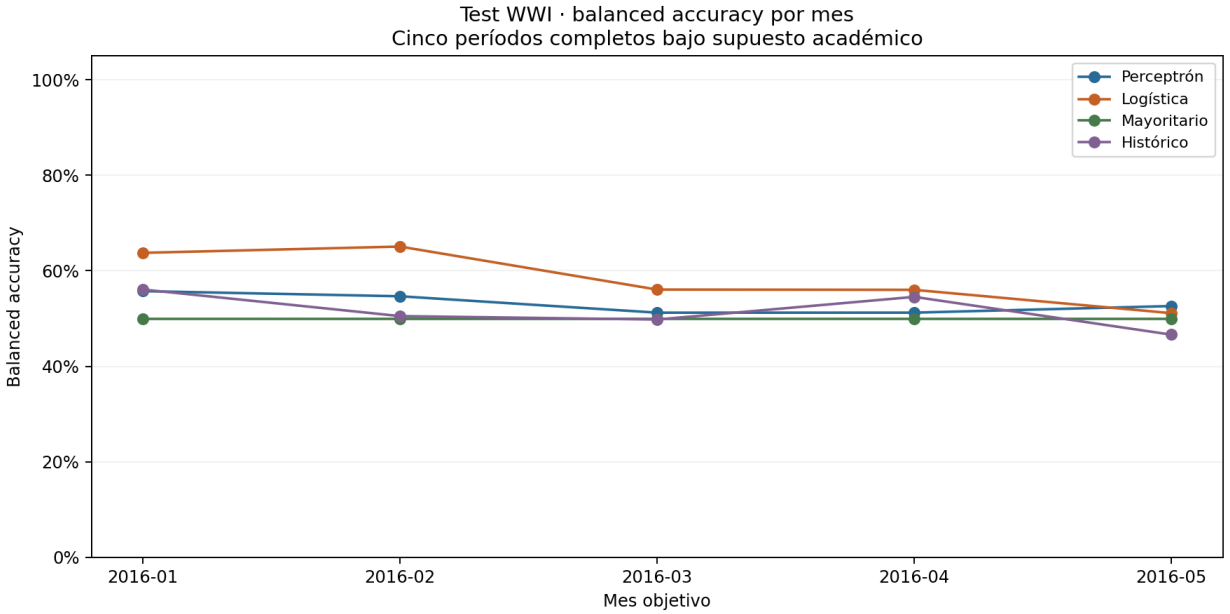


Figura 19: BA de los cuatro métodos en todos los meses de test. No se excluyen meses difíciles ni se selecciona un subperíodo por rendimiento.

La diferencia de 4,009691 puntos se verifica con tolerancia 10^{-12} en puntos porcentuales, utilizando las contribuciones por mes registradas en el análisis temporal. No es una contradicción ni un error de cálculo.

10.4. Productos conocidos y nuevos

Tabla 12: Comparación de cohortes en test, sin excluir los productos nuevos.

Cohorte	Método	N	0/1	TN	FP	FN	TP	BA (%)
conocidos	Perceptrón	1095	552/543	62	490	14	529	54.327
conocidos	Logística	1095	552/543	184	368	46	497	62.431
conocidos	Mayoritario	1095	552/543	0	552	0	543	50.000
conocidos	Histórico	1095	552/543	389	163	367	176	51.442
nuevos	Perceptrón	16	6/10	6	0	8	2	60.000
nuevos	Logística	16	6/10	4	2	3	7	68.333
nuevos	Mayoritario	16	6/10	0	6	0	10	50.000
nuevos	Histórico	16	6/10	3	3	7	3	40.000

Se consideran conocidos los nombres presentes en train, según la regla congelada. En test hay 219 conocidos con 1 095 filas y ocho nuevos con 16 filas de abril y mayo. Se conservan todos en el global. Entre los nuevos, el perceptrón tiene precision 100 % sobre solo dos positivos predichos, pero omite ocho de diez positivos reales. Logística reconoce siete de diez positivos y cuatro de seis negativos. Los conteos son insuficientes para sostener estabilidad de porcentajes o una ventaja extrapolable a nuevos catálogos.

10.5. Concordancias y desacuerdos

Ambos modelos aciertan 554 casos y ambos fallan 374; solo perceptrón acierta 45 y solo logística 138. Las cuatro categorías son excluyentes y suman 1 111. Coinciden en 928 decisiones y discrepan en 183: acuerdo no equivale a acierto. Los 93 aciertos exclusivos netos de logística explican la

diferencia de accuracy. Las agrupaciones por mes y cohorte están disponibles en el archivo de acuerdos; no se usaron para construir un clasificador combinado.

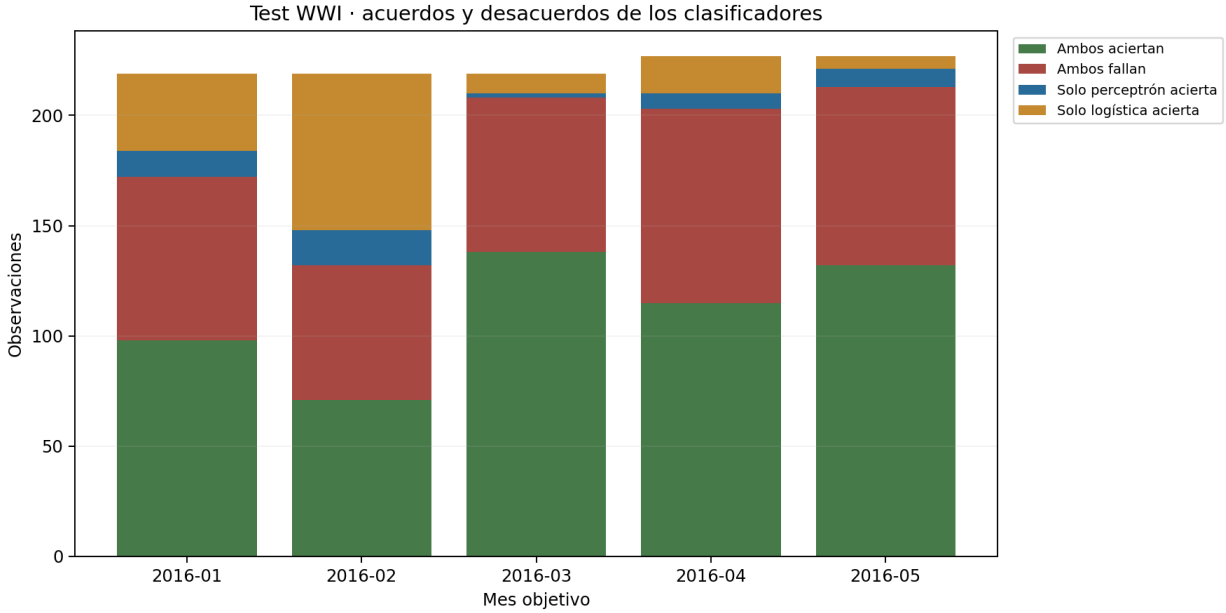


Figura 20: Descomposición de aciertos y errores compartidos y exclusivos por mes. Las categorías conservan los conteos de las mismas predicciones alineadas; los detalles por cohorte están en el archivo estructurado.

11. Comparación estadística y cambios de distribución

11.1. Distribuciones observadas frente a hipótesis de cambio

El análisis descriptivo conserva medias, desviaciones y cuantiles 5/25/50/75/95 de las 20 entradas transformadas en cada partición, sin ajustar un nuevo escalador. Las mayores diferencias de media test menos train, medidas en desviaciones de train, corresponden a antigüedad observada (+4,046562), seno del mes (+0,992743) y coseno (+0,700490). Facturas medias de tres meses cambia +0,485939. La figura 21 muestra el conjunto completo de columnas. La antigüedad cre-

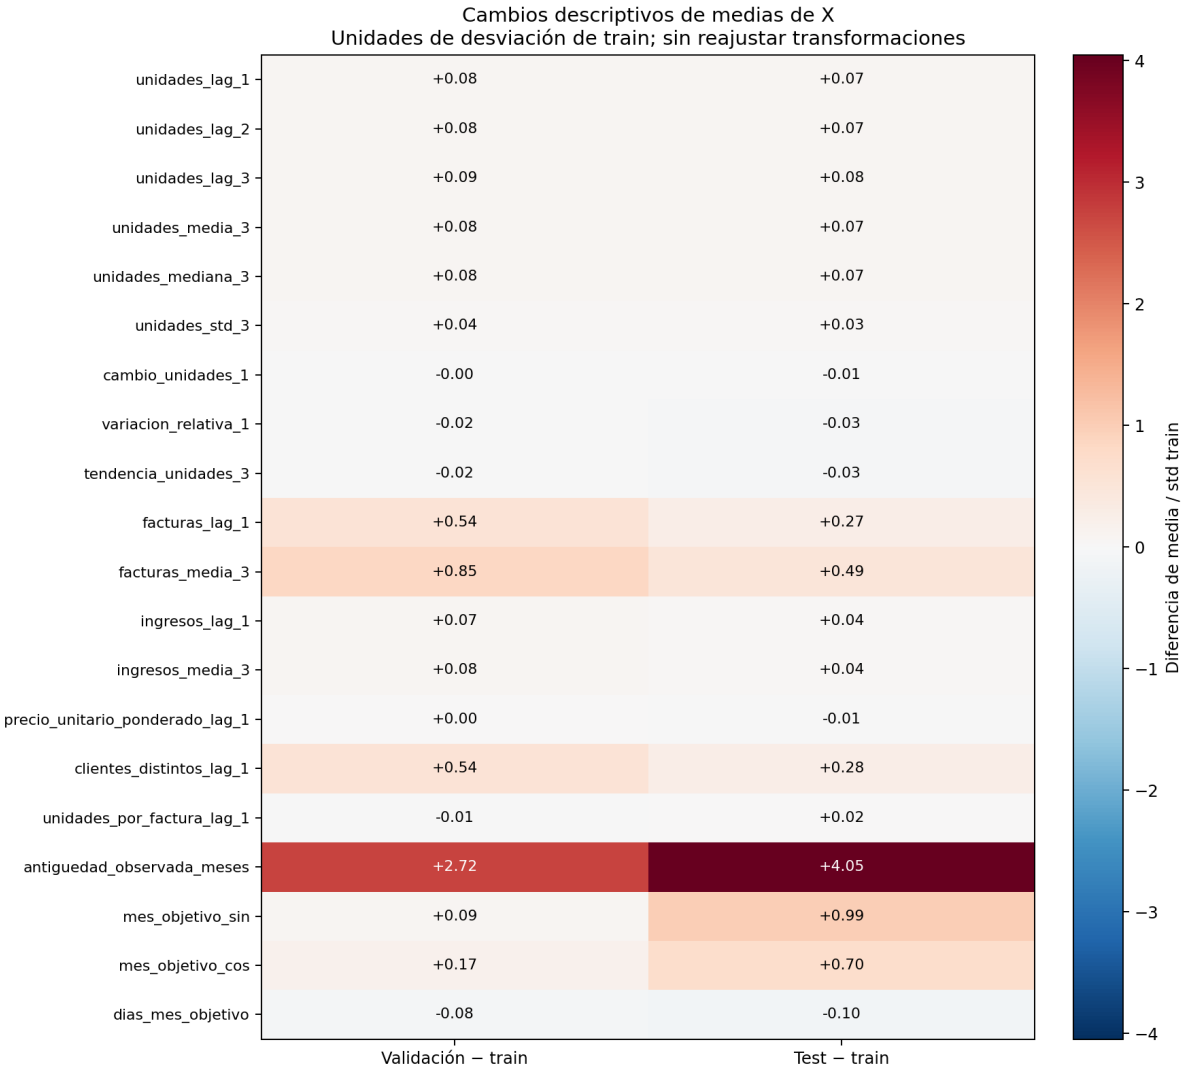


Figura 21: Cambios descriptivos de media en las 20 entradas existentes respecto a train, expresados en su desviación de entrenamiento. No son parámetros de una transformación nueva ni pruebas de deriva de concepto.

ce por definición del tiempo: los productos conocidos tienen entre 36 y 40 meses observados en test, frente a tres o cuatro en los nuevos. Además, test contiene enero–mayo, validación un año completo y train 21 meses objetivo: las mezclas del calendario no son idénticas. La mediana de unidades del mes previo en test es 192 entre conocidos y 3 336 entre nuevos, señal de escalas comerciales diferentes. Los resúmenes de historia mensual se conservan en el artefacto descriptivo, sin reinterpretar ausencia de una línea como falta de demanda.

Estos hallazgos prueban cambios descriptivos de X y mezcla de población, pero no demuestran un cambio de $P(y \mid X)$ o *concept drift*. Posibles explicaciones incluyen extrapolación temporal del

modelo lineal, comportamiento comercial variable, cobertura incompleta o identidad provisional; son hipótesis que los CSV no permiten discriminar causalmente. No se modifican características tras observarlas.

11.2. Incertidumbre y dependencia

Las 1 111 filas no son réplicas independientes. Se repiten productos, se solapan ventanas de historia y productos distintos comparten condiciones de un mismo mes. Solo hay cinco bloques temporales de test. No se utilizan intervalos iid, bootstrap de líneas de factura, p-valores ni declaraciones de superioridad estadística universal.

El análisis exploratorio omite sistemáticamente cada mes completo por turno y vuelve a agregar las mismas predicciones de los cuatro restantes. La BA logística resultante varía de 58,157 % a 64,129 %. Ese rango no es un intervalo de confianza, no corrige toda dependencia temporal y no reemplaza la evaluación oficial de los cinco meses. Se conservan todas las omisiones, sin elegir la favorable. La evidencia permite describir sensibilidad al período observado, no estimar de forma fiable la distribución de rendimiento futuro.

12. Interpretación para Inteligencia de Negocios

La mejor comparación global observada corresponde a logística, que también mejora BA y especificidad respecto al perceptrón. No obstante, 370 falsos positivos pueden generar revisiones comerciales innecesarias; los 49 falsos negativos pueden omitir meses superiores a la mediana reciente. No se traduce un FP automáticamente en sobrestock ni se inventan costos de revisión o ventas perdidas. El histórico reconoce más negativos, pero omite 374 positivos, por lo que tampoco es una solución comercial suficiente.

La utilidad de una alerta depende de la acción, su costo, la capacidad de revisión y el valor de detectar una subida relativa. Esos datos no están registrados. La comparación actual debe servir para comprender una primera aplicación académica y diseñar una validación operacional independiente, no para afirmar retorno de inversión.

Se requieren claves operativas y catálogos vigentes, unidades y empaques consistentes, cierres e ingestiones verificables, promociones y precios planificados, inventarios, faltantes de stock y demanda no atendida. También hacen falta acciones registradas y costos FP/FN validados por el negocio. La extracción de ventas observadas no sustituye esa información.

13. Limitaciones y decisiones pendientes

La identidad por nombre no prueba continuidad de producto y la cobertura al cierre es académica, no certificada. La respuesta mide facturación observada y un cambio relativo que puede ser pequeño; no incorpora relevancia económica ni disponibilidad de inventario. Las probabilidades logísticas no cuentan con calibración validada. La selección de tasa, checkpoint y umbral en una misma validación introduce optimismo en las métricas de desarrollo.

Las fronteras lineales pueden no representar todas las interacciones, pero el análisis no demuestra que esa limitación sea la causa del resultado. El presupuesto de épocas es finito y no certifica convergencia completa; PCA pierde 50,38 % de varianza en 2D. Cinco meses de test y 16 filas de productos nuevos restringen generalización e inferencia estadística. No se reutiliza la reserva consumida para mejorar las cifras.

En identificación académica, los informes previos coinciden en autores, asignatura, nivel y paralelo, pero sus fechas no permiten fijar inequívocamente el ciclo de esta entrega. La portada

deja ciclo y fecha pendientes; la forma del nombre y grado del docente sigue la solicitud actual. Las referencias locales no declaran con certeza una autoría bibliográfica individual para todos sus textos; se citan como documentos académicos del proyecto, sin inventar metadatos.

14. Conclusiones parciales del Data Mart de Ventas

La preparación temporal y los artefactos alineados permiten una comparación reproducible de dos modelos propios y dos baselines. El uso común de 20 entradas y particiones cronológicas evita atribuir diferencias a cambios de muestra o de representación entre clasificadores. Las etiquetas significan exclusivamente superar la mediana de tres meses del propio producto.

La regresión logística obtiene la mayor BA de test (62,42 %), con mejora observada frente a perceptrón y baselines. Su elevada tasa de falsos positivos y variación mensual impiden recomendar decisiones automáticas inmediatas. La BA global supera su promedio mensual por ponderaciones diferentes de clases, comprobadas algebraicamente, sin contradicción entre ambas cifras.

El perceptrón no deja de actualizarse y sus errores fluctúan; el checkpoint 70 debe distinguirse del último estado. La logística reduce monótonamente la entropía cruzada y el gradiente, pero termina por el máximo de épocas y mantiene gradiente no nulo. La conclusión verificable es descenso estable sin convergencia completa demostrada. La proyección PCA aporta una vista exploratoria, sin explicar causalmente el rendimiento ni sustituir los modelos de 20 dimensiones.

Estas conclusiones parciales se circunscriben a Ventas y se conservan al añadir la aplicación financiera de la sección 15. **La ampliación a los procesos aún no implementados sigue siendo obligatoria**. Cada uno requiere verificar modelo dimensional y disponibilidad, formular una respuesta propia, fijar cortes y transformaciones y ejecutar una evaluación independiente. La incorporación de Transacciones no convierte los estudios de viabilidad de Pedidos o Compras en modelos entrenados, ni cierra las obligaciones pendientes de Inventario/Movimientos.

15. Clasificación de la frecuencia de cobros en Transacciones Financieras

15.1. Problema empresarial, eventos e identidad

La segunda aplicación reutiliza los fundamentos de la sección de modelos lineales para una pregunta distinta: al inicio de un mes, ¿puede anticiparse que una cuenta registre más cobros que su referencia reciente? La finalidad académica es estudiar frecuencia de eventos y carga potencial de conciliación, no morosidad, liquidez, ingresos monetarios, saldo pendiente ni unidades vendidas. No se asigna un beneficio económico automático a una predicción positiva.

Una fila de `Fact.Transaction` representa una transacción operacional de cliente o proveedor. El catálogo diferencia facturas de cliente (tipo 1), cobros recibidos (tipo 3), facturas de proveedor (tipo 5) y pagos emitidos (tipo 7); estos son los tipos observados en desarrollo. Notas de crédito, devoluciones y otros tipos del catálogo no se mezclan con cobros. Una factura registra una obligación: no demuestra un pago efectivo. El signo negativo del tipo 3 reduce cuentas por cobrar y corresponde a una entrada registrada; el mismo signo en tipo 7 reduce cuentas por pagar y corresponde a una salida registrada. El signo sin dominio y tipo no determina ingreso o egreso.

La fuente elegida es `Sales.CustomerTransactions`. El evento se identifica mediante `CustomerTransactionID`. Se cuentan solo eventos tipo 3 *Customer Payment Received*, cuya convención contable fue verificada. La identidad de cuenta es `CustomerID` operacional, correspondiente al pagador *Bill To*, no necesariamente al destinatario de una factura. La unión por ID de evento con DW permitió recuperar cuentas aun cuando su clave dimensional era el miembro desconocido: 21 142 cobros de desarrollo tenían ese problema. No se agrupan cuentas desconocidas bajo una identidad cero ni por nombre actual.

En desarrollo se conciliaron 86 475 transacciones financieras OLTP–DW, incluidas 23 018 de cobro. En test se extrajeron 3 619 cobros de 263 cuentas y se verificó la biyección por ID, fecha y tipo. Un pago puede agrupar obligaciones; los cobros no llevan `InvoiceID`. Por ello, no se inventa una aplicación uno a uno pago-factura ni se reutilizan líneas de venta como observaciones financieras. La simulación vincula pagos con obligaciones de facturación, pero no hace idénticos los eventos ni sus etiquetas.

15.2. Contrato temporal, cobertura y etiqueta

`TransactionDate` representa el día empresarial del cobro; `DateKey` procede de esa fecha. No contiene hora auditada de inserción. `LastEditedWhen` es última modificación y solo aporta un control observable de versión; no acredita creación ni completitud absoluta. Los eventos de cobro inspeccionados se editaron en su propio día empresarial. En cambio, `OutstandingBalance`, `IsFinalized` y `FinalizationDate` son estados mutables y no se reconstruyen como historia a partir del último valor.

El contrato utiliza explícitamente `business_ledger_academic`: se asume conservación y cobertura mensual del libro de eventos dentro del alcance conciliado. La fecha interpretable, unicidad, correspondencia OLTP–DW, continuidad mensual y mecanismo local de registro respaldan una reconstrucción de conteos sin exigir snapshots de saldos que el objetivo no usa. No prueban ausencia universal de borrados, correcciones, escrituras externas, carga retroactiva o latencia. Tampoco equivalen a conciliación bancaria.

La ausencia de cobros se representa como cero solo en un mes cubierto posterior a primera observación de la cuenta. Antes de primera aparición no se fabrican filas. Cobertura desconocida, mes incompleto o extracto inconsistente produce indeterminación, no clase negativa. La población inicial incluye pagadores previamente observados; no se afirma cubrir cuentas nunca vistas en cobros.

Sea $N_{c,t}$ el número de IDs distintos de cobro de la cuenta c en el mes calendario t. La referencia y la respuesta son

$$R_{c,t} = \text{mediana}(N_{c,t-1}, N_{c,t-2}, N_{c,t-3}), \qquad y_{c,t} = \mathbf{1}[N_{c,t} > R_{c,t}]. \tag{17}$$

El empate pertenece a clase 0. Se requieren tres meses consecutivos de historia, no las tres últimas compras o transacciones activas. El instante de predicción es el comienzo de t, después del cierre de $t-1$. El conteo objetivo y y permanecen fuera de X; R sí puede ser entrada porque utiliza exclusivamente el pasado.

15.3. Preparación causal y representación de 16 entradas

La extracción focalizada usa SELECT y autenticación integrada en la instancia local AMBATO. Se conserva una proyección mínima con ID de evento, cuenta, fecha, tipo, edición y comprobación de signo sin exportar importes. El snapshot comprimido y las consultas tienen hashes reproducibles. Se rechazan duplicados, tipos distintos y discrepancias de unión, sin repetir la auditoría general ni exportar indiscriminadamente la base.

Cada cuenta-mes se ordena por mes y CustomerID. La primera aparición se determina con eventos previos al instante; no se utiliza actividad del objetivo, última aparición futura o supervivencia para elegir la población. Las 16 características efectivas se detallan en la tabla 13. No se impuso una dimensión de 20 por analogía con Ventas.

Tabla 13: Las 16 características financieras antes de estandarizar. $n_k = N_{c,t-k}$.

Característica	Fórmula
`cobros_lag_1`	n_1
`cobros_lag_2`	n_2
`cobros_lag_3`	n_3
`cobros_media_3`	$(n_1 + n_2 + n_3)/3$
`cobros_mediana_3`	$\text{mediana}(n_1, n_2, n_3)$
`cobros_std_3`	$\text{std}(n_1, n_2, n_3)$, $ddof = 0$
`cobros_cambio_1`	$n_1 - n_2$
`cobros_tendencia_3`	$(n_1 - n_3)/2$
`meses_con_cobros_3`	$\sum_{k=1}^{3} \mathbf{1}[n_k > 0]$
`mes_anterior_sin_cobros`	$\mathbf{1}[n_1 = 0]$
`variacion_relativa_cobros`	$(n_1 - n_2)/n_2$ si $n_2 > 0$; nulo si no
`base_variacion_cero`	$\mathbf{1}[n_2 = 0]$
`antiguedad_observada_meses`	$\text{ordinal}(t) - \text{ordinal}(t_{\text{primero}})$
`mes_sin`	$\sin(2\pi(\text{mes}(t) - 1)/12)$
`mes_cos`	$\cos(2\pi(\text{mes}(t) - 1)/12)$
`dias_mes_objetivo`	Días calendario del mes objetivo

Solo la variación relativa puede ser nula cuando $n_2 = 0$: se imputa con mediana de train y conserva el indicador de base cero. La historia esencial no se imputa. Las 16 columnas resultaron no constantes en train; ninguna se eliminó con información de validación. Las medias y desviaciones poblacionales del escalado ($ddof = 0$) se ajustaron solo con entrenamiento y se aplicaron sin refit a los períodos posteriores. CustomerID queda como metadato, no magnitud continua. Se excluyen importes, saldos, estados finales, medios actuales de pago y atributos dimensionales condicionados.

La tabla 14 separa soporte principal y común. Train utiliza objetivos 2013–2014 desde abril, con etiquetas conocidas antes de 2015-01-01; validación usa 2015, antes de 2016-01-01. Test se limita a enero–mayo de 2016, con corte exclusivo de conocimiento 2016-06-01. No se reajusta con

Tabla 14: Transacciones: particiones temporales y poblaciones principal y común.

Conjunto	Mes objetivo	N principal	Clase 0	Clase 1	N común
Entrenamiento	2013-04–2014-12	4612	2814	1798	4376
Validación	2015-01–2015-12	2943	1745	1198	2927
Prueba	2016-01–2016-05	1284	759	525	1276

meses posteriores: eventos de validación o test ya concluidos solo aportan historia causal para el mes siguiente.

Las pruebas de preparación perturbaban cobros del objetivo para comprobar que cambia la etiqueta al cruzar R, pero no sus predictores; perturbaciones futuras no alteraban períodos anteriores. También se verificaron identidad cliente-mes, continuidad de lags, cobertura explícita de ceros, parámetros train-only, alineación y reproducción. X es float64 finita; las etiquetas canónicas son 0/1. Estas pruebas usan fixtures sintéticos como controles, no sustituyen los eventos empresariales.

15.4. Configuración experimental y modelos congelados

Se reutilizan sin cambios las clases NumPy del perceptrón y la logística explicadas mediante las ecuaciones 1–4. Ambos comienzan con pesos y sesgo cero, sin transferir pesos de Ventas ni utilizar clasificadores predefinidos o autodiferenciación. La dimensionalidad de estas ejecuciones es exactamente 16. El presupuesto de la tabla 15 se fijó antes de resultados: dos recorridos por

Tabla 15: Presupuesto financiero predefinido: cuatro ejecuciones, sin ampliación adaptativa.

Modelo	η	Semilla	Máx. épocas	Checkpoint	BA val. (%)
Perceptrón	0,01	42	100	80	66,457
Perceptrón	0,01	7	100	3	66,783
Logística	0,05	42	400	380	60,611
Logística	0,10	42	400	399	62,082

semillas distintas para perceptrón, con tasa 0,01 y 100 épocas y una permutación nueva por época; dos tasas logísticas con 400 épocas y lote completo. En logística, seed=42 no altera la inicialización cero. La tolerancia de norma del gradiente es 10^{-6}. No hubo búsqueda adaptativa de tasas o épocas ni selección posterior de umbral: $\tau = 0,5$ quedó fijo. A diferencia de Ventas, no se inspeccionó una cuadrícula de 19 umbrales y el presupuesto logístico fue de 400, no 200 épocas.

La selección maximiza BA en las 2 943 filas de validación completa; desempata por F1, menor época y orden predefinido. Las actualizaciones solo utilizan train. Se conserva el checkpoint, sin refit train+val. La comparación con un histórico de mayor exigencia no altera retrospectivamente esa población de selección.

15.4.1. Perceptrón financiero

Se seleccionaron tasa 0,01, semilla 7 y época 3. El sesgo es $b = -0,060000000000000005$. La tabla 16 reproduce sus 16 pesos; la regla es $\widehat{y} = \mathbf{1}[z \geq 0]$. Las magnitudes actúan sobre entradas estandarizadas correlacionadas y no representan efectos causales o importancia independiente.

Tabla 16: Pesos financieros congelados: perceptrón. Precisión decimal suficiente para recuperar float64.

Índice	Característica estandarizada	Peso
1	`cobros_lag_1`	-0.04287896966745797
2	`cobros_lag_2`	-0.03607377463708822
3	`cobros_lag_3`	-0.02506460518201935
4	`cobros_media_3`	-0.03912919228599467
5	`cobros_mediana_3`	-0.23984633131606187
6	`cobros_std_3`	-0.022046274510795494
7	`cobros_cambio_1`	-0.008542006557497794
8	`cobros_tendencia_3`	-0.0224937898692178 3
9	`meses_con_cobros_3`	0.010515036627325475
10	`mes_anterior_sin_cobros`	-0.01832001014751086
11	`variacion_relativa_cobros`	0.03828637104414538
12	`base_variacion_cero`	0.018388594765704862
13	`antiguedad_observada_meses`	0.026577078904025647
14	`mes_sin`	0.01864275205505169
15	`mes_cos`	-0.0052679857739134466
16	`dias_mes_objetivo`	0.03913688671035464

15.4.2. Regresión logística financiera

Se seleccionaron tasa 0,10 y época 399, con umbral fijo 0,5 y sesgo $b = -0{,}5397483970938558$. La tabla 17 conserva los 16 pesos. Se mantuvieron sigmoidea por ramas, pérdida `logaddexp` y gradientes analíticos del modelo general. La serialización sin pickle conserva nombres, dimensión, sesgo, parámetros y checkpoint; la recuperación reproduce las predicciones aprobadas. La tabla

Tabla 17: Pesos financieros congelados: logística. Precisión decimal suficiente para recuperar float64.

Índice	Característica estandarizada	Peso
1	`cobros_lag_1`	-0.01131612469869563
2	`cobros_lag_2`	0.026461475377230335
3	`cobros_lag_3`	-0.04202999215738953
4	`cobros_media_3`	-0.010071816705856898
5	`cobros_mediana_3`	-0.8948655245730728
6	`cobros_std_3`	-0.13941955635444683
7	`cobros_cambio_1`	-0.04702866804625703
8	`cobros_tendencia_3`	0.03830044269545719
9	`meses_con_cobros_3`	-0.1518249526896529
10	`mes_anterior_sin_cobros`	0.0796368591991789
11	`variacion_relativa_cobros`	0.09177270933112168
12	`base_variacion_cero`	0.10951007173144613
13	`antiguedad_observada_meses`	0.07819826481425454
14	`mes_sin`	0.06375213358821646
15	`mes_cos`	-0.056330945759771635
16	`dias_mes_objetivo`	0.07942064011905278

18 corresponde a los checkpoints restaurados, no a las últimas épocas. La selección repetida en validación puede introducir optimismo; esa partición no es una prueba independiente del diseño. Los hashes aprobados de ambos modelos se verificaron antes de abrir test y permanecen en los anexos digitales, junto con sus pesos de precisión completa.

15.5. Convergencia observada y comportamiento durante el entrenamiento

Tabla 18: Métricas financieras de los checkpoints seleccionados en soporte principal (%).

Modelo	Conjunto	Acc.	Prec.	Recall	Espec.	F1	BA
Perceptrón	Train	66,522	56,065	65,295	67,306	60,329	66,301
Perceptrón	Validación	65,511	55,787	73,623	59,943	63,476	66,783
Logística	Train	68,148	68,462	33,927	90,014	45,370	61,970
Logística	Validación	67,244	69,898	34,307	89,857	46,025	62,082

15.5.1. Perceptrón: oscilación y checkpoint temprano

Los errores online iniciales/finales fueron 1856/1810, con mínimo 1768 y máximo 1917. Se registraron 183820 actualizaciones y 52 transiciones crecientes. Ninguna de las 100 épocas quedó sin errores; la última mantuvo 1 810 actualizaciones. Las figuras 22 y 23 muestran la misma identidad error–actualización exigida por la regla online, no dos evidencias independientes. Las

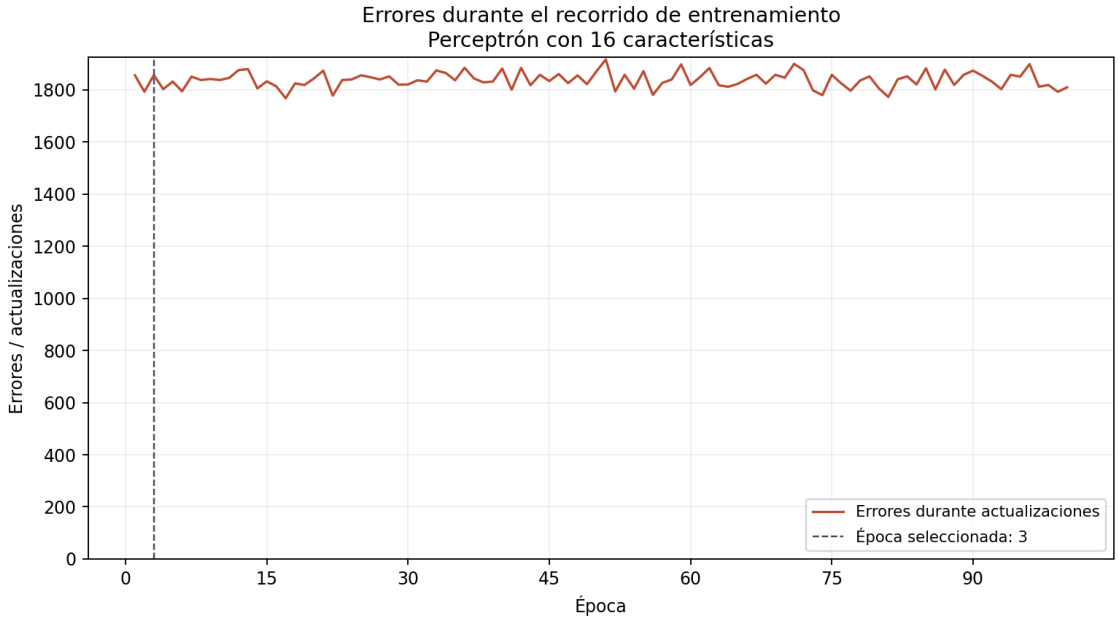


Figura 22: Errores online del perceptrón financiero por época, sin suavizar ni ocultar oscilaciones. La línea vertical identifica el checkpoint 3.

curvas de accuracy y BA de las figuras 24 y 25 distinguen selección y optimización. El checkpoint 3 alcanza BA de validación 66,782699 %; la última época cae a 59,099 %. No debe exportarse el último estado como si fuera el elegido. Los errores al cierre también difieren del conteo online: al final hay 1 722 errores con un estado fijo de parámetros. La conclusión es ausencia de convergencia a cero actualizaciones en el presupuesto observado. No se demuestra separabilidad ni su ausencia mediante estas 100 épocas; tampoco se amplía el presupuesto al observar oscilación o test.

15.5.2. Logística: descenso estable sin alcanzar tolerancia

La pérdida train pasó de 0,693147181 a 0,616972884; la pérdida de validación final fue 0,631334062. No hubo incrementos train mayores que 10^{-12}. El último cambio de pérdida fue aproximadamente $-2,6413 \times 10^{-5}$ y la norma final del gradiente fue 0,016242538, mayor que 10^{-6}. Las figuras 26 y 27 muestran descenso y gradiente no nulo, sin convertirlos en prueba de

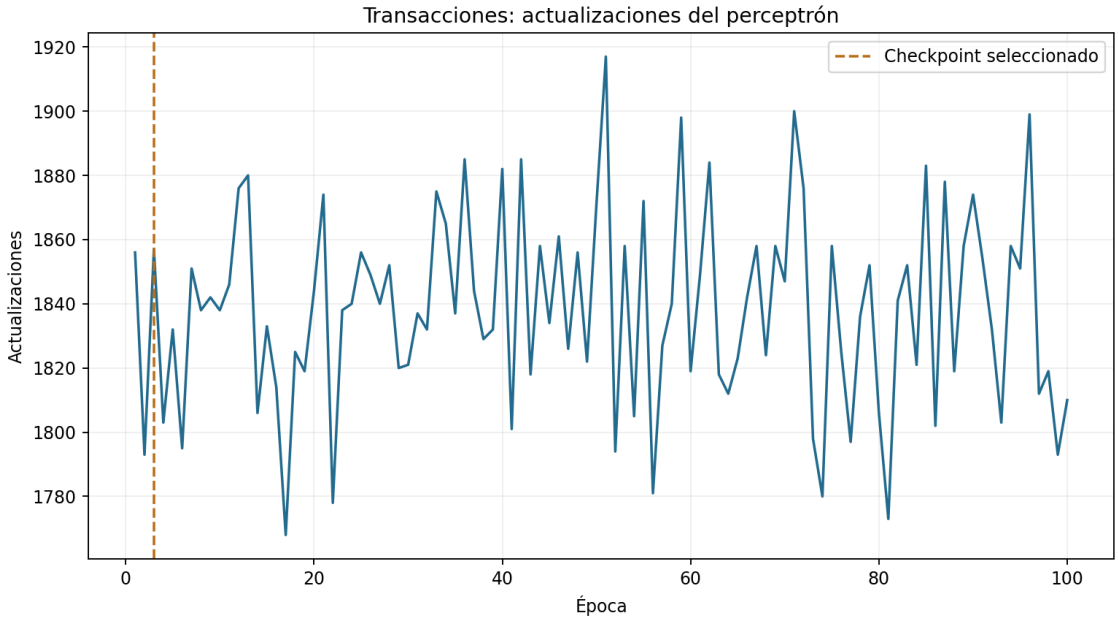


Figura 23: Actualizaciones por época del perceptrón financiero. Cada error online provoca una actualización, por lo que ambos conteos coinciden.

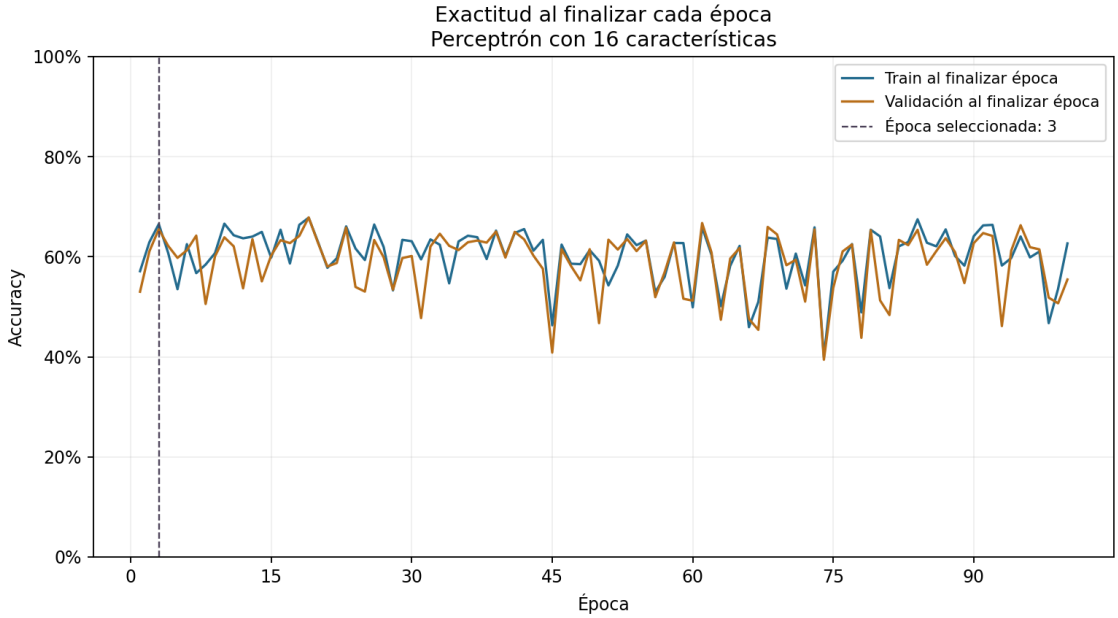


Figura 24: Accuracy financiera de train y validación al finalizar cada época del perceptrón. La validación no interviene en las actualizaciones.

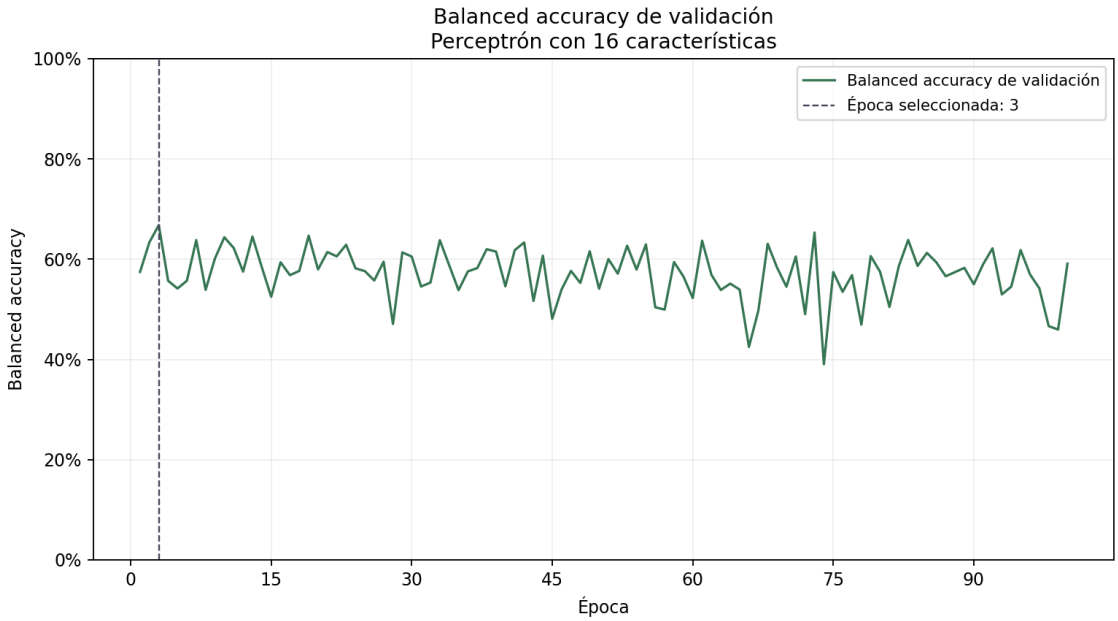


Figura 25: BA financiera de validación por época. La época 3 se seleccionó por el criterio predefinido, no por cese de actualizaciones.

óptimo. La ejecución terminó por máximo de épocas, no por tolerancia. El checkpoint 399 y la época 400 tienen BA de validación 62,081956 % y 62,040220 %, respectivamente; se conservó el primero. Las figuras 28 y 29 permiten observar que disminuir una pérdida continua no equivale a mejorar monótonamente métricas discretas con umbral fijo. La conclusión verificable es descenso estable sin convergencia completa demostrada. No se dibujan curvas de entrenamiento para test ni se entrenan nuevas configuraciones para interpretar estos historiales.

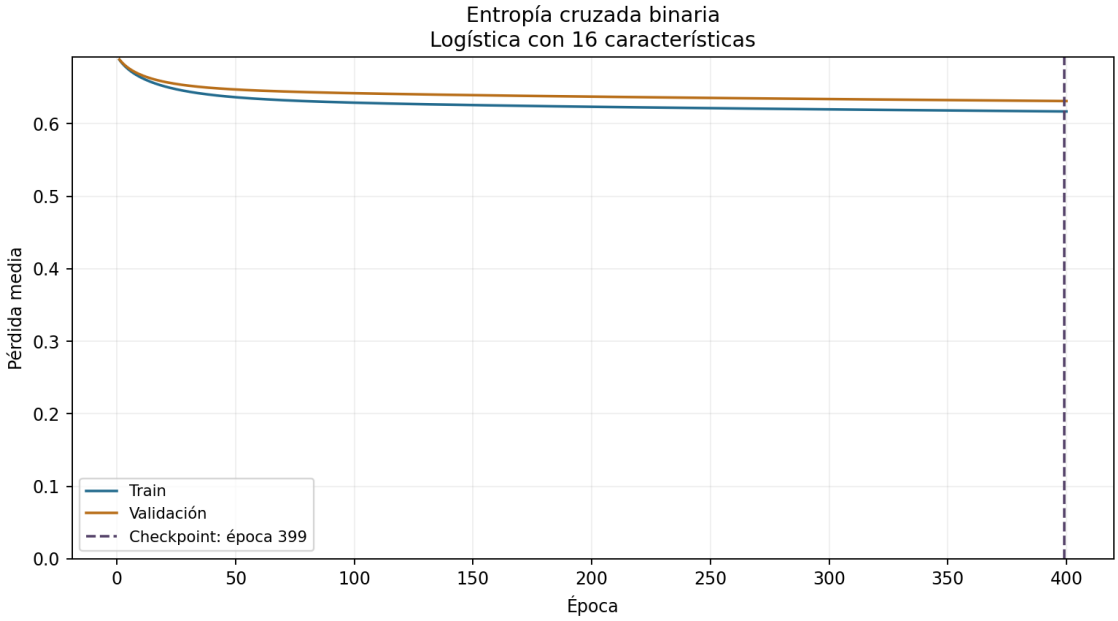


Figura 26: Entropía cruzada financiera de train y validación durante las 400 épocas de la logística seleccionada. La línea vertical marca el checkpoint 399.

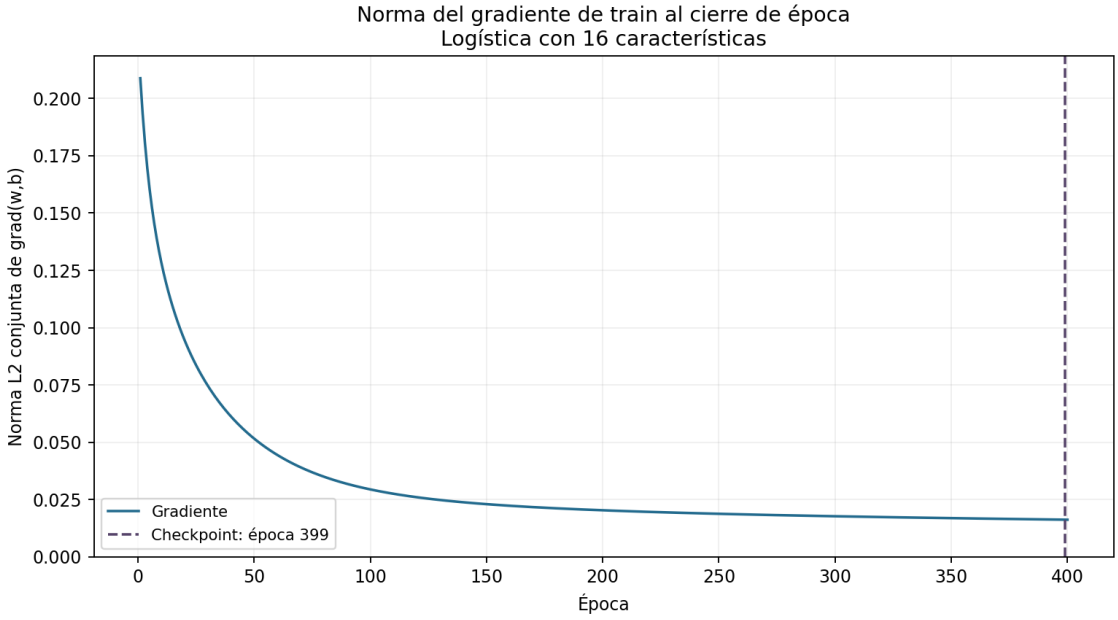


Figura 27: Norma conjunta de los gradientes de pesos y sesgo al cierre de cada época financiera. El criterio 10^{-6} no se alcanzó.

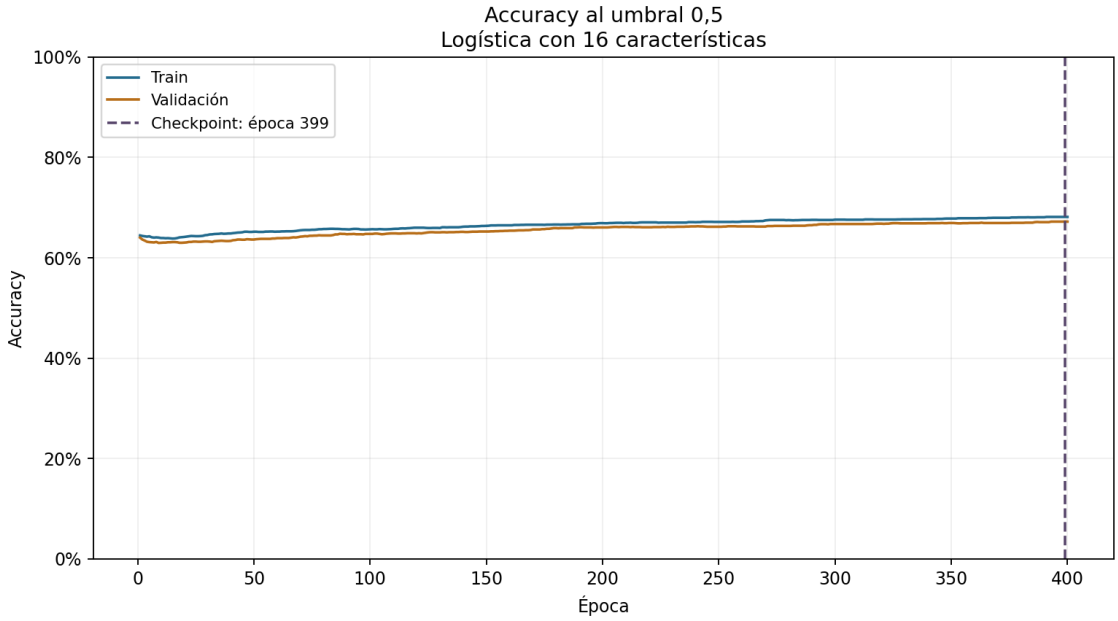


Figura 28: Accuracy financiera por época de la logística con umbral 0,5; ambas series corresponden a desarrollo, no a test.

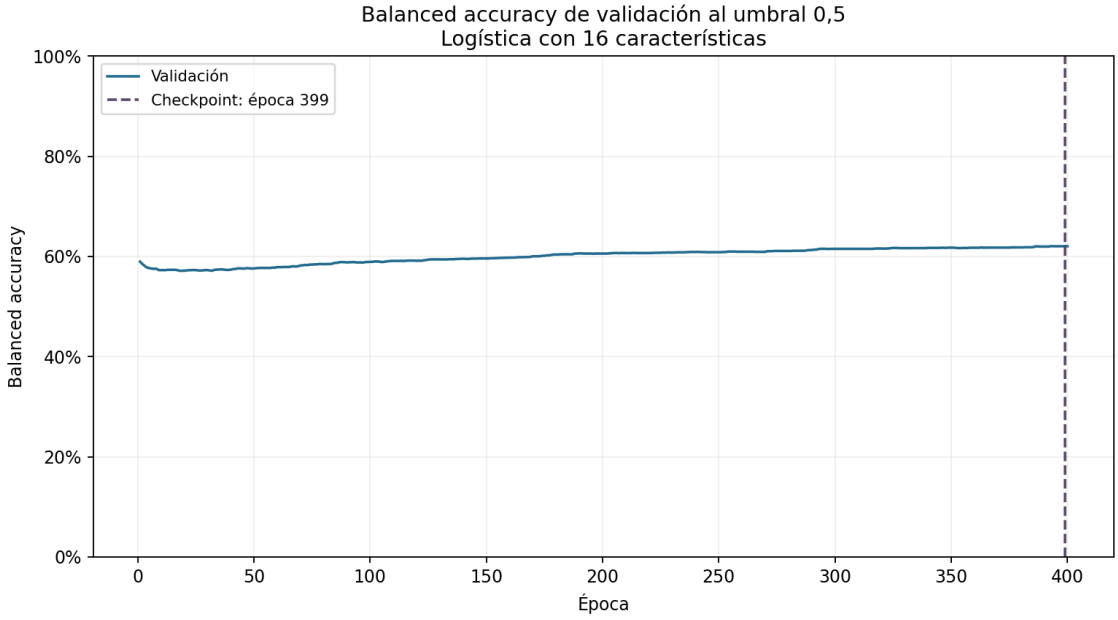


Figura 29: BA financiera de validación de la logística. La selección de checkpoint es distinta del criterio de parada por gradiente.

15.6. PCA financiero: estructura de variación y solapamiento

PCA se ajustó mediante la SVD de la ecuación 6 solo con X de entrenamiento, sin etiquetas ni nuevo escalado. La validación recibió la misma media y matriz de componentes. PC1 explica 27,896 %, PC2 17,125 % y juntas 45,021 %; queda fuera del plano 54,979 %. El rango numérico fue 13 de 16, compatible con las redundancias algebraicas de media, diferencias y tendencias. Los clasificadores mantuvieron sus 16 entradas originales procesadas. PC1 resume nivel de actividad:

Tabla 19: Coeficientes de mayor magnitud del PCA financiero en entradas estandarizadas.

Comp.	Característica	Coeficiente
PC1	`cobros_media_3`	0,467395768
PC1	`cobros_mediana_3`	0,458978900
PC1	`cobros_lag_1`	0,424372958
PC1	`cobros_lag_2`	0,411495169
PC1	`cobros_lag_3`	0,407070303
PC2	`cobros_cambio_1`	0,535122635
PC2	`variacion_relativa_cobros`	0,503452365
PC2	`cobros_tendencia_3`	0,437702542
PC2	`mes_anterior_sin_cobros`	-0,352326429
PC2	`cobros_lag_1`	0,218738061

los mayores coeficientes positivos corresponden a media (0,467396), mediana (0,458979) y los tres lags de cobros. PC2 enfatiza cambio (0,535123), variación relativa (0,503452) y tendencia (0,437703), frente a ausencia de actividad en el mes anterior (coeficiente negativo). La tabla 19 presenta los cinco de mayor magnitud; el CSV conserva todos. Son coeficientes unitarios en coordenadas estandarizadas, no correlaciones automáticamente ni factores económicos causales.

Las figuras 30 y 31 muestran solapamiento de clases; la figura 32 cuantifica la varianza que queda fuera del plano. Esa imagen no prueba imposibilidad de clasificación en 16 dimensiones ni explica por sí sola los errores. Se verificaron ortogonalidad, varianza de las proyecciones, suma de ratios, equivalencia del espectro SVD con la covarianza y residuo de reconstrucción. No se usó PCA para predecir, ajustar umbrales o seleccionar filas.

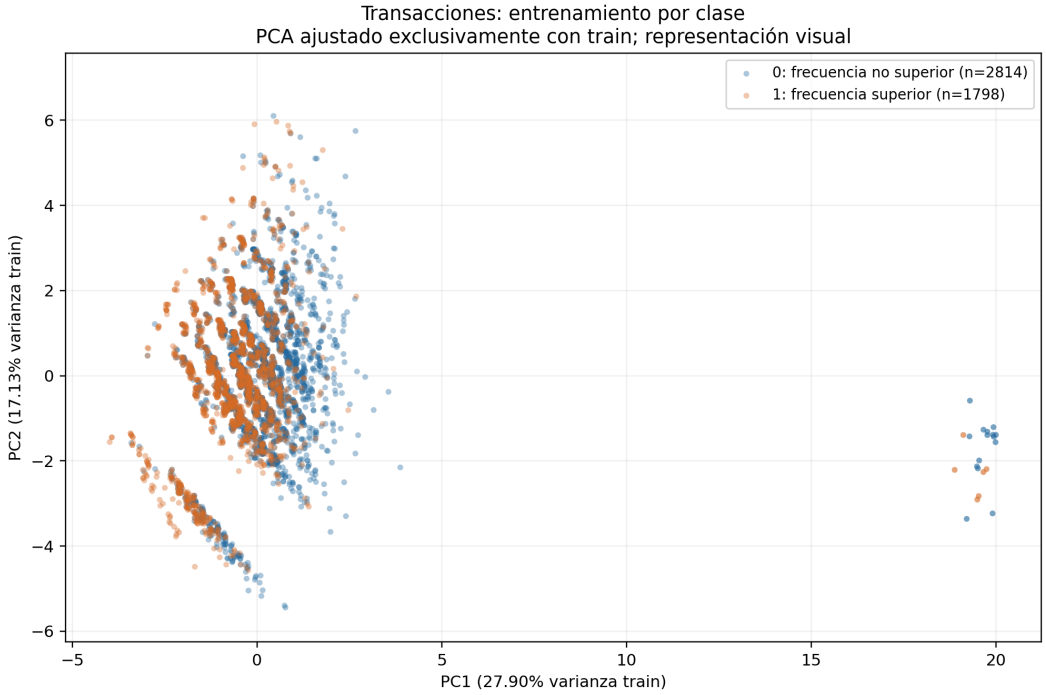


Figura 30: PCA financiero de entrenamiento por clase real. Se conservan todos los puntos, incluidos extremos, sin desplazamiento artificial ni frontera de clasificación 2D.

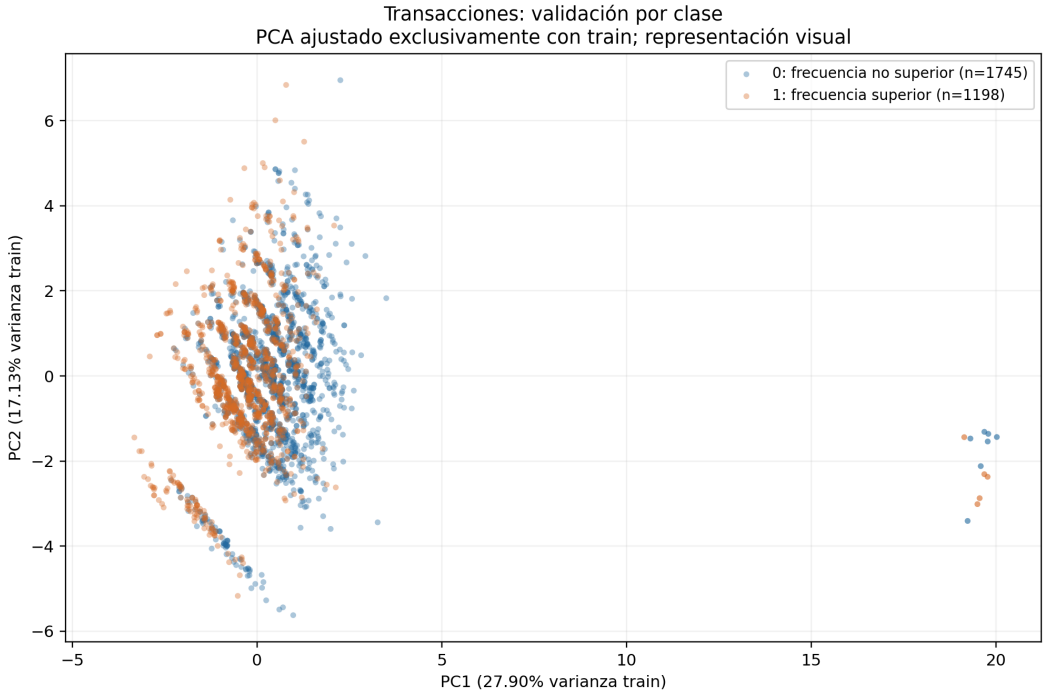


Figura 31: Validación financiera proyectada con parámetros exclusivamente de train. Los colores solo describen etiquetas; los ejes mantienen límites comparables.

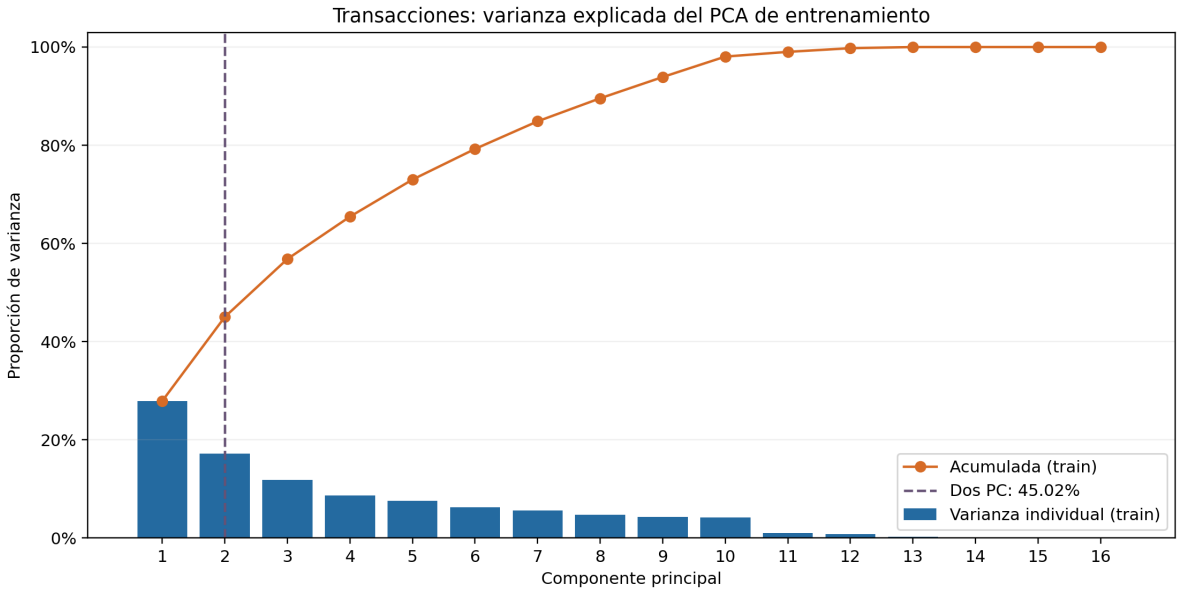


Figura 32: Varianza financiera individual y acumulada en las 16 direcciones de entrenamiento. La retención bidimensional es 45,021 %, no el porcentaje obtenido en Ventas.

15.7. Evaluación final: apertura, poblaciones y baselines

Antes de consultar 2016 se reprodujeron métricas y predicciones de validación y se verificaron hashes de modelos, matrices, preprocesador y protocolo. Un registro persistente de apertura precede a las consultas. El modelo de prueba ya no constituye una reserva disponible para diseñar nuevas configuraciones: sus resultados se documentan sin reajuste.

La población principal contiene 1 284 observaciones de enero–mayo, con 525 positivas y 759 negativas. Ambos clasificadores y mayoría se evalúan sobre esas mismas claves. El mayoritario predice 0, aprendida de train, a diferencia de la clase 1 del baseline de Ventas. El histórico financiero es la persistencia de la etiqueta anterior:

$$\widehat{y}_{c,t}^{\text{hist}} = y_{c,t-1} = \mathbf{1}[N_{c,t-1} > \text{mediana}(N_{c,t-2}, N_{c,t-3}, N_{c,t-4})]. \tag{18}$$

Requiere cuatro meses previos y no se sustituye por $\mathbf{1}[N_{c,t-1} > R_{c,t}]$, que incluye $N_{c,t-1}$ en otra referencia y usa tres meses. Ocho filas principales carecen del cuarto antecedente; su histórico queda indeterminado y la comparación secundaria se restringe a 1 276. No se eliminan de los clasificadores ni se inventa el lag cero. La misma conciliación explicó previamente 16 filas de validación: 2 943 principales frente a 2 927 comunes, todas con etiqueta y predicciones válidas de modelos/mayoría. El perceptrón alcanza BA 66,222 %, accuracy 62,461 %, recall 86,857 % y F1

Tabla 20: Test financiero: métricas sobre las 1 284 filas principales (%).

Método	Acc.	Prec.	Recall	Espec.	F1	BA
Perceptrón	62,461	52,474	86,857	45,586	65,423	66,222
Logística	65,265	58,998	49,333	76,285	53,734	62,809
Mayoritario	59,112	0,000	0,000	100,000	0,000	50,000

Tabla 21: Conteos financieros principales y tasas FPR/FNR y predicción positiva (%).

Método	TN	FP	FN	TP	FPR	FNR	Pred. 1
Perceptrón	346	413	69	456	54,414	13,143	67,679
Logística	579	180	266	259	23,715	50,667	34,190
Mayoritario	759	0	525	0	0,000	100,000	0,000

65,423 %; logística BA 62,809 %, accuracy 65,265 %, recall 49,333 % y F1 53,734 %. La mayor BA del primero coexiste con menor accuracy y especificidad. Su FPR es 54,414 % y FNR 13,143 %, frente a 23,715 % y 50,667 % de logística. Son distintas preferencias de error de modelos ya fijados, sin atribuir un costo monetario no disponible.

Las matrices de las figuras 33 y 34, junto con la tabla 21, proceden directamente de los artefactos exportados. El perceptrón reconoce 456 positivos y 346 negativos, con 413 FP y 69 FN; logística reconoce 259 y 579, con 180 FP y 266 FN. No se reconstruyeron predicciones para elaborar el informe.

Tabla 22: Comparación financiera secundaria: los cuatro métodos en 1 276 filas (%).

Método	Acc.	Prec.	Recall	Espec.	F1	BA
Perceptrón	62,226	52,364	86,807	45,153	65,324	65,980
Logística	65,125	58,904	49,331	76,096	53,694	62,713
Mayoritario	59,013	0,000	0,000	100,000	0,000	50,000
Histórico	49,373	38,104	37,667	57,503	37,885	47,585

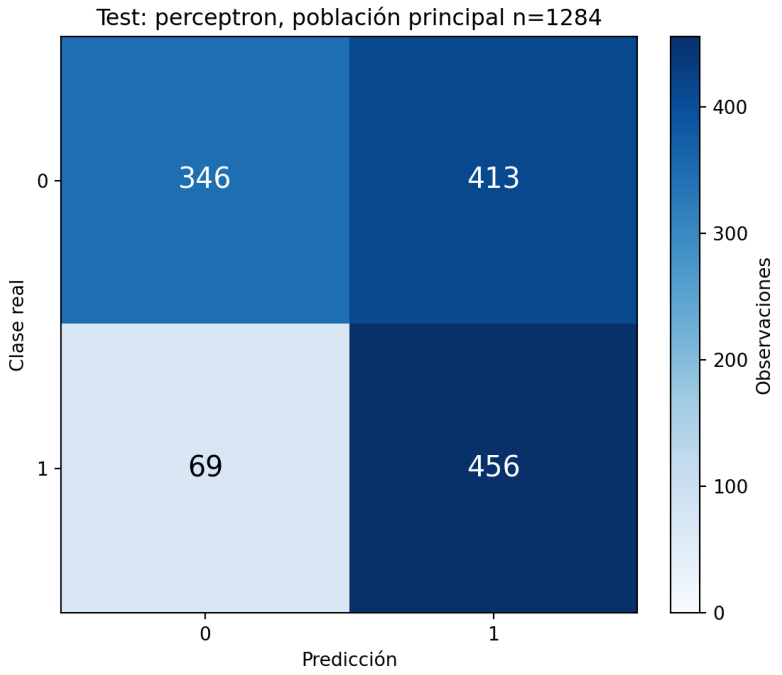


Figura 33: Matriz financiera principal del perceptrón: 1 284 observaciones, filas reales y columnas predichas. La alta sensibilidad se acompaña de 413 falsas alertas.

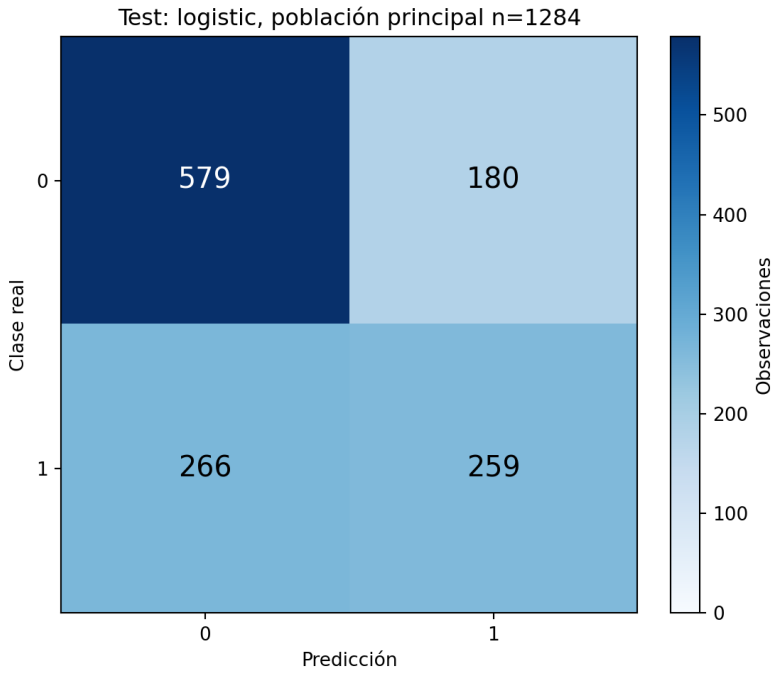


Figura 34: Matriz financiera principal de logística: 180 FP y 266 FN con umbral congelado 0,5. No corresponde al subconjunto del histórico.

En el soporte común de la tabla 22, las BA son 65,980 % para perceptrón, 62,713 % para logística, 50,000 % para mayoría y 47,585 % para histórico. Las figuras 35, 36 y 37 usan exactamente ese subconjunto de cuatro métodos. No reemplazan la tabla principal 20. Las pequeñas diferencias entre BA principal y común son aritmética de soporte, no cambios de pesos o umbral. Average

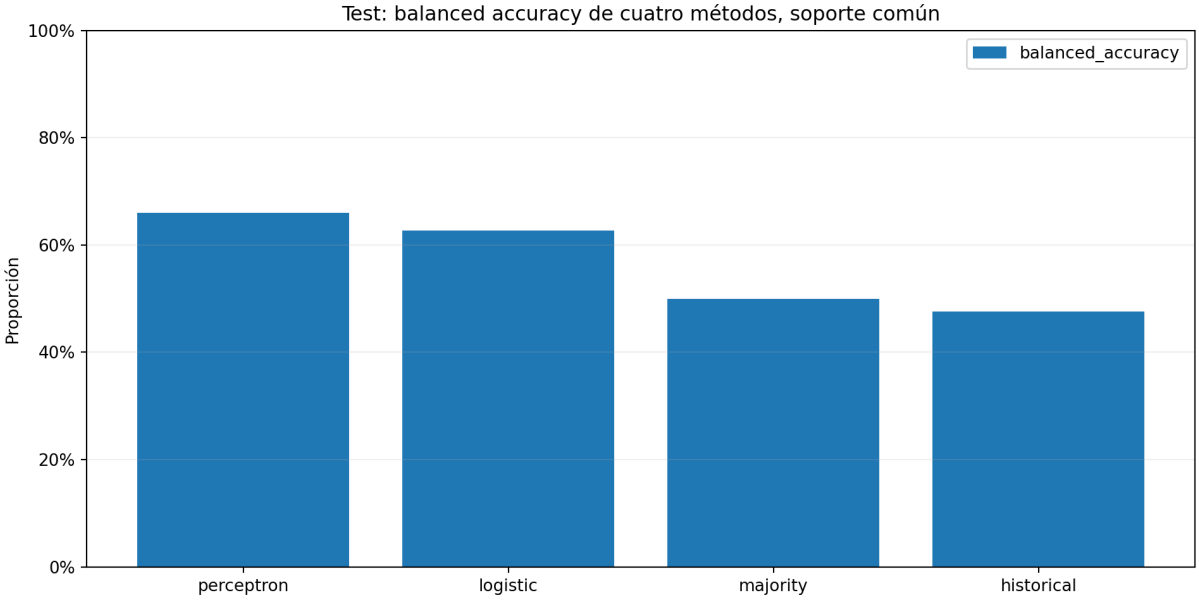


Figura 35: BA financiera de cuatro métodos sobre las mismas 1 276 observaciones comunes. La población principal de modelos conserva 1 284.

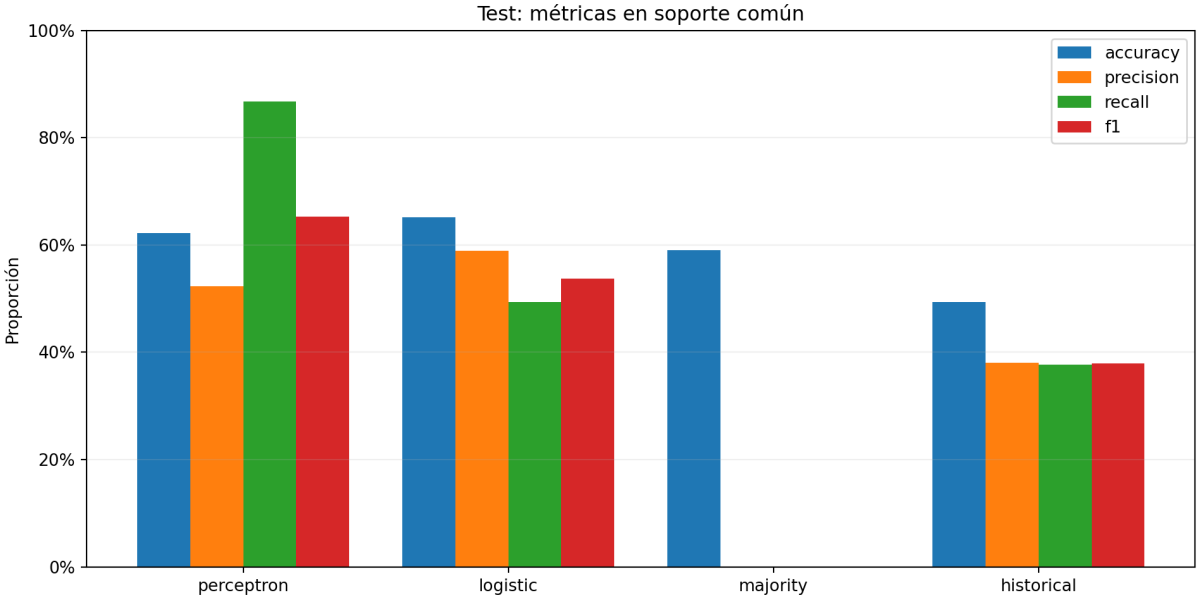


Figura 36: Accuracy, precision, recall y F1 financieros sobre soporte común. Ninguna métrica aislada representa beneficio empresarial.

Precision de logística en la población principal es 0,621821, calculada sobre scores sigmoid con grupos de empates y sin interpolación. No participó en la selección ni certifica calibración. La mayoría conserva precision y F1 cero por ausencia de positivos predichos; recall o especificidad sin clase real y BA sin ambas clases serían no estimables, conforme a las convenciones generales.

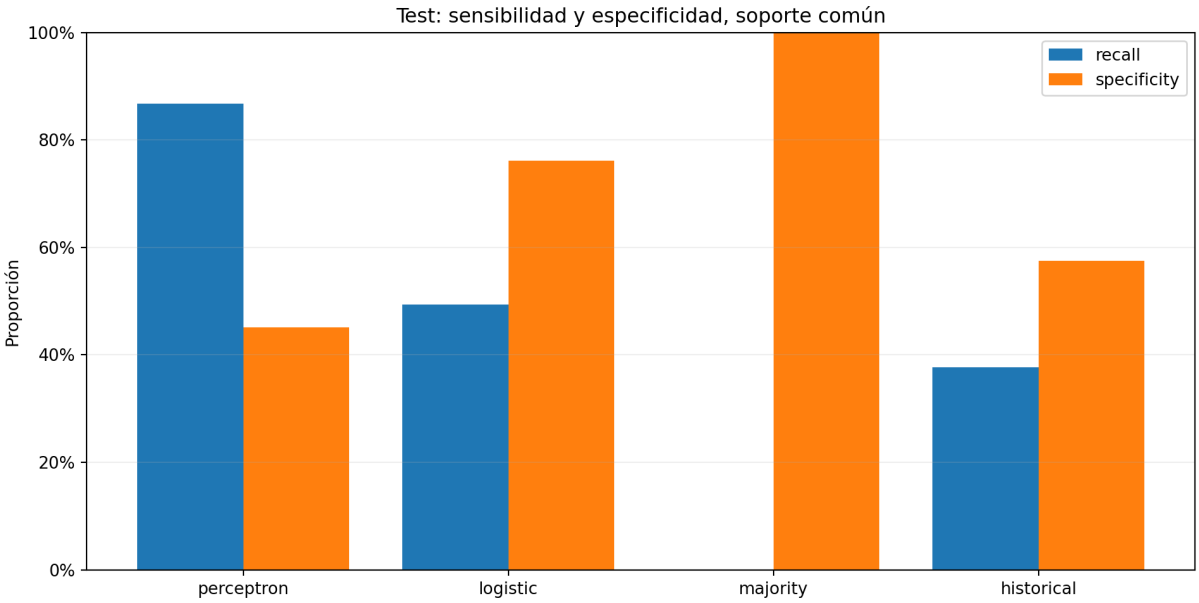


Figura 37: Sensibilidad y especificidad financieras de los cuatro métodos en soporte común. Se conserva la regla histórica contractual aunque su BA sea inferior a 50 %.

15.8. Generalización temporal, cuentas nuevas y análisis de errores

La BA test menos validación principal cambia -0,561 puntos en perceptrón y +0,727 en logística. Las poblaciones no son muestras emparejadas y cada ventana mezcla meses de forma distinta. Se conservan todos los meses, aun desfavorables, en la tabla 23; no se confunde BA global con media mensual sin ponderar. La figura 38 compara los cuatro métodos por mes en soporte común y la

Tabla 23: Todos los meses de test financiero: soporte principal y BA principal, sin sustituirla por la común.

Mes	N principal	N común	Clase 0/1	BA perc. (%)	BA log. (%)
2016-01	254	252	145/109	68,519	60,418
2016-02	254	254	168/86	75,817	64,708
2016-03	257	254	149/108	62,820	63,348
2016-04	259	257	143/116	64,188	59,103
2016-05	260	259	154/106	58,123	65,015

figura 39 contrasta las poblaciones principales de cada partición. El perceptrón obtiene su mayor BA principal mensual en febrero (75,817 %) y su menor en mayo (58,123 %). Logística varía entre 59,103 % en abril y 65,015 % en mayo. Por ello, una cifra global cercana a validación no equivale a estabilidad mensual. La ecuación de ponderación por clase desarrollada para Ventas también explica por qué BA agregada y promedio simple de meses pueden diferir; no se requieren nuevas predicciones para distinguirlos.

Tabla 24: Cuentas financieras conocidas y nuevas; cinco filas nuevas no acreditan generalización estable.

Cohorte	Cuentas	Filas	Clase 0/1	BA perc. (%)	BA log. (%)
Vistas en desarrollo	257	1279	755/524	66,065	62,793
Nuevas en test	3	5	4/1	100,000	50,000

La tabla 24 distingue las 257 cuentas vistas en desarrollo, que aportan 1 279 filas, de las nuevas elegibles: tres cuentas con solo cinco filas; las demás primeras apariciones aún no cumplen historia.

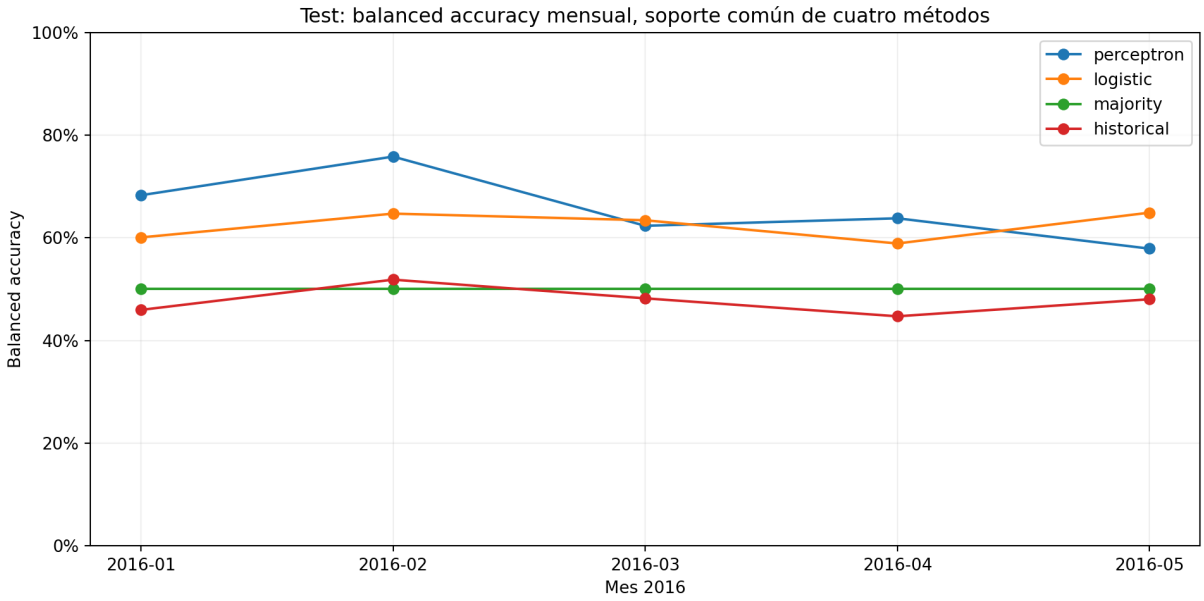


Figura 38: BA financiera mensual de cuatro métodos en soporte común. La tabla del texto conserva por separado las BA principales y los dos tamaños de muestra.

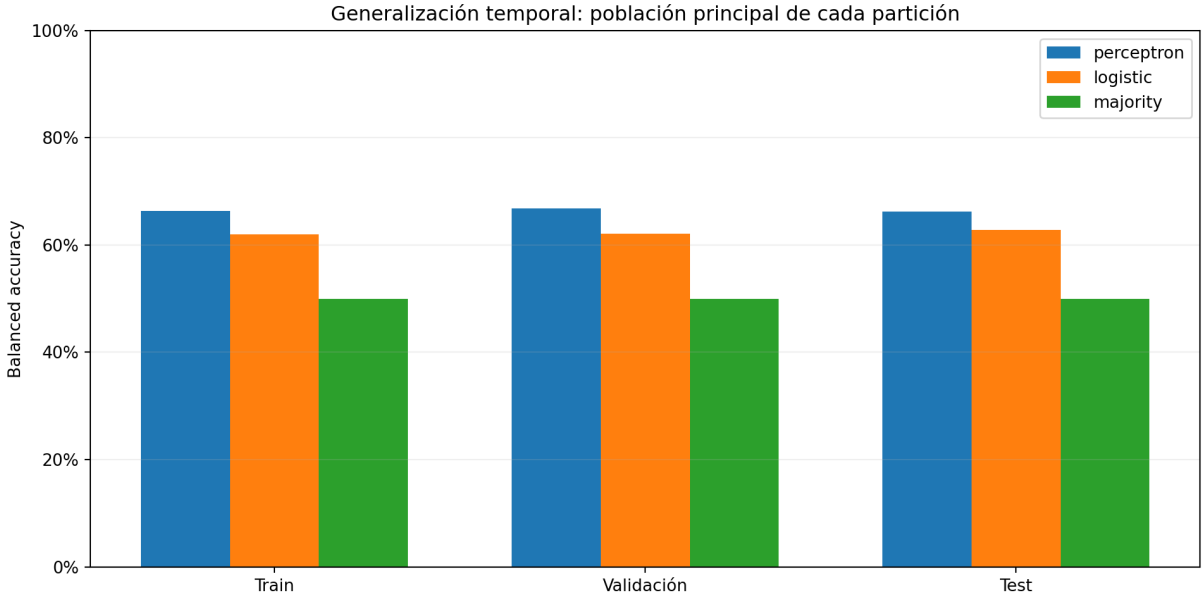


Figura 39: BA de train, validación y test financieros en la población principal de cada partición. No hay entrenamiento ni selección con test.

La BA de 100 % del perceptrón en esas cinco filas no acredita generalización estable: un positivo y cuatro negativos son un soporte mínimo. No se usa ese resultado para escoger modelo, redefinir elegibilidad o eliminar cuentas.

Mayo concentra 124 errores del perceptrón sobre 260 filas (47,69 %); abril concentra 103 de logística sobre 259 (39,77 %). Se conservan FP, FN, acuerdos y desacuerdos por cuenta-mes y mes, sin construir un clasificador combinado. La logística presenta menos falsas alertas, pero omite más positivos que el perceptrón. No se deduce la causa del cambio en decisiones de una variable particular ni se reajusta el umbral para compensarlo.

15.9. Limitaciones y conclusión parcial financiera

El experimento evalúa frecuencia relativa de cobros registrados, no demanda, mora, saldo ni ingreso monetario. La conservación y disponibilidad del libro son supuestos académicos explícitos; la biyección de las filas actuales no descarta todas las eliminaciones o correcciones históricas. Cinco meses, repetición de cuentas y ventanas solapadas restringen inferencia estadística. Las probabilidades no tienen calibración demostrada y los costos de alertas no están disponibles.

Ambos clasificadores superan descriptivamente los baselines en la comparación común; el perceptrón tiene mayor BA y recall, y logística mayor accuracy y especificidad en la población principal. Esas ventajas se refieren a esta etiqueta, representación y presupuesto finito. Se preservan modelos, preprocesador, PCA y métricas; test ya fue consumido y no se reutiliza como reserva para mejorar configuraciones. La evidencia permite documentar una segunda aplicación académica completa, sin declarar terminado el proyecto ni recomendar automatización financiera productiva.

16. Comparación académica entre Ventas y Transacciones

La metodología comparte modelos multidimensionales propios, orden temporal, selección en validación y transformaciones ajustadas solo con train. Sin embargo, no son dos mediciones sobre la misma población: Ventas predice unidades relativas por producto provisional; Transacciones predice frecuencia relativa de cobros por cuenta operacional. Las columnas, identidad, escala empresarial, supuestos y baselines son específicos de cada contrato.

Ventas utiliza 20 características, con lags de unidades y variables históricas comerciales/monetarias; Transacciones conserva 16, centradas en conteos, estadísticos, antigüedad observada y calendario. En esta última no se habilitan importes ni saldos históricos no acreditados. Las ventanas principales de test contienen 1 111 y 1 284 observaciones, respectivamente; sus positivos no tienen el mismo significado. La tabla 25 conserva cada población. La mayor BA observada en

Tabla 25: Contraste descriptivo entre problemas distintos: porcentajes de test, sin comparación estadística emparejada.

Proceso	Modelo	N	Acc.	BA	Recall	Espec.
Ventas	Perceptrón	1111	53,915	54,104	96,022	12,186
Ventas	Logística	1111	62,286	62,415	91,139	33,692
Transacciones	Perceptrón	1284	62,461	66,222	86,857	45,586
Transacciones	Logística	1284	65,265	62,809	49,333	76,285

Ventas corresponde a logística (62,42 %); en Transacciones, al perceptrón (66,22 %). No procede restar ambas cifras como estimación de superioridad sobre un mismo problema ni concluir que un algoritmo sea universalmente mejor. Se comparan dos experimentos con diferentes etiquetas y muestras, no un ensayo emparejado de métodos en una única población.

En Ventas, ambos modelos presentan alta sensibilidad y escasa especificidad, particularmente el perceptrón. La logística reduce falsas alertas y obtiene mejor equilibrio, aunque sus 370 FP todavía limitan el uso automático. En Transacciones, el perceptrón reconoce muchos positivos con FPR 54,41 %, mientras logística sacrifica recall para obtener mayor especificidad y accuracy. La interpretación debe partir del costo y la acción empresarial, que no se han cuantificado; ninguna métrica equivale a rentabilidad o conciliación bancaria.

El perceptrón continúa actualizando en ambos procesos, pero sus checkpoints elegidos son 70 y 3. La logística tiene descenso estable en ambos: Ventas agota 200 épocas con tolerancia desactivada; Transacciones agota 400 sin alcanzar 10^{-6}. No se interpreta la distinta época elegida como evidencia de convergencia más rápida a una solución comparable. Los PCA retienen 49,619 % y 45,021 % de varianza; solo visualizan estructuras distintas y no intervienen en las predicciones.

Las dos pruebas cubren cinco meses y tienen dependencia temporal y por entidad. La selección repetida en validación introduce optimismo de desarrollo; los pocos productos/cuentas nuevos impiden extrapolaciones estables. Los porcentajes son descriptivos de WWI y sus supuestos de cobertura. No se han demostrado significación estadística, deriva conceptual causal, superioridad universal ni utilidad productiva.

17. Conclusiones integradas y continuidad del alcance académico

La aplicación de Ventas conserva sus conclusiones verificadas: preparación causal común de 20 entradas, comparación reproducible de modelos propios y baselines, mejor BA logística y limitaciones por falsas alertas, identidad provisional y cobertura asumida. La ampliación financiera añade una segunda pregunta empresarial verificable, con identidad operacional, 16 características y separación entre eventos de pago y estados actuales.

La evaluación financiera mantuvo una población principal de 1 284 filas y una comparación secundaria de 1 276 por disponibilidad del cuarto lag histórico. Esta distinción evita que una limitación del baseline cambie la evaluación de clasificadores. Se registraron las decisiones antes de abrir la reserva y se conservaron pesos, sesgos, umbral y preprocesador. La revisión de convergencia y PCA aportó interpretación, no entrenamiento o ajuste adicional del resultado final.

La reutilización segura corresponde a la matemática y a las interfaces verificadas, no a copiar etiquetas, presupuestos, pesos o supuestos entre procesos. Los experimentos muestran distintos compromisos de sensibilidad y especificidad. Sin costos y contexto operacional, no se justifica elegir universalmente una neurona ni convertir sus predicciones en acciones automáticas.

La ampliación a los demás Data Marts sigue siendo una obligación académica pendiente. Pedidos conserva estudios por línea/documento con bloqueo temporal y un objetivo de retraso descartado; Compras conserva estudios de viabilidad sin dataset ni clasificadores aprobados bajo su contrato actual. Se describen como investigaciones con limitaciones, nunca como modelos implementados. Inventario/Movimientos continúa pendiente, así como una revisión final de procesos bloqueados si se obtiene evidencia nueva. Estas actividades no se ejecutaron para ampliar el informe.

La entrega documenta dos aplicaciones y no cierra el proyecto completo. Continúan pendientes la certificación operacional de conservación/cierres, la validación de costos FP/FN, información empresarial adicional, evidencia sobre cuentas nuevas y la identificación inequívoca del ciclo de entrega. Se requiere una evaluación independiente para cualquier uso real; las reservas ya observadas no pueden presentarse de nuevo como test nunca visto.

Referencias

[1] F. Rosenblatt. "The perceptron: a probabilistic model for information storage and organization in the brain". *Psychological Review*, 65(6), 386–408, 1958. DOI: 10.1037/h0042519. Metadatos contrastados con PubMed, PMID 13602029. Referencia histórica; no se atribuye a este artículo la implementación particular del proyecto.

[2] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. ISBN 978-0-387-31073-2. Capítulos 4 (clasificación lineal) y 12 (reducción dimensional). Edición disponible desde Microsoft Research.

[3] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. Capítulos 3 y 9. Sitio de los autores: `https://web.stanford.edu/~boyd/cvxbook/`.

[4] NumPy Developers. *numpy.linalg.svd*, documentación oficial de la descomposición en valores singulares. `https://numpy.org/doc/stable/reference/generated/numpy.linalg.svd.html`. Consulta: 2 de noviembre de 2026. La versión ejecutada por el proyecto se registra en los manifiestos; la documentación enlazada es la estable al consultar.

[5] Proyecto académico de Inteligencia de Negocios. *Formato de levantamiento de datos para la planificación de un modelo OLAP: Wide World Importers*. Universidad Técnica de Ambato, 18/08/2026, versión 1.0. Documento local: `referencias/Carta_de_DiseÃśo(2).pdf`. Integrantes consignados: Jonathan López y Josue Guevara. Autoría editorial no declarada.

[6] Proyecto académico de Inteligencia de Negocios. *Limpieza y preparación de datos utilizando OpenRefine*. Universidad Técnica de Ambato, ciclo indicado enero–julio de 2026. Documento local: `referencias/Openrefine_Cluster(2).pdf`. Participantes consignados: Josue Guevara y Jonathan López.

[7] Proyecto académico de Inteligencia de Negocios. *Dashboard de Business Intelligence para el Análisis de Ventas*. Universidad Técnica de Ambato, ciclo indicado enero–julio de 2026. Documento local: `referencias/Dashboard(1).pdf`. Participantes consignados: Josue Guevara y Jonathan López.

A. Catálogo de características efectivas

Las fórmulas de la tabla 26 corresponden a Ventas y son transcripción del contrato estructurado, antes de imputación y estandarización. q_1, q_2, q_3 denotan unidades de los tres meses anteriores. Las unidades monetarias son las de la extracción: no se infiere una moneda empresarial sin metadatos adicionales. El catálogo financiero independiente de 16 entradas aparece en la tabla 13.

Tabla 26: Entradas efectivas y fórmulas del contrato. $q_j = Q_{p,t-j}$.

Índice	Nombre	Fórmula registrada
1	`unidades_lag_1`	Q(p,t-1)
2	`unidades_lag_2`	Q(p,t-2)
3	`unidades_lag_3`	Q(p,t-3)
4	`unidades_media_3`	(q1+q2+q3)/3
5	`unidades_mediana_3`	mediana(q1,q2,q3)
6	`unidades_std_3`	std(q1,q2,q3), ddof=0
7	`cambio_unidades_1`	q1-q2
8	`variacion_relativa_1`	(q1-q2)/q2 si q2>0; nulo en otro caso
9	`tendencia_unidades_3`	(q1-q3)/2
10	`facturas_lag_1`	COUNT DISTINCT InvoiceID(p,t-1)
11	`facturas_media_3`	media de facturas distintas en t-1,t-2,t-3
12	`ingresos_lag_1`	SUM VentaSinImpuesto(p,t-1)
13	`ingresos_media_3`	media de ingresos de t-1,t-2,t-3
14	`precio_unitario_ponderado_lag_1`	ingresos_lag_1/q1 si q1>0; nulo si q1=0
15	`clientes_distintos_lag_1`	COUNT DISTINCT NombreCliente(p,t-1)
16	`unidades_por_factura_lag_1`	q1/facturas_lag_1 si facturas_lag_1>0; nulo si no
17	`antiguedad_observada_meses`	ordinal(t)-ordinal(primer mes observado antes del corte)
18	`mes_objetivo_sin`	sin(2*pi*(mes(t)-1)/12)
19	`mes_objetivo_cos`	cos(2*pi*(mes(t)-1)/12)
20	`dias_mes_objetivo`	días calendario de t, con bisiestos

B. Trazabilidad y reproducción documental

B.1. Relación entre afirmaciones y evidencia

El archivo `informe/evidencias/trazabilidad.json` relaciona cada tabla y figura con su fuente y hash SHA-256. Las afirmaciones cuantitativas sobre convergencia se derivan de los CSV por época y del registro de inicialización; las de evaluación se contrastan con las matrices, predicciones y análisis estadístico. Los pesos se comparan exactamente con el estado del archivo de congelación. Las figuras copiadas mantienen los mismos bytes de su origen; las nuevas vistas de soporte temporal, comparación global con cinco métricas, convergencia, paneles de error y error por partición se generan desde registros guardados.

La procedencia principal se organiza así:

- Calidad, grano y cardinalidades: `resultados/auditoria/`, especialmente `perfilado_datos.json` y `comparacion_csv.json`.
- Fórmulas, parámetros y particiones: `datos/Procesados/fase_03/` y su manifiesto.

- Pesos y recorrido del perceptrón: `resultados/fase_04/modelo_seleccionado.json` e `historial_orden_barajado.csv`.
- Logística, gradientes y selección: `resultados/fase_05/`, sus JSON y `historial_eta_010.csv`.
- PCA y estados congelados: `resultados/fase_06/`.
- Métricas y predicciones finales alineadas: `resultados/fase_07/`.
- Descomposición temporal, acuerdos, distribuciones y sensibilidad agrupada: `resultados/fase_08/`.

Los nombres técnicos de directorio se mantienen para reproducibilidad; no organizan la narrativa académica.

B.2. Comandos sin reentrenamiento

Desde la raíz del proyecto, el exportador documental lee artefactos y escribe únicamente dentro de `informe/`:

```
python informe/herramientas/generar_transacciones.py
cd informe
pdflatex --disable-installer -interaction=nonstopmode -halt-on-error main.tex
pdflatex --disable-installer -interaction=nonstopmode -halt-on-error main.tex
pdflatex --disable-installer -interaction=nonstopmode -halt-on-error main.tex
```

No ejecutar los entrenadores, la preparación del dataset ni la evaluación final para compilar. Los archivos `README.md` y `evidencias/verificacion_informe.json` documentan los comandos efectivos, número de tablas/figuras y controles de integridad. Se comprueban referencias cruzadas, ecuaciones, archivos gráficos y dimensiones de tablas, además de la inspección visual del PDF.

Los antecedentes de Ventas registran 104 pruebas satisfactorias antes de su elaboración documental. La evaluación financiera posterior registró 313 pruebas satisfactorias, según su archivo de validaciones. Son resultados históricos, no una suite reejecutada para esta edición. El verificador documental comprueba integridad, transcripción y reproducción de tablas/figuras con operaciones experimentales bloqueadas. Las pruebas matemáticas históricas usan ejemplos de control y no deben confundirse con reentrenamientos de WWI.

B.3. Parámetros y series que no deben confundirse

Los JSON conservan precisión completa de pesos y sesgos; los porcentajes del texto se redondean solo para lectura. Las curvas de accuracy y BA registran estados por época; las métricas finales corresponden al checkpoint restaurado. La norma del gradiente logístico incluye el sesgo y se registra después de cada actualización; `gradient_used_norm` corresponde al estado previo. No se transforma una curva de entrenamiento en una curva de test.

B.4. Trazabilidad de la ampliación financiera

La exportación documental financiera se ejecuta mediante `informe/herramientas/generar_transacciones.py`; su verificación y reproducción sin operaciones de aprendizaje o predicción corresponden a `informe/herramientas/verificar_transacciones_informe.py`. La trazabilidad

adicional está en `informe/evidencias/transacciones/`. Las 18 figuras financieras son copias binarias de resultados aprobados. Las 13 tablas nuevas transcriben JSON/CSV estructurados; FNR se obtiene algebraicamente de la matriz de confusión, sin recalcular predicciones.

Los comandos de compilación de este anexo siguen vigentes. Los exportadores y verificadores iniciales de Ventas se conservan como evidencia de la versión previa; sus conteos de 21 figuras y 13 tablas describen esa versión, no la ampliación actual. El README actualizado indica el procedimiento vigente. No se ejecutan preparación de datos, entrenamiento, evaluación o PCA para elaborar esta versión documental.

C. Continuidad obligatoria del proyecto académico

Esta versión documenta dos aplicaciones efectivamente evaluadas: Ventas y Transacciones Financieras. Las ampliaciones siguientes deberán incorporar, para cada proceso verificado, su formulación, procedencia, metodología, resultados y conclusiones parciales. Cliente o Producto no constituyen Data Marts distintos por el solo hecho de ser dimensiones. Pedidos y Compras conservan limitaciones de viabilidad; Inventario/Movimientos permanece pendiente. No se incluyen resultados vacíos o ficticios. La identificación inequívoca del ciclo actual y la evidencia operacional de cobertura, claves y unidades también siguen pendientes. El proyecto académico completo no se declara terminado.