INFORME DE PROYECTO DE INTELIGENCIA DE NEGOCIOS

Portada

Tema:	Limpieza y preparación de datos utilizando OpenRefine.
Unidad de Organización Curricular:	Profesional.
Nivel y Paralelo:	Sexto “A”.
Alumnos participantes:	Josue Guevara Jonathan López

Asignatura:	Inteligencia de Negocios.
Docente:	Ing. PhD. Rubén Nogales Portero.

Fase de Preparación y Calidad de Datos

Perfilado, Limpieza y Clustering Textual

I. Tema

Limpieza y preparación de datos utilizando OpenRefine sobre el dataset analítico de ventas derivado del Data Warehouse Wide World Importers.

II. Objetivo

General

Realizar el perfilado, revisión de calidad, limpieza y clustering textual del dataset de ventas a nivel de línea de factura extraído del Data Warehouse dimensional `WWI_Kimball`, utilizando la herramienta OpenRefine para asegurar la consistencia de la información previa a su consumo en etapas analíticas posteriores.

Específicos

- Importar y perfilar el dataset transaccional evaluando la distribución de los registros y la presencia de anomalías textuales.
- Implementar transformaciones mediante expresiones GREL para corregir la representación de valores nulos textuales y estandarizar los tipos de datos numéricos y de fecha.

- Ejecutar técnicas de validación para descartar la existencia de registros duplicados utilizando el identificador único transaccional.
- Aplicar algoritmos de agrupamiento (*Clustering*) textual para detectar y evaluar posibles inconsistencias ortográficas o redundancias en las variables categóricas.

Índice

1. Introducción y Dataset Utilizado **3**

2. Importación del Dataset en OpenRefine **3**

3. Perfilado Inicial de Datos **4**
3.1. Perfilado de Valores en la columna Marca 4
3.2. Perfilado de la columna Tamaño (`Tamanio`) 5

4. Tratamiento de Valores Nulos Textuales **6**
4.1. Validación de la Limpieza 8

5. Verificación de Duplicados **8**

6. Conversión y Análisis de Variables Numéricas **9**

7. Tratamiento de Fechas **11**

8. Clustering Textual (Agrupamiento Heurístico) **11**
8.1. Agrupamiento en Categoría de Cliente 11
8.2. Agrupamiento de Ubicaciones (Ciudades) 12

9. Validación Final y Exportación **13**

10. Conclusiones **14**

1. Introducción y Dataset Utilizado

El presente informe técnico documenta la etapa de preparación de datos, un procedimiento fundamental dentro de la arquitectura de Business Intelligence orientada a consolidar la sanidad de la información.

Previo a esta fase, se construyó de manera íntegra un Data Warehouse dimensional bajo la metodología de Kimball utilizando la base de datos operacional Wide World Importers (WWI). Este repositorio analítico fue alojado en Microsoft SQL Server bajo la nomenclatura `WWI_Kimball`. Dentro de esta arquitectura, la tabla central `FactVentas` almacena un total de 228.265 registros y consolida las transacciones a nivel de línea de factura en relación directa con cinco dimensiones contextuales: `DimTiempo`, `DimProducto`, `DimCliente`, `DimUbicacion` y `DimVendedor`.

Para la presente práctica, se generó un dataset analítico desnormalizado ejecutando una consulta SQL que ensambla la información del modelo estrella. Dicho dataset integra atributos clave como identificadores de factura, fecha, descripciones dimensionales (producto, cliente, ubicación, vendedor) y las medidas cuantitativas de rendimiento (*cantidad vendida, precio unitario, venta sin impuesto, impuesto, venta total y beneficio*).

El flujo macro del proceso que precede y encuadra este trabajo se define de la siguiente manera: `WWI_Kimball` $\rightarrow$ `Consulta SQL` $\rightarrow$ `Archivo CSV` $\rightarrow$ `OpenRefine` $\rightarrow$ `Perfilado y limpieza` $\rightarrow$ `CSV Limpio`.

2. Importación del Dataset en OpenRefine

El archivo resultante de la extracción, en formato CSV, fue incorporado a la herramienta de calidad de datos OpenRefine.

Durante el proceso de configuración de la importación, se aplicaron controles predeterminados para asegurar la fidelidad estructural de los datos. Se verificó que el analizador (*parser*) reconociera correctamente la primera fila del documento como encabezados de columna, que el separador de campos coincidiera adecuadamente con la exportación del origen, y que la codificación de caracteres no alterara cadenas de texto especiales.

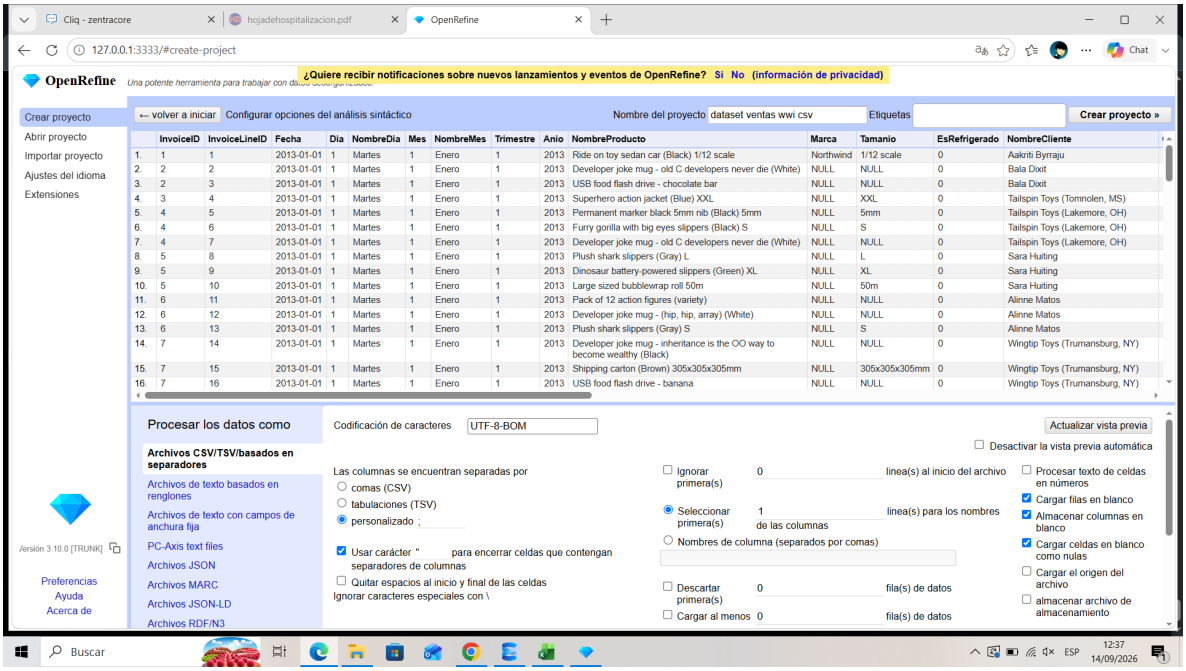


Figura 1: Importación exitosa y reconocimiento de las 228.265 filas en OpenRefine.

Como se evidencia en la Figura 1, tras crear el proyecto, OpenRefine interpretó correctamente las columnas, identificando un volumen exacto de **228.265 filas**. Esta coincidencia absoluta con el origen relacional demuestra una extracción e importación limpias, proveyendo un punto de partida seguro para el análisis de calidad.

3. Perfilado Inicial de Datos

El perfilado consiste en el análisis exploratorio de las variables para comprender su distribución y detectar anomalías o registros faltantes.

3.1. Perfilado de Valores en la columna Marca

Mediante una faceta de texto aplicada sobre la columna `Marca`, se categorizaron todas las ocurrencias presentes.

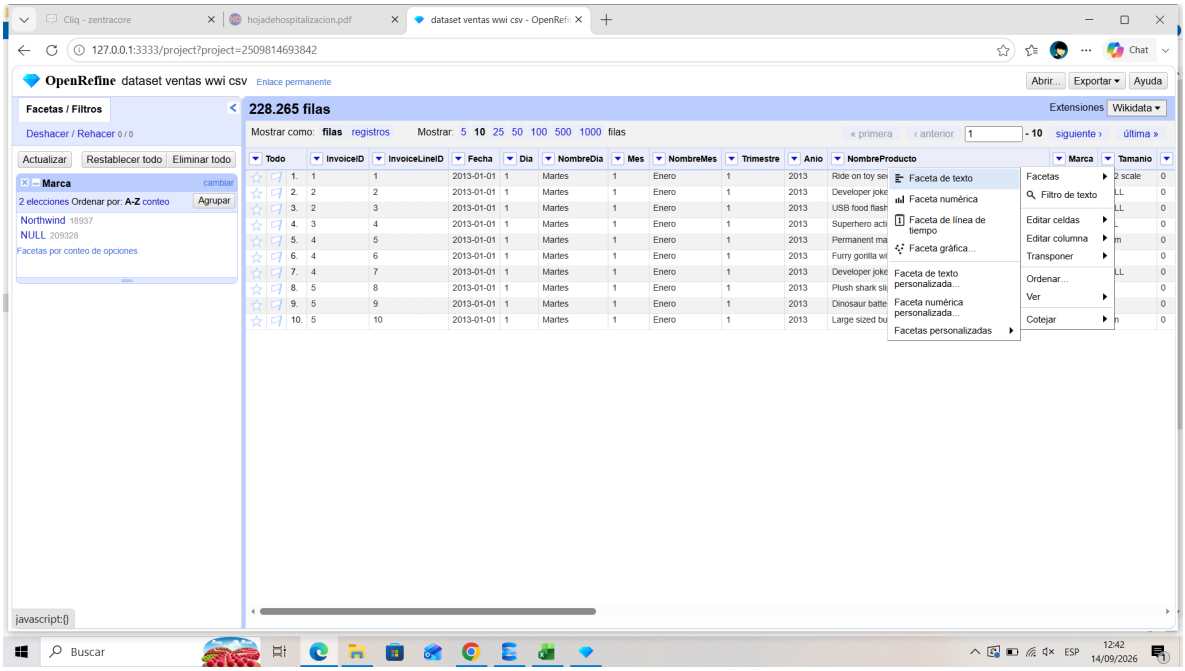


Figura 2: Identificación de valores en la columna Marca y detección de literales “NULL”.

La Figura 2 ilustra los resultados de esta revisión: se identificaron 18.937 registros con el valor legítimo de marca “Northwind”, mientras que 209.328 registros mostraron el valor “NULL”. El perfilado permitió determinar que esta última métrica correspondía a una cadena de texto literal (un *string* que dice "NULL") y no a un valor nulo real o campo vacío en el entorno de OpenRefine. Es fundamental aclarar que estos registros **no fueron eliminados**, dado que comercialmente es válido que ciertos artículos carezcan de una marca designada.

3.2. Perfilado de la columna Tamaño (`Tamanio`)

A continuación, se evaluó la columna `Tamanio` a través de otra faceta de texto.

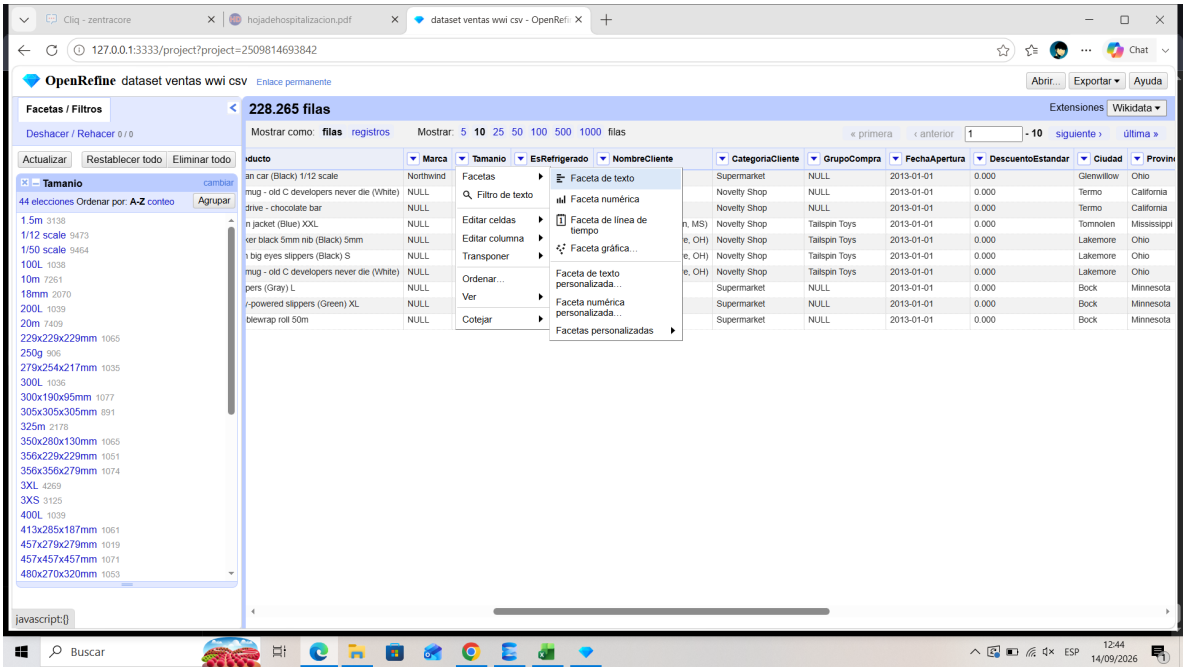


Figura 3: Inspección de las variaciones y escalas de magnitud en la columna Tamaño.

Como constata la Figura 3, la plataforma identificó 44 valores diferentes. Al inspeccionarlos, se observó una mezcla heterogénea de unidades de medida y escalas descriptivas (ej. *1.5m, 1/12 scale, 100L, 10m, 18mm, 250g, 3XL, 3XS, L, M, S, XL, XXL*). Desde un análisis de dominio, estos valores representan atributos válidos y heterogéneos de diferentes categorías de producto. Por consiguiente, se determinó de forma técnica que **no corresponde unificarlos o reemplazarlos indiscriminadamente**.

4. Tratamiento de Valores Nulos Textuales

Una de las deficiencias identificadas durante el perfilado fue la exportación de valores nulos desde SQL Server en forma de texto plano. Para garantizar que la herramienta interprete las celdas vacías correctamente y no como una categoría textual denominada “NULL”, se ejecutó un proceso de corrección sistémico.

Se aplicó la siguiente expresión en el lenguaje de reglas de OpenRefine (GREL):

```
if(value == "NULL", null, value)
```

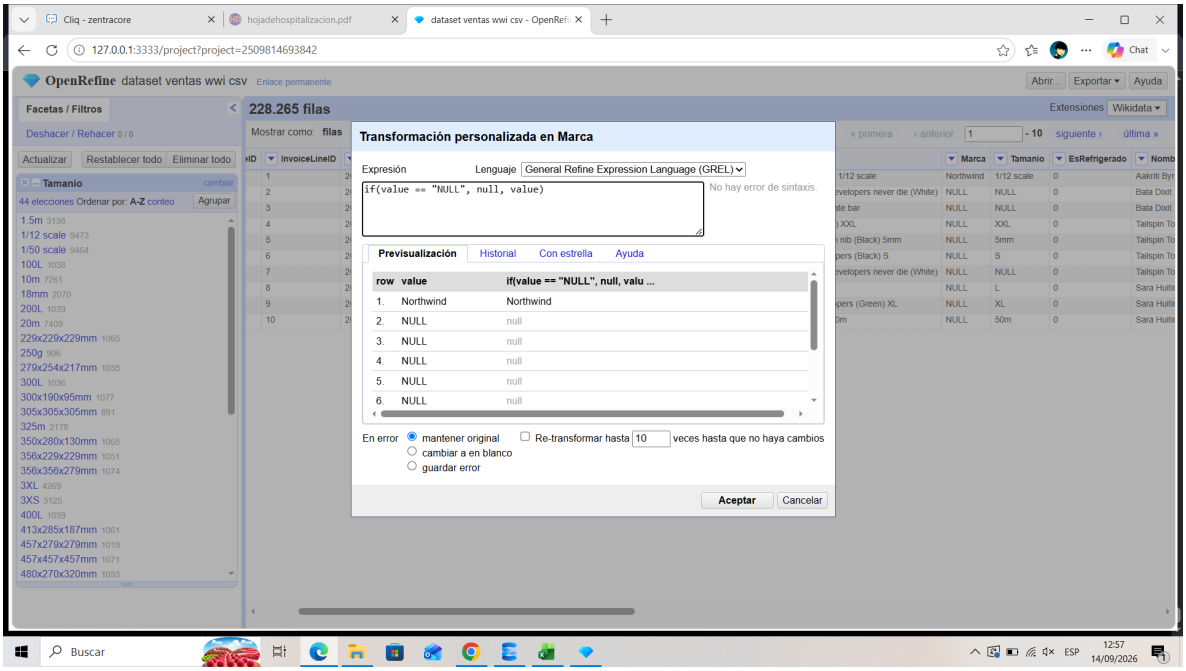


Figura 4: Aplicación de la transformación GREL para sustituir texto por nulos reales.

Esta transformación (Figura 4) evalúa condicionalmente el contenido de cada celda; si el texto es exactamente "NULL", lo convierte en un dato nulo genuino, caso contrario, mantiene el valor existente intacto.

El procedimiento se efectuó sobre tres columnas principales, obteniendo los siguientes resultados:

- **Columna** `Marca`**:** Los 209.328 valores anómalos fueron convertidos a celdas vacías. Los 18.937 registros de *Northwind* no sufrieron alteración alguna.
- **Columna** `Tamanio`**:** Se procesaron 67.315 apariciones textuales de “NULL”, asignándoles nulidad nativa sin alterar o eliminar la fila.
- **Columna** `GrupoCompra`**:** Se trataron 84.297 filas en estado nulo de manera exitosa, manteniendo vigentes los registros válidos pertenecientes a *Tailspin Toys* (72.249 filas) y *Wingtip Toys* (71.719 filas).

4.1. Validación de la Limpieza

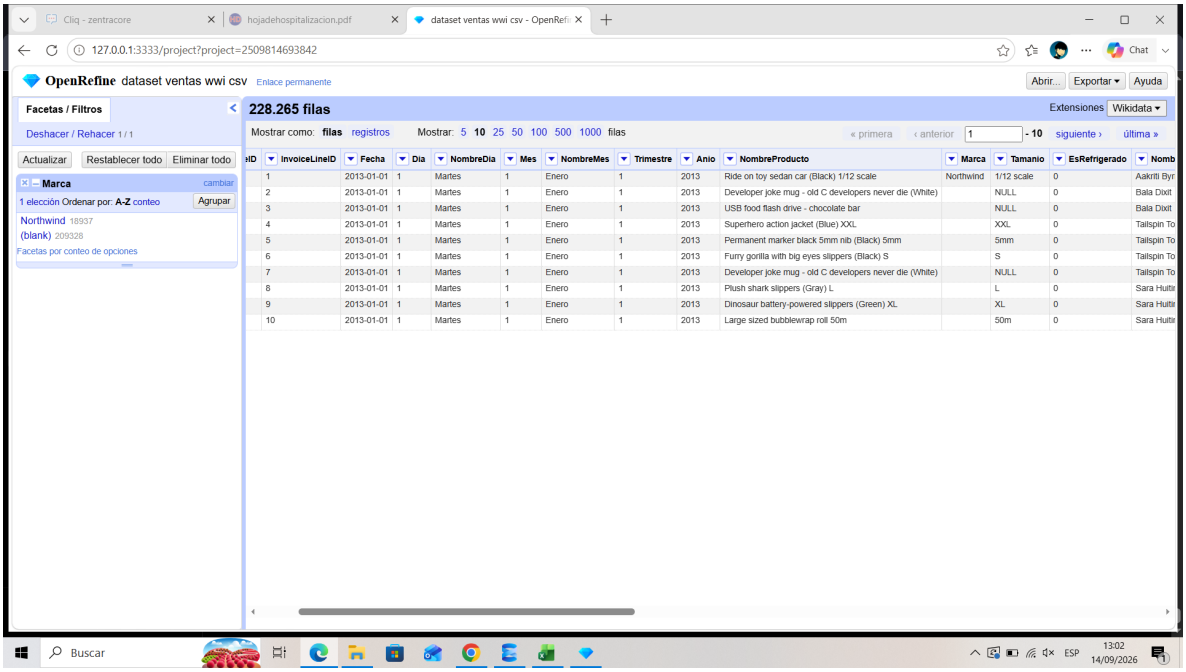


Figura 5: Faceta comprobando el éxito de la transformación en la columna Marca.

Para auditar la efectividad de este proceso, se regeneró la faceta de texto en `Marca` (Figura 5). El panel de control certificó que la categoría “NULL” desapareció, pasando a tabularse como *(blank)* para 209.328 líneas, mientras que *Northwind* se mantuvo estable. Lo más importante de esta validación es confirmar que la cardinalidad del dataset continuó siendo de **228.265 filas**, evidenciando que se mejoró la calidad del registro sin incurrir en pérdida de datos.

5. Verificación de Duplicados

El aseguramiento de la unicidad es crítico en datos transaccionales, ya que las duplicidades pueden sobredimensionar artificialmente las métricas financieras (Ingresos, Impuestos, Beneficio).

Para esta comprobación no se consideraron como duplicados a la repetición de clientes, fechas o productos, ya que son inherentes al modelo de negocio de ventas recurrentes. La validación se enfocó en `InvoiceLineID`, el cual representa de forma inequívoca y atómica la identificación única de la línea operativa de la factura.

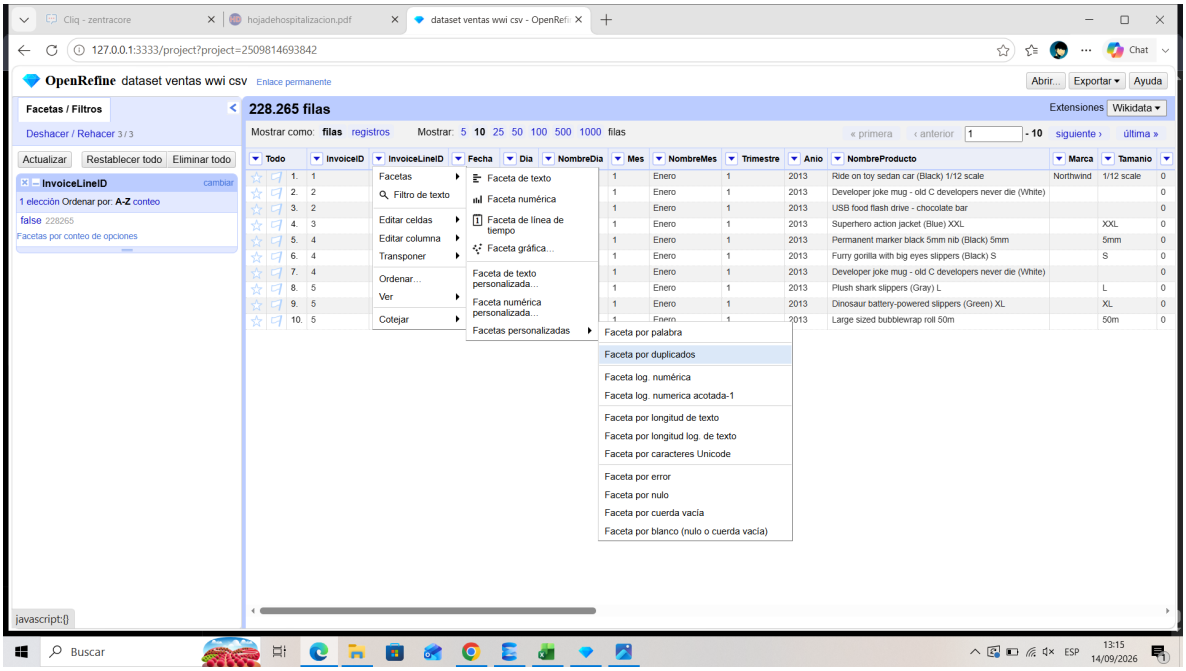


Figura 6: Evaluación de unicidad transaccional mediante la Faceta de Duplicados.

Se utilizó la función de faceta por duplicidad especializada de OpenRefine sobre `InvoiceLineID` (Figura 6). El motor analítico retornó el flag *false* para las 228.265 filas, confirmando que se hallaron **cero (0) duplicados**. Debido a esta limpieza de origen, no se requirió la ejecución de rutinas de eliminación.

6. Conversión y Análisis de Variables Numéricas

Al ser el origen un archivo CSV (texto plano de naturaleza no tipada), las métricas cuantitativas ingresaron a OpenRefine como cadenas de caracteres. Resultó indispensable convertirlas a su tipo primitivo numérico correcto para permitir un análisis de dispersión y la posterior inyección estructurada.

Las transformaciones numéricas estándar de la plataforma fueron aplicadas sobre las siguientes columnas transaccionales: `CantidadVendida`, `PrecioUnitario`, `VentaSinImpuesto`, `Impuesto`, `VentaTotal` y `Beneficio`.

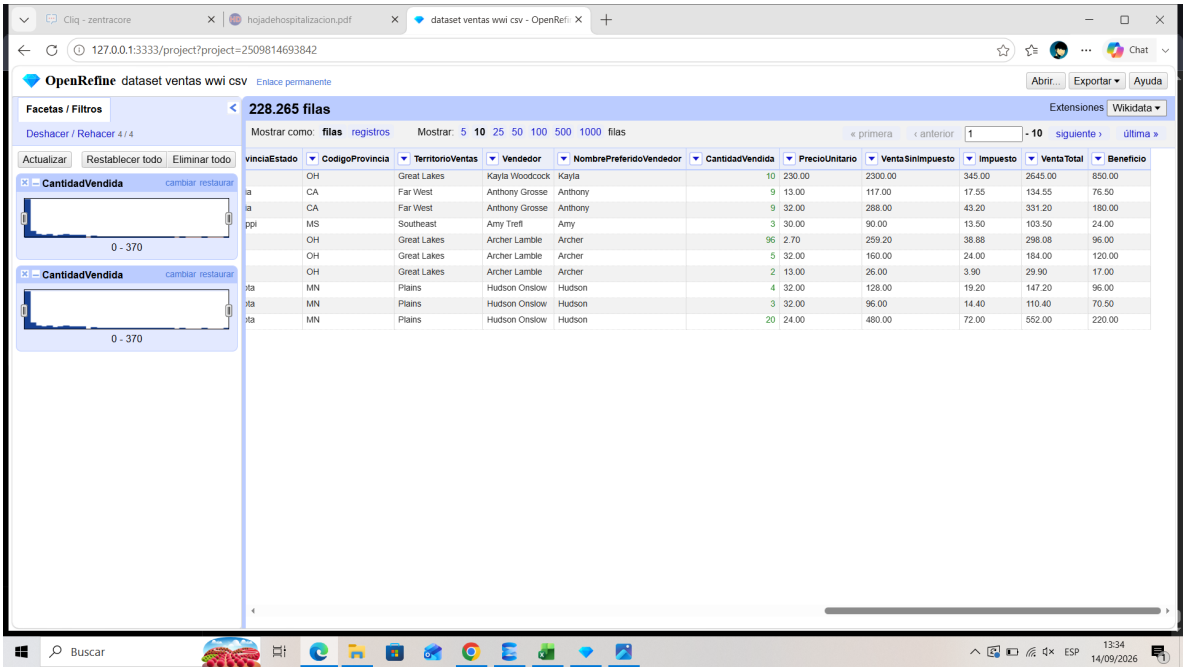


Figura 7: Conversión de la cadena de texto y representación numérica.

Una vez completada la conversión, se habilitaron las facetas numéricas para analizar estadísticamente las variables (Figura 7). A través de los histogramas interactivos de OpenRefine se evaluó la dispersión general de los indicadores de rendimiento.

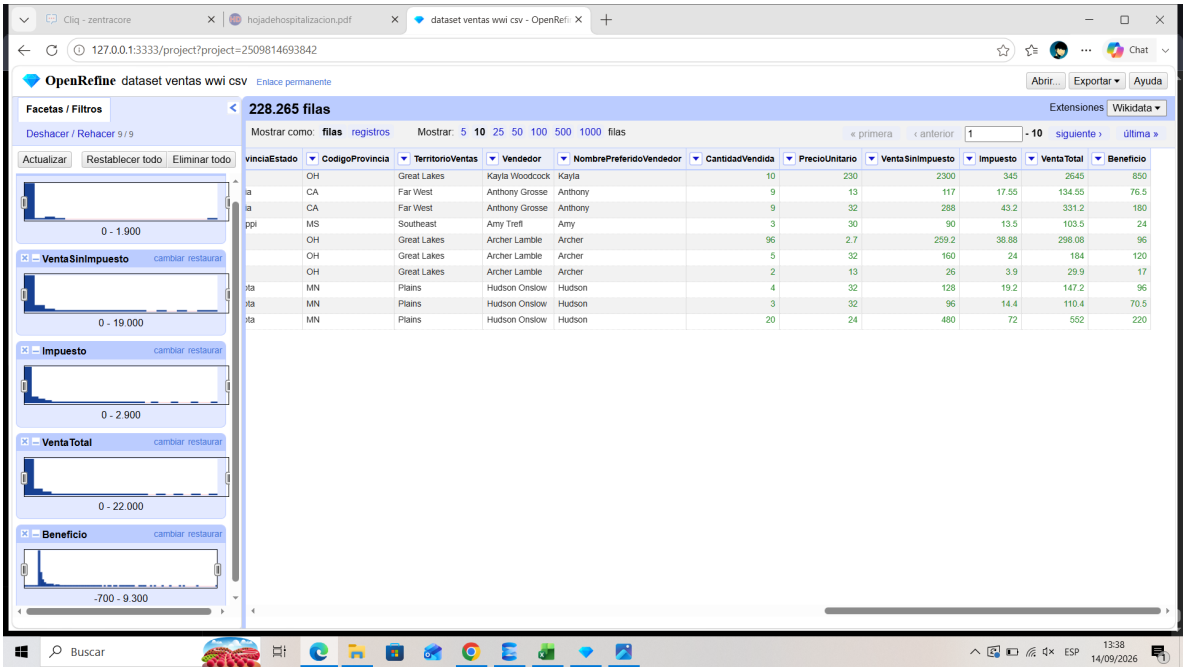


Figura 8: Histogramas de dispersión reflejando las distribuciones numéricas de las métricas de negocio.

La observación múltiple (Figura 8) permitió perfilar las distribuciones operacionales del negocio sin detectar anomalías corruptas. Los rangos operativos aproximados son:

- **PrecioUnitario:** 0 – 1.900 $
- **VentaSinImpuesto:** 0 – 19.000 $
- **Impuesto:** 0 – 2.900 $
- **VentaTotal:** 0 – 22.000 $
- **Beneficio:** -700 – 9.300 $

El análisis determinó que, aunque existen beneficios negativos o montos de venta inusualmente altos respecto al promedio, **no se procederá a eliminarlos ni truncarlos**. Estas dispersiones pueden representar operaciones comerciales válidas (ventas al por mayor institucionales, descuentos extremos o liquidaciones por debajo del costo) y no constituyen un error técnico del sistema transaccional.

7. Tratamiento de Fechas

Al igual que con las variables numéricas, las columnas temporales (`Fecha` y `FechaApertura`) requerían ser tipificadas para su correcto análisis cronológico en etapas subsecuentes.

Se procedió utilizando la herramienta de corrección: *Editar celdas* → *Transformaciones comunes* → *A fecha*. Este comando parsea el formato ISO del texto subyacente de CSV, instruyendo a OpenRefine para que trate dichos vectores en el dominio del tiempo (*Datetime*). Este proceso garantizó la consistencia analítica sin alterar en lo más mínimo la cronología original del dato.

8. Clustering Textual (Agrupamiento Heurístico)

El clustering en OpenRefine corresponde estrictamente a la agrupación de valores textuales similares con la finalidad exclusiva de detectar errores ortográficos o inconsistencias de entrada humana (limpieza). Es un procedimiento de normalización y difiere conceptualmente del algoritmo de Machine Learning predictivo.

8.1. Agrupamiento en Categoría de Cliente

El primer experimento de normalización se aplicó a la columna `CategoriaCliente`.

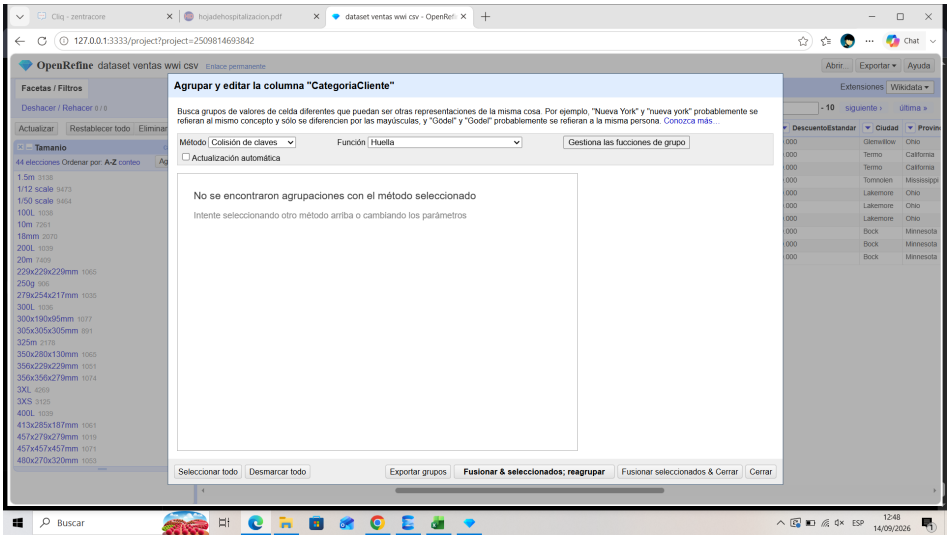


Figura 9: Evaluación de colisión de claves demostrando cero agrupaciones difusas en la categoría de clientes.

Se utilizó el método *Colisión de claves* con la función *Huella* (*Fingerprint*). El motor heurístico (Figura 9) no detectó ninguna coincidencia ni variante textual sugerida, demostrando contundentemente que las categorías se encontraban ortográficamente pulcras y exentas de redundancias, sin requerir fusión de valores.

8.2. Agrupamiento de Ubicaciones (Ciudades)

La auditoría prosiguió evaluando la integridad textual de la columna `Ciudad`. Se intentó primero con la Colisión de Claves sin éxito. Posteriormente, se afinó la búsqueda optando por el método de *Vecino más cercano* utilizando la función de distancia *Levenshtein* con un radio de sensibilidad de 1.0.

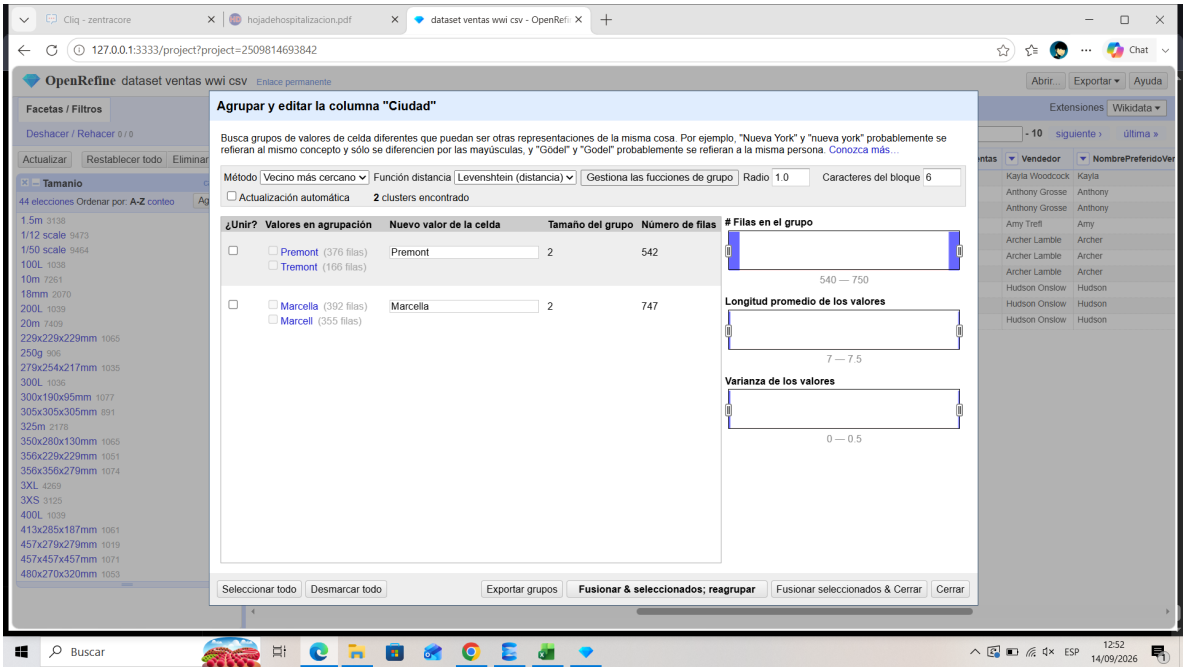


Figura 10: Detección de similitud ortográfica mediante el algoritmo Levenshtein.

Como documenta la Figura 10, el análisis probabilístico identificó dos clusters de alto riesgo:

- **Cluster 1:** Premont (376 filas) y Tremont (166 filas). Total: 542 operaciones.
- **Cluster 2:** Marcella (392 filas) y Marcell (355 filas). Total: 747 operaciones.

Tras auditar geográficamente los hallazgos, se determinó una resolución de negocio: **NO fusionarlos**. Pese a la distancia tipográfica minúscula de *Levenshtein*, son jurisdicciones/nombres válidos distintos. La similitud en los caracteres no prueba que representen la misma entidad operativa. Por tanto, el algoritmo de clustering operó eficazmente como mecanismo de detección y evaluación crítica, previniendo la alteración destructiva de información geográfica lícita.

9. Validación Final y Exportación

Tras finalizar todos los bloques analíticos y operativos de saneamiento (conversión, depuración GREL, tipado fuerte y detección ortográfica), el sistema de control del proyecto auditó el conjunto final.

Se corroboró de forma absoluta que el *grid* de OpenRefine seguía exhibiendo un conteo maestro de **228.265 filas**. Las transformaciones, aplicadas de manera controlada y académica, lograron mitigar la representación defectuosa de los nulos y organizar los tipos de datos sin comprometer la integridad estructural original, probando que no era necesaria la extirpación para obtener calidad.

Finalmente, el insumo curado fue exportado bajo formato CSV para consolidar la salida: `dataset_ventas_wwi_limpio.csv`

Este archivo resultante se establece oficialmente como el objeto de datos limpio y estandarizado que respaldará con fiabilidad estadística las arquitecturas predictivas y de exploración en las fases sucesivas del proyecto, asegurando que las inyecciones analíticas futuras carezcan de *Data Smells* o tipados ambiguos.

10. Conclusiones

1. El entorno OpenRefine facilitó el manejo eficiente de un volumen denso compuesto por **228.265 registros transaccionales**. Es de vital importancia académica destacar que **no se eliminaron registros** bajo ninguna circunstancia, resguardando en un 100 % la volumetría de las ventas consolidadas.

2. Mediante el despliegue del lenguaje interno de OpenRefine (GREL), se normalizó sustancialmente la calidad técnica del corpus corrigiendo las anomalías de tipo texto plano presentes en columnas categóricas, reemplazando con pericia la cadena literal “NULL” por un formato de ausencia nativo sin pérdida de registro.

3. La exploración del componente primario `InvoiceLineID` evidenció empíricamente una tasa nula de registros cruzados, demostrando la integridad de exportación del Data Warehouse y confirmando la ausencia total de duplicados transaccionales ocultos en la capa del cliente.

4. Se rectificaron transversalmente las topologías de datos provenientes del formato CSV para todos los vectores financieros y temporales (a tipos Numérico y Fecha). Este *cast* resulta crítico y habilita sin error el consumo estadístico de la analítica multidimensional en fases futuras.

5. Las estrategias algorítmicas implementadas a través de *Clustering Textual* (*Fingerprint* y *Levenshtein*) se revelaron como mecanismos altamente certeros para auditar el factor de error de entrada humana. Las coincidencias ortográficas detectadas en el rubro metropolitano se desecharon del esquema de fusión, previniendo exitosamente la pérdida de contexto geográfico de ciudades que, aunque parecidas, diferencian mercados de negocio distintos.

6. El resultado técnico de la depuración es un conjunto de datos consolidado (`dataset_ventas_wwi_limpio` con una mejorada calidad y consistencia lógica que servirá de sustrato estable en las subsiguientes etapas de modelación analítica.